【발명의 설명】

【발명의 명칭】

딥보이스 탐지 장치 및 방법{Apparatus and method for deep voice detection}

【기술분야】

본 발명은 딥보이스 탐지 장치 및 방법에 관한 것으로, 보다 상세하게는 머신러닝 모델을 이용하여 실제 음성과 인공적으로 생성된 음성을 판별하는 딥보이스 탐지 장치 및 방법에 관한 것이다.

【발명의 배경이 되는 기술】

인공신경망 기반의 음성 합성(딥보이스)은 딥러닝 기술을 이용하여 특정인의 목소리를 복제하는 기술을 의미한다.

최근에는 보이스피싱과 같은 금융 사기 범죄나 여론 조작에 악용되면서, 딥보이스 탐지에 대한 필요성이 높아지고 있다.

일반적으로 AI를 이용한 딥보이스 탐지는, 방대한 양의 실제 음성과 합성 음성 데이터를 AI 모델에 학습시켜 두 음성 데이터 집단 사이에 존재하는 차이를 식별하는 원리에 기초한다.

그러나, 원시 파형이나 스펙트로그램을 직접 입력으로 사용하는 종래의 딥보이스 탐지 기술은 음성의 물리적, 음향학적 특성과는 무관한 특징에 과적합되는 문제점이 있었다.

그리고, 종래의 딥보이스 탐지 기술은 최종 판별을 단일 모델에 의존하므로 해당 모델의 성능이 전체 시스템의 성능을 좌우하는 문제점이 있었다.

또한, 종래의 딥보이스 탐지 기술은 개발 시점의 데이터셋으로 학습된 정적 모델을 이용하므로, 딥보이스 생성 기술의 변화, 사용자 음성 변화 및 녹음 환경의 변화에 따라 탐지 성능이 저하되는 문제점이 있었다.

또한, 불특정 다수의 음성으로 구성된 데이터셋으로 학습된 범용적 모델을 이용하므로, 사용자 개개인의 고유한 음성 패턴이나 단말기별 녹음 특성이 반영되지 못하여 개인화된 탐지를 제공하지 못하는 문제점이 있었다.

【선행기술문헌】

【특허문헌】

한국 등록특허공보 제10-2024-0042921호

【발명의 내용】

【해결하고자 하는 과제】

본 발명은 전술한 바와 같은 문제점을 해결하기 위하여 창안된 것으로, 본 발명의 목적은 음성의 물리적 특성과 관련한 다수의 음향 특징을 추출하여 특징 벡터를 구성하는 딥보이스 탐지 장치 및 방법을 제공하는 것이다.

본 발명의 다른 목적은 심층 네트워크와 랜덤 포레스트를 병렬로 결합한 앙상블 분류기에 기초하여 딥보이스를 탐지하는 딥보이스 탐지 장치 및 방법을 제공하는 것이다.

본 발명의 또 다른 목적은 애플리케이션을 통해 단말기 소유자의 통화 기록을 자동으로 수집하여 딥보이스 탐지 모델을 갱신하는 딥보이스 탐지 장치 및 방법

을 제공하는 것이다.

본 발명의 목적은 이상에서 언급한 과제에 한정되지 않으며, 언급되지 않은 본 발명의 다른 목적 및 장점들은 하기의 설명에 의해서 이해될 수 있고, 본 발명의 실시예에 의해 보다 분명하게 이해될 것이다. 또한, 본 발명의 목적 및 장점들은 특허청구범위에 나타낸 수단 및 그 조합에 의해 실현될 수 있음을 알 수 있을 것이다.

【과제의 해결 수단】

상기 목적을 위하여, 본 발명의 일 실시예에 따른 딥보이스 탐지 장치는, 입력된 음성으로부터 하나 이상의 음향 특징을 추출하여 특징 벡터를 생성하는 특징 벡터 생성부; 상기 특징 벡터에 기초하여 RF(Random Forest) 예측 확률 및 DNN(Deep Neural Network) 예측 확률을 생성하는 예측 확률 생성부; 및 상기 RF 예측 확률과 상기 DNN 예측 확률의 산술 평균 값이 기 설정된 임계값 미만인 경우, 상기 음성을 딥보이스로 결정하는 딥보이스 판별부를 포함한다.

바람직하게는, 상기 특징 벡터 생성부는, MFCC(Mel-Frequency Cepstral Coefficient), MFCC 델타(Delta), MFCC 델타-델타(Delta-Delta)에 대한 특징 중 적어도 하나를 추출하는 제1 추출부; 스펙트럼 대비(Spectral Contrast), 스펙트럼 중심(Spectral Centroid), 스펙트럼 롤오프(Spectral Rolloff), 스펙트럼 대역폭(Spectral Bandwidth), 스펙트럼 평탄도(Spectral Flatness)에 대한 특징 중 적어도 하나를 추출하는 제2 추출부; 크로마(Chroma), 톤네츠(Tonnetz), HNR(Harmonic-to-Percussive Ratio)에 대한 특징 중 적어도 하나를 추출하는 제3 추출부; 및 제로 크

로싱율(Zero Crossing Rate), RMS 에너지 및 속도(Tempo)에 대한 특징 중 적어도 하나를 추출하는 제4 추출부 중 적어도 하나를 포함하고, 상기 특징 벡터 생성부는, 상기 제1 추출부 내지 상기 제4 추출부로부터 추출되는 상기 하나 이상의 음향 특징에 기초하여 상기 특징 벡터를 생성한다.

그리고, 본 발명의 일 실시예에 따른 딥보이스 탐지 시스템은, 입력된 음성으로부터 하나 이상의 음향 특징을 추출하여 특징 벡터를 생성하는 사용자 단말기; 및 상기 사용자 단말기로부터 상기 특징 벡터를 수집하고, 복수의 딥보이스 판별 모델을 이용하여 상기 특징 벡터에 대해 딥보이스 여부를 판별하는 서버를 포함한다.

바람직하게는, 상기 서버는, 상기 사용자 단말기로부터 수집된 사용자 음성의 특징 벡터를 제1 클래스로, 상기 사용자 음성에 상응하여 생성된 딥보이스 음성의 특징 벡터를 제2 클래스로 포함하는 데이터셋을 생성하고, 상기 복수의 딥보이스 판별 모델은, 상기 데이터셋을 학습 데이터로 한다.

바람직하게는, 상기 서버는, 상기 사용자 단말기의 사용자 음성으로부터 추출된 특징 벡터에 기초하여 상기 데이터셋을 생성하고, 상기 사용자 단말기에서 통화 중 수신되는 음성으로부터 추출된 특징 벡터에 기초하여 상기 딥보이스 여부를 판별한다.

【발명의 효과】

본 발명에 따르면, 음성의 물리적 특성과 관련한 다수의 음향 특징에 기초하여 딥보이스 여부를 판별하므로, 보다 안정적으로 딥보이스를 탐지할 수 있는 효과

를 가진다.

그리고, 본 발명에 따르면, 한 모델이 놓칠 수 있는 딥보이스의 특징을 다른 모델이 포착하게 하여 탐지 정확도를 향상시키는 효과를 가진다.

또한, 본 발명에 따르면, 자동으로 수집되는 통화 기록에 기초하여 인공지능이 갱신되므로, 환경 변화에 따른 탐지 성능 저하를 방지하고, 애플리케이션 이용자들에 대해 개인화된 딥보이스 구분이 가능한 효과를 가진다.

【도면의 간단한 설명】

도 1은 본 발명의 일 실시예에 따른 딥보이스 탐지 장치의 구성도이다.

도 2는 본 발명의 일 실시예에 따른 딥보이스 탐지 방법의 순서도이다.

도 3은 본 발명의 일 실시예에 따른 특징 벡터 생성부의 구성도이다.

도 4는 본 발명의 일 실시예에 따른 예측 확률 생성부의 구성도이다.

도 5는 본 발명의 일 실시예에 따른 랜덤 포레스트(RF) 분류기의 하이퍼 변수를 나타낸 표이다.

도 6은 본 발명의 일 실시예에 따른 딥 뉴럴 네트워크 분류기의 상세 구조를 나타내는 도면이다.

도 7은 본 발명의 일 실시예에 따른 딥 뉴럴 네트워크 분류기의 하이퍼변수를 나타낸 표이다.

도 8은 본 발명의 일 실시예에 따른 성능 평가 결과를 나타낸 표이다.

도 9는 본 발명의 다른 실시예에 따른 딥보이스 탐지 시스템의 아키텍처이다.

도 10은 실제 음성과 딥보이스의 MFCC(멜 주파수 켑스트럼 계수) 및 MSE값을 비교한 도면이다.

도 11은 실제 음성과 딥보이스의 실제 음성(원본)과 딥보이스 각각의 MFCC(멜 주파수 켑스트럼 계수) 시퀀스 간의 DTW(Dynamic Time Warping) 거리 행렬 및 누적 거리를 나타낸 도면이다.

도 12는 실제 음성과 딥보이스의 실제 음성과 딥보이스의 RMS(Root Mean Square) 에너지를 비교한 도면이다.

도 13은 실제 음성과 딥보이스의 ZCR(Zero Crossing Rate)을 비교한 도면이다.

도 14는 실제 음성과 딥보이스의 크로마그램을 비교한 도면이다.

도 15는 실제 음성과 딥보이스의 스펙트로그램을 비교한 도면이다.

도 16은 실제 음성과 딥보이스의 스펙트럼 대비를 비교한 도면이다.

도 17은 실제 음성과 딥보이스의 피치 컨투어를 비교한 도면이다.

【발명을 실시하기 위한 구체적인 내용】

이하, 첨부된 도면을 참조하여 본 명세서에 개시된 실시예를 상세히 설명하되, 도면 부호에 관계없이 동일하거나 유사한 구성요소는 동일한 참조 번호를 부여하고 이에 대한 중복되는 설명은 생략하기로 한다. 이하의 설명에서 사용되는 구성요소에 대한 접미사 "모듈" 및 "부"는 명세서 작성의 용이함만이 고려되어 부여되거나 혼용되는 것으로서, 그 자체로 서로 구별되는 의미 또는 역할을 갖는 것은 아니다. 또한, 본 명세서에 개시된 실시예를 설명함에 있어서 관련된 공지 기술에

대한 구체적인 설명이 본 명세서에 개시된 실시예의 요지를 흐릴 수 있다고 판단되는 경우 그 상세한 설명을 생략한다. 또한, 첨부된 도면은 본 명세서에 개시된 실시예를 쉽게 이해할 수 있도록 하기 위한 것일 뿐, 첨부된 도면에 의해 본 명세서에 개시된 기술적 사상이 제한되지 않으며, 본 발명의 사상 및 기술 범위에 포함되는 모든 변경, 균등물 내지 대체물을 포함하는 것으로 이해되어야 한다.

제1, 제2 등과 같이 서수를 포함하는 용어는 다양한 구성요소들을 설명하는데 사용될 수 있지만, 상기 구성요소들은 상기 용어들에 의해 한정되지는 않는다. 상기 용어들은 하나의 구성요소를 다른 구성요소로부터 구별하는 목적으로만 사용된다.

어떤 구성요소가 다른 구성요소에 "연결되어" 있다거나 "접속되어" 있다고 언급된 때에는, 그 다른 구성요소에 직접적으로 연결되어 있거나 또는 접속되어 있을 수도 있지만, 중간에 다른 구성요소가 존재할 수도 있다고 이해되어야 할 것이다. 반면에, 어떤 구성요소가 다른 구성요소에 "직접 연결되어" 있다거나 "직접 접속되어" 있다고 언급된 때에는, 중간에 다른 구성요소가 존재하지 않는 것으로 이해되어야 할 것이다.

이하에서는 도 1 내지 도 17을 참조하여 본 발명에 따른 딥보이스 탐지 장치 및 방법에 대해 상술한다.

도 1은 본 발명의 일 실시예에 따른 딥보이스 탐지 장치의 구성도이고, 도 2는 본 발명의 일 실시예에 따른 딥보이스 탐지 방법의 순서도이다.

도 1을 참조하면, 본 발명의 일 실시예에 따른 딥보이스 탐지 장치(100)는 특징 벡터 생성부(110), 예측 확률 생성부(120), 딥보이스 판별부(130)를 포함한다.

분석 대상이 되는 음성 신호를 입력받는다(도 2의 단계 S210 참조). 이는 실시간 통화 음성, 녹음 파일 등 다양한 형태일 수 있다.

특징 벡터 생성부(110)는 다차원의 음향 특징들을 추출하여 하나의 특징 벡터로 구성한다(도 2의 단계 S220 참조).

예컨대, 특징 벡터 생성부(110)는 원본 음성 신호에 대해 복수의 특징 추출 모듈을 병렬 또는 직렬로 적용한다.

도 3은 본 발명의 일 실시예에 따른 특징 벡터 생성부의 구성도이다.

도 3을 참조하면, 본 발명의 일 실시예에 따른 복수의 특징 추출 모듈은 제1 추출부(111) 내지 제4 추출부(114)로 구성되며, 제1 추출부(111)는 음성의 스펙트럼 정보를 인간의 청각 특성에 맞게 변환한 MFCC(Mel-Frequency Cepstral Coefficient) 및 MFCC의 동적 변화를 나타내는 MFCC 평균, MFCC 델타(Delta), MFCC 델타-델타(Delta-Delta) 특징을 추출한다.

제2 추출부(112)는 스펙트럼 대비(Spectral Contrast), 스펙트럼 중심(Spectral Centroid), 스펙트럼 롤오프(Spectral Rolloff), 스펙트럼 대역폭(Spectral Bandwidth), 스펙트럼 평탄도(Spectral Flatness) 등 스펙트럼의 분포와 형태에 관한 특징을 추출한다.

제3 추출부(113)는 음의 높낮이와 관련된 하모닉 정보를 추출하며, 예컨대 크로마(Chroma), 톤네츠(Tonnetz), HNR(Harmonic-to-Percussive Ratio) 등을 추출한

다.

제4 추출부(114)는 제로 크로싱율(Zero Crossing Rate), RMS 에너지 및 속도(Tempo) 등 시간 영역에서의 특징을 추출한다.

특징 벡터 생성부(110)는 제1 추출부 내지 상기 제4 추출부로부터 추출되는 모든 특징들을 하나의 고차원 특징 벡터로 통합한다.

예측 확률 생성부(120)는 상기 특징 벡터에 기초하여 RF(Random Forest) 예측 확률 및 DNN(Deep Neural Network) 예측 확률을 생성한다(도 2의 단계 S230 참조).

이처럼 본 발명은 MFCC, 크로마, 스펙트럼 관련 특징 등 다차원의 음향 특징을 종합적으로 활용함으로써, 특정 특징에 대한 의존성을 줄이고 새로운 유형의 딥보이스 생성 기술에 대해서도 탐지 성능을 유지할 수 있는 효과가 있다.

도 4는 본 발명의 일 실시예에 따른 예측 확률 생성부의 구성도이다.

도 4를 참조하면, 생성된 특징 벡터는 미리 학습된 두 개의 분류기, 즉 예측 확률 생성부(120)의 랜덤 포레스트 분류기(121)와 딥 뉴럴 네트워크 분류기(122)에 동시에 입력되고, 각 분류기는 독립적으로 입력된 특징 벡터에 기초하여 해당 음성이 딥보이스일 확률을 각각 계산한다.

랜덤 포레스트 분류기(121)는 다수의 결정 트리로 구성된 앙상블 모델로서, 입력된 특징 벡터를 기반으로 RF 예측 확률을 출력한다.

도 5는 본 발명의 일 실시예에 따른 랜덤 포레스트(RF) 분류기의 하이퍼 변수를 나타낸 표이다.

랜덤 포레스트 분류기(121)는 100개의 결정 트리(n_estimators)를 사용하여 구성된다. random_state를 42로 고정하여 실험 결과의 재현성을 확보하였다. 다른 하이퍼변수들은 scikit-learn 라이브러리의 기본값을 사용할 수 있으나, 데이터셋의 특성에 따라 추가적인 튜닝이 가능하다.

딥 뉴럴 네트워크 분류기(122)는 다수의 은닉층으로 구성된 인공 신경망으로서, 입력된 특징 벡터를 기반으로 DNN 예측 확률을 출력한다.

도 6은 본 발명의 일 실시예에 따른 딥 뉴럴 네트워크 분류기(122)의 상세 구조를 나타내는 도면이다.

도 6을 참조하면, 본 발명의 일 실시예에 따른 딥 뉴럴 네트워크 분류기(122)는 다수의 완전 연결 계층(Dense Layer)으로 구성된다.

입력층은 45차원의 특징 벡터를 입력받는다. 제1 은닉층(1221)은 64개의 유닛과 ReLU 활성화 함수를 포함하며, 그 뒤에 30% 비율의 드롭아웃(Dropout) 계층(12211)이 연결되어 과적합을 방지한다. 이어서 32개의 유닛을 가진 제2 은닉층(1222)과 드롭아웃 계층(12221), 최종 출력층(1224)은 1개의 유닛과 시그모이드 활성화 함수를 사용하여, 입력된 음성이 딥보이스일 확률을 0과 1 사이의 값으로 출력한다.

도 7은 본 발명의 일 실시예에 따른 딥 뉴럴 네트워크 분류기(122)의 하이퍼변수를 나타낸 표이다.

도 7을 참조하면, 딥 뉴럴 네트워크 분류기(122)는 최적화 함수(Optimizer)로는 Adam을 사용하며, 학습률(Learning Rate)은 0.001로 설정된다. 손실 함수(Loss

Function)는 이진 분류 문제에 적합한 binary_crossentropy를 사용하였다. 학습은 총 150 에포크(Epochs) 동안 진행되며, 배치 크기(Batch Size)는 8로 설정하였다. 또한, 불필요한 학습을 방지하고 최적의 모델을 저장하기 위해 손실 값을 기준으로 10 에포크의 patience를 갖는 조기 종료(Early Stopping) 콜백을 사용하였다.

딥보이스 판별부(130)는 상기 RF 예측 확률과 상기 DNN 예측 확률의 산술 평균 값이 기 설정된 임계값 미만인 경우, 상기 음성을 딥보이스로 결정한다.

예컨대, 딥보이스 판별부(130)는 각 분류기의 예측 확률의 산술 평균값이 임계값보다 크면(도 2의 단계 S240 참조) 해당 음성을 딥보이스로 판별하고, 그렇지 않으면 실제 음성으로 판별하여 그에 따른 조치(예, 사용자에게 경고 알림, 통화 차단 등)를 수행한다(도 2의 단계 S250 및 단계 S260 참조).

이처럼 서로 다른 학습 매커니즘을 가진 RF와 DNN 모델을 앙상블함으로써, 단일 모델이 놓칠 수 있는 다양한 형태의 딥보이스 특징을 상호 보완적으로 탐지하여 전체적인 탐지 정확도와 신뢰도를 향상시키는 효과를 가진다.

본 발명의 일 실시예에 따른 학습 및 평가에 사용된 데이터셋에는 총 1,692개의 음성 파일이 사용되었다. 이 중 모델 학습에는 5초 분량의 음성 파일 약 700개가 사용되었다.

성능 평가는 학습에 사용되지 않은 별도의 음성 파일 992개로 구성된 테스트 데이터셋을 통해 수행되었다. 테스트 데이터셋은 실제 음성 496개와 딥보이스 음성 496개로 구성되었다.

도 8은 본 발명의 일 실시예에 따른 성능 평가 결과를 나타낸 표이다.

도 8을 참조하면, 992개의 평가 데이터셋에 대한 본 발명의 성능 평가 결과, 총 12개의 오탐(misclassification)이 발생하여 최종적으로 98.8%의 높은 정확도(Accuracy)를 달성하였다. 오탐률(Error Rate)은 1.2%로 나타났다.

이하에서는 본 발명의 일 실시예에 따른 딥보이스 탐지 시스템에 대해 설명한다.

본 발명의 일 실시예에 따른 딥보이스 탐지 시스템은 서버(10) 및 사용자 단말기(20)를 포함하고, 사용자 단말기(20)는 하나 이상의 음향 특징을 추출하여 특징 벡터를 생성하고, 서버(10)는 사용자 단말기로부터 수신된 상기 특징 벡터를 복수의 딥보이스 판별 모델에 입력하여 모델의 출력값에 따라 딥보이스 여부를 판별한다.

도 9는 본 발명의 다른 실시예에 따른 딥보이스 탐지 시스템의 아키텍처이다.

도 9를 참조하면, 서버(10)는 사용자 단말기에서 통화 중 수신되는 음성으로부터 추출된 특징 벡터를 복수의 딥보이스 판별 모델에 입력하여 딥보이스 여부를 판별한다.

서버(10)의 데이터베이스에 사용자 단말기 소유자의 음성이 수집되므로, 서버(10)는 추가된 음성을 토대로 딥보이스 음성을 생성하고 실제 음성과 딥보이스 음성 각각에 대한 특징 추출을 수행하여 학습용 데이터셋을 생성한다.

여기서, 사용자 단말기로부터 수집된 사용자 음성의 특징 벡터는 제1 클래스(실제 음성)로, 사용자 음성에 상응하여 생성된 딥보이스 음성의 특징 벡터는 제2

클래스(딥보이스 음성)로 자동 태깅된다.

이처럼 사용자의 통화 데이터를 지속적으로 학습에 활용하는 구조를 통해, 애플리케이션을 이용하는 사용자들(예, 가족, 친구)에 최적화된 탐지 모델을 구축하며, 시간이 지남에 따라 탐지 정확도가 향상되어 진화하는 보이스피싱 위협에 동적으로 대응할 수 있다.

이하에서는 본 발명에서 추출되는 각 음향 특징을 설명한다.

도 10은 실제 음성과 딥보이스의 MFCC(멜 주파수 켑스트럼 계수) 및 MSE값을 비교한 도면이다.

MFCC는 음성의 스펙트럼 에너지 분포를 저차원 공간에 나타내어 음색과 발음 특성을 나타낸다.

도 10을 참조하면, 실제 음성(원본)은 각 프레임(시간)별로 MFCC값이 다양한 폭(-400 ~ 200 이상)에서 고르게 분포하며, 특정 프레임에서는 짙은 빨간색(고값), 다른 프레임에서는 파란색(저값)을 자주 넘나드는 것을 특징으로 한다. 구체적으로, 일부 음소·무성음·자음 구간에서 MFCC가 순간적으로 낮게 떨어지며 파란색으로 뚜렷 → 특징값이 분명히 드러나고 발음이 선명하게 구분된다.

반면, 딥보이스는 밝은 오렌지색(중간값 부근)이 많이 분포하며, 시간 축에 따라 원본 대비 더 균일한 MFCC 특징값을 보이고, 전반적으로 단조로운 패턴이 다수 존재함을 확인할 수 있다.

도 11은 실제 음성과 딥보이스의 실제 음성(원본)과 딥보이스 각각의 MFCC(멜 주파수 켑스트럼 계수) 시퀀스 간의 DTW(Dynamic Time Warping) 거리 행렬

및 누적 거리를 나타낸 도면이다.

DTW는 두 시계열 데이터의 길이가 다르거나 시간 축 상에서 약간의 뒤틀림(warping)이 있더라도, 비선형적으로 시간 축을 정렬하여 두 시퀀스 간의 최적 경로(optimal path)를 찾고 그 유사도를 측정하는 알고리즘이다.

도 11을 참조하면, 도면의 행렬에서 진한 보라색 또는 파란색은 두 프레임 간의 매칭 비용(유클리드 거리)이 낮아 유사도가 높음을 의미하며, 노란색에 가까울수록 비용이 커져 차이가 크다는 것을 나타낸다.

도 12는 실제 음성과 딥보이스의 실제 음성과 딥보이스의 RMS(Root Mean Square) 에너지를 비교한 도면이다.

RMS 에너지는 오디오 신호의 짧은 구간(프레임) 내 진폭(amplitude)의 제곱 평균 제곱근으로, 해당 구간의 전반적인 소리 크기(loudness) 또는 강도를 나타낸다. RMS 에너지의 시간적 변화를 관찰하면 발화의 강약 변화, 즉 다이내믹 레인지(dynamic range)를 파악할 수 있다.

도 12를 참조하면, 실제 음성(원본)은 0.05 근처의 낮은 값부터 0.3에 근접하는 높은 값까지 넓은 범위에 걸쳐 에너지가 분포하며, 시간에 따라 부드럽고 자연스러운 변화를 보인다. 이는 모음(vowel) 구간에서 소리가 커지고 자음(consonant) 구간에서 작아지는 등 자연스러운 발화의 강약 조절이 잘 이루어지고 있음을 의미한다.

반면, 딥보이스는 원본보다 프레임 수가 훨씬 많게 나타나는데, 이는 합성 과정에서 프레임 추출 설정이 더 촘촘하게 이루어졌을 가능성을 시사한다. 더 중요

한 특징으로, 딥보이스의 RMS 에너지는 짧은 시간 안에 급격하게 상승하고 하강하는 뾰족한 피크(peak)들이 반복적으로 관찰된다. 이는 합성된 음성의 볼륨이 안정적이지 않고, 인위적인 노이즈나 클리핑(clipping)과 같은 왜곡이 발생했음을 시사한다.

도 13은 실제 음성과 딥보이스의 ZCR(Zero Crossing Rate)을 비교한 도면이다.

ZCR은 오디오 신호의 파형이 시간 축(0점)을 교차하는 비율을 측정한 값으로, 신호에 포함된 고주파 성분의 양을 간접적으로 나타내는 지표이다.

일반적으로 목소리의 진동으로 생성되는 유성음은 저주파수 대역에 에너지가 집중되어 ZCR이 낮게 나타나고, 공기의 마찰이나 파열로 생성되는 무성음은 고주파수 대역에 에너지가 많아 ZCR이 높게 나타난다.

도 13을 참조하면, 실제 음성(원본)은 ZCR이 대략 0.0에서 0.2 사이를 오르내리며, 파열음이나 마찰음과 같은 특정 무성음 구간에서 순간적으로 높아지는 자연스러운 패턴을 보인다. 그래프의 변동 폭이 불규칙하면서도 안정적인 범위 내에서 유지된다. 반면, 딥보이스는 특정 구간에서 ZCR이 짧은 간격으로 매우 높게 급상승하는 모습이 자주 관찰된다. 이는 유성음으로 발성되어야 할 구간에 불필요한 노이즈나 고주파 아티팩트가 포함되었거나, 유성음과 무성음 간의 전환이 부자연스럽게 처리되었음을 시사한다. 딥보이스의 ZCR에서는 특정 구간에서 0에 가깝게 머물거나 비정상적으로 급증하는 극단적인 분포를 확인할 수 있다.

도 14는 실제 음성과 딥보이스의 크로마그램을 비교한 도면이다.

Chroma는 12음계(반음)에 해당하는 12개의 피치 클래스(pitch class)로 사상(mapping)하여 표현하는 12차원의 특징 벡터이다.

도 14를 참조하면, 원본 음성(Original)은 짧은 시간(약 0-25초) 동안 다양한 색상 변화가 나타난다. 특정 반음대(예, C, D, E 등)에 에너지가 집중되지 않고, 여러 반음대에 걸쳐 에너지가 동적으로 분포하는 경향을 보인다.

이는 자연스러운 발화에서 나타나는 억양의 상승과 하강, 즉 F0의 변화가 풍부한 배음 구조의 변화로 이어져 크로마그램에 다채롭게 반영된 결과이다. 반면, 딥보이스(DeepVoice)는 상대적으로 긴 시간(약 1분 이상) 동안 색상 변화 패턴이 단조롭고 반복적이다. 특정 반음대(가로축의 특정 행)에서 짙은 빨간색(고에너지) 구간이 길게 유지되거나, 전반적으로 유사한 패턴이 지속되는 모습을 보인다.

도 15는 실제 음성과 딥보이스의 스펙트로그램을 비교한 도면이다.

스펙트로그램(Spectrogram)은 시간(가로축), 주파수(세로축), 에너지(색상 또는 명암)의 3차원 정보를 2차원 이미지로 시각화한 것이다.

도 15를 참조하면, 원본 음성(Original)의 스펙트로그램은 0-4kHz 대역에서 뚜렷하게 관찰된다. 또한, 3-4kHz 이상의 고주파 영역에서도 마찰음이나 파열음으로 인한 에너지 분포가 뚜렷하게 나타난다.

반면, 딥보이스(DeepVoice)의 스펙트로그램에서는 에너지가 주로 0-2kHz의 저주파 대역에 집중되는 패턴을 보인다.

도 16은 실제 음성과 딥보이스의 스펙트럼 대비를 비교한 도면이다.

스펙트럼 대비(Spectral Contrast)는 주파수 스펙트럼 내에서 국소적인 피크

(peak, 에너지가 높은 부분)와 밸리(valley, 에너지가 낮은 부분) 간의 에너지 차이를 측정하는 지표이다.

도 16을 참조하면, 원본 음성(Original)은 각 주파수 대역(세로축)에 걸쳐 밝은색(대비가 큼)과 어두운색(대비가 작음) 구간이 동적으로 교차하며 나타난다. 반면, 딥보이스(DeepVoice)의 그래프는 시간 축(가로축)을 따라 원본 대비 훨씬 균일하고 변화가 적은 패턴을 보인다. 특정 주파수 대역에서 지속적으로 어두운색(대비가 작음)이 나타나거나, 전반적으로 색 변화의 폭이 좁다.

도 17은 실제 음성과 딥보이스의 피치 컨투어를 비교한 도면이다. 피치 컨투어(Pitch Contour)는 시간에 따른 기본 주파수(Fundamental Frequency, F0)의 변화를 나타낸 그래프이다.

F0의 변화 패턴, 즉 피치 컨투어는 억양, 리듬, 감정 표현 등의 정보를 전달한다.

도 17을 참조하면, 원본 음성(Original)의 피치는 대략 100-250Hz 범위 내에서 시간에 따라 부드럽고 연속적으로 변동하는 모습을 보인다.

반면, 딥보이스에서는 피치가 변동 없이 거의 수평으로 유지되는 구간이 존재하고, 피치 값이 갑자기 비정상적으로 튀거나 끊어지는 불연속적인 지점이 다수 발견되며, 0-100Hz 부근의 매우 낮은 주파수 영역 구간이 주를 이룬다.

본 개시의 명세서(특히 특허청구범위에서)에서 "상기"의 용어 및 이와 유사한 지시 용어의 사용은 단수 및 복수 모두에 해당하는 것일 수 있다. 또한, 본 개

시에서 범위(range)를 기재한 경우 상기 범위에 속하는 개별적인 값을 적용한 발명을 포함하는 것으로서(이에 반하는 기재가 없다면), 발명의 상세한 설명에 상기 범위를 구성하는 각 개별적인 값을 기재한 것과 같다.

본 개시에 따른 방법을 구성하는 단계들에 대하여 명백하게 순서를 기재하거나 반하는 기재가 없다면, 상기 단계들은 적당한 순서로 행해질 수 있다. 반드시 상기 단계들의 기재 순서에 따라 본 개시가 한정되는 것은 아니다. 본 개시에서 모든 예들 또는 예시적인 용어(예들 들어, 등등)의 사용은 단순히 본 개시를 상세히 설명하기 위한 것으로서 특허청구범위에 의해 한정되지 않는 이상 상기 예들 또는 예시적인 용어로 인해 본 개시의 범위가 한정되는 것은 아니다. 또한, 통상의 기술자는 다양한 수정, 조합 및 변경이 부가된 특허청구범위 또는 그 균등물의 범주 내에서 설계 조건 및 인자(factor)에 따라 구성될 수 있음을 알 수 있다.

따라서, 본 개시의 사상은 상기 설명된 실시 예에 국한되어 정해져서는 아니되며, 후술하는 특허청구범위뿐만 아니라 이 특허청구범위와 균등한 또는 이로부터 등가적으로 변경된 모든 범위는 본 개시의 사상의 범주에 속한다고 할 것이다.

【부호의 설명】

100: 딥보이스 탐지 장치

110: 특징 벡터 생성부

120: 예측 확률 생성부

130: 딥보이스 판별부

【청구범위】

【청구항 1】

입력된 음성으로부터 하나 이상의 음향 특징을 추출하여 특징 벡터를 생성하는 특징 벡터 생성부;

상기 특징 벡터에 기초하여 RF(Random Forest) 예측 확률 및 DNN(Deep Neural Network) 예측 확률을 생성하는 예측 확률 생성부; 및

상기 RF 예측 확률과 상기 DNN 예측 확률의 산술 평균 값이 기 설정된 임계값 미만인 경우, 상기 음성을 딥보이스로 결정하는 딥보이스 판별부를 포함하는,

딥보이스 탐지 장치.

【청구항 2】

제1항에 있어서,

상기 특징 벡터 생성부는,

MFCC(Mel-Frequency Cepstral Coefficient), MFCC 델타(Delta), MFCC 델타-델타(Delta-Delta)에 대한 특징 중 적어도 하나를 추출하는 제1 추출부;

스펙트럼 대비(Spectral Contrast), 스펙트럼 중심(Spectral Centroid), 스펙트럼 롤오프(Spectral Rolloff), 스펙트럼 대역폭(Spectral Bandwidth), 스펙트럼 평탄도(Spectral Flatness)에 대한 특징 중 적어도 하나를 추출하는 제2 추출부;

크로마(Chroma), 톤네츠(Tonnetz), HNR(Harmonic-to-Percussive Ratio)에 대한 특징 중 적어도 하나를 추출하는 제3 추출부; 및

제로 크로싱율(Zero Crossing Rate), RMS 에너지 및 속도(Tempo)에 대한 특

징 중 적어도 하나를 추출하는 제4 추출부 중 적어도 하나를 포함하고,

상기 특징 벡터 생성부는,

상기 제1 추출부 내지 상기 제4 추출부로부터 추출되는 상기 하나 이상의 음향 특징에 기초하여 상기 특징 벡터를 생성하는,

딥보이스 탐지 장치.

【청구항 3】

입력된 음성으로부터 하나 이상의 음향 특징을 추출하여 특징 벡터를 생성하는 사용자 단말기; 및

상기 사용자 단말기로부터 상기 특징 벡터를 수집하고, 복수의 딥보이스 판별 모델을 이용하여 상기 특징 벡터에 대해 딥보이스 여부를 판별하는 서버를 포함하는,

딥보이스 탐지 시스템.

【청구항 4】

제3항에 있어서,

상기 서버는,

상기 사용자 단말기로부터 수집된 사용자 음성의 특징 벡터를 제1 클래스로, 상기 사용자 음성에 상응하여 생성된 딥보이스 음성의 특징 벡터를 제2 클래스로 포함하는 데이터셋을 생성하고,

상기 복수의 딥보이스 판별 모델은,

상기 데이터셋을 학습 데이터로 하는,

딥보이스 탐지 시스템.

【청구항 5】

제4항에 있어서,

상기 서버는,

상기 사용자 단말기의 사용자 음성으로부터 추출된 특징 벡터에 기초하여 상기 데이터셋을 생성하고, 상기 사용자 단말기에서 통화 중 수신되는 음성으로부터 추출된 특징 벡터에 기초하여 상기 딥보이스 여부를 판별하는,

딥보이스 탐지 시스템.

【요약서】

【요약】

본 발명은 딥보이스 탐지 장치 및 방법에 관한 것이다.

본 발명에 따른 딥보이스 탐지 장치는, 입력된 음성으로부터 하나 이상의 음향 특징을 추출하여 특징 벡터를 생성하는 특징 벡터 생성부; 상기 특징 벡터에 기초하여 RF(Random Forest) 예측 확률 및 DNN(Deep Neural Network) 예측 확률을 생성하는 예측 확률 생성부; 및 상기 RF 예측 확률과 상기 DNN 예측 확률의 산술 평균 값이 기 설정된 임계값 미만인 경우, 상기 음성을 딥보이스로 결정하는 딥보이스 판별부를 포함한다.

【대표도】

도 1

【도면】

【도 1】

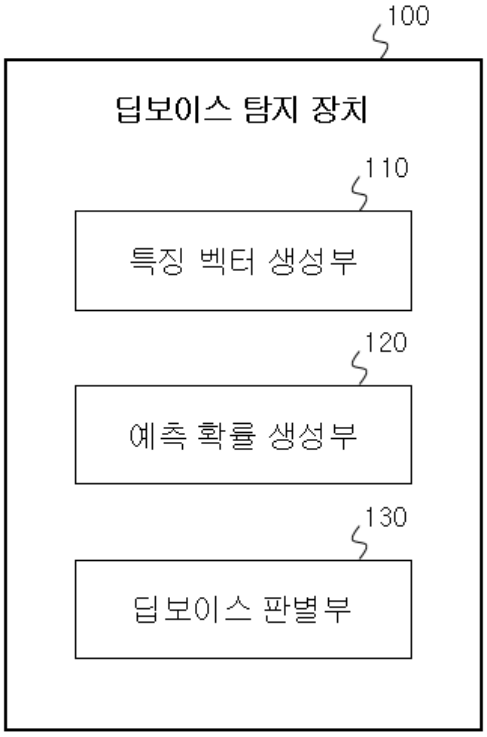

【도 2】

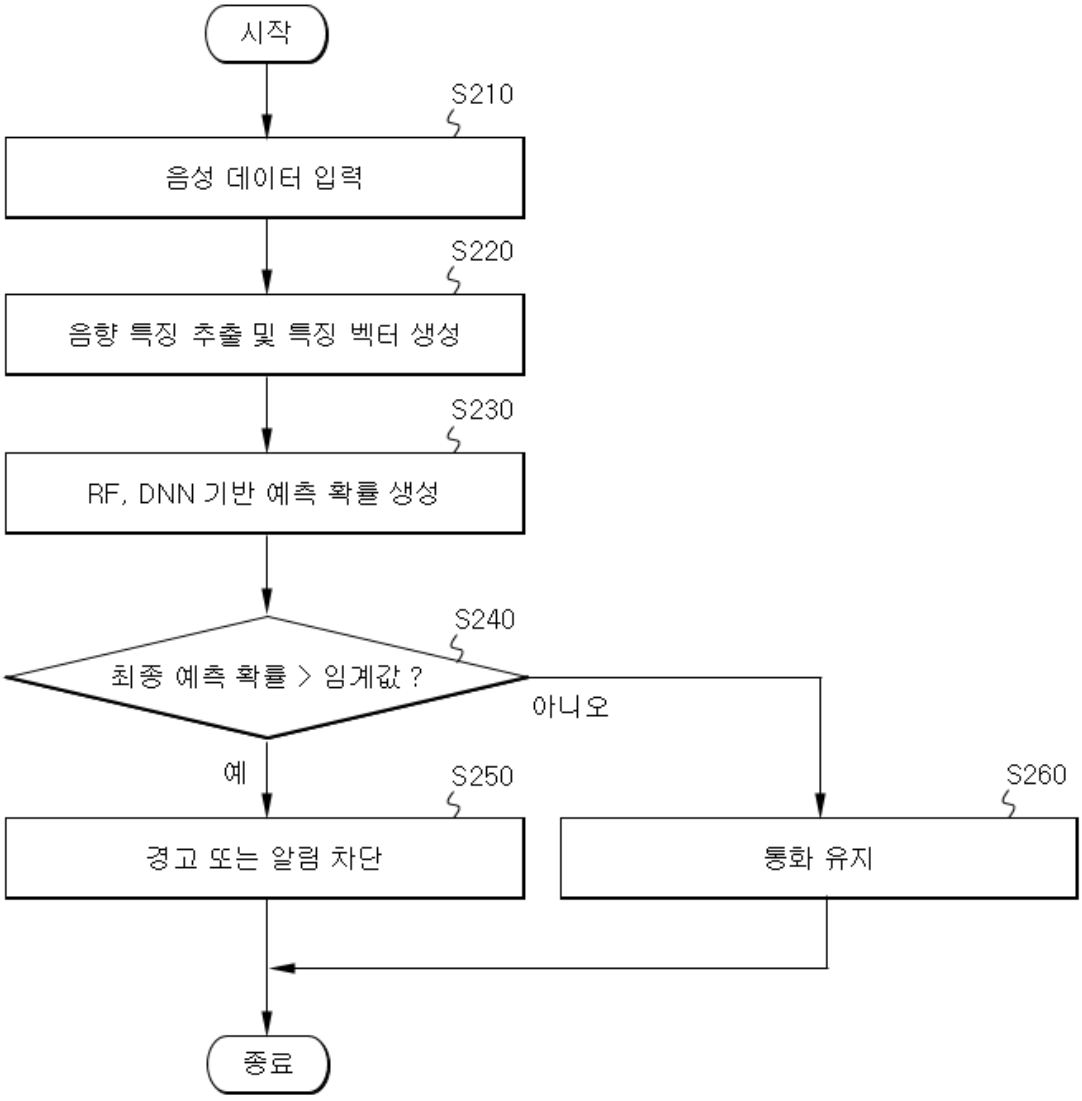
시작
S210
음성 데이터 입력
S220
음향 특징 추출 및 특징 벡터 생성
S230
RF, DNN 기반 예측 확률 생성
S240
최종 예측 확률 > 임계값 ?
아니오
예
S250
경고 또는 알림 차단
S260
통화 유지
종료

【도 3】

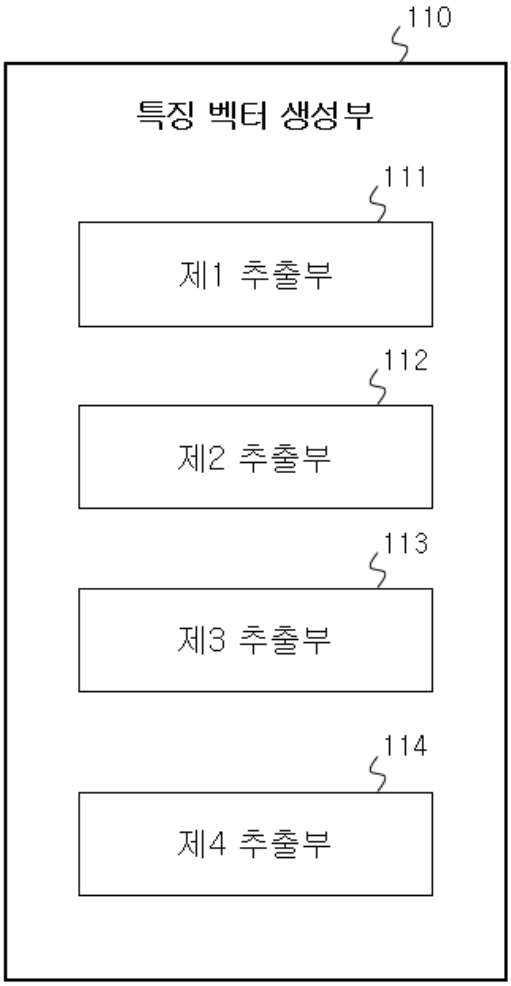

【도 4】

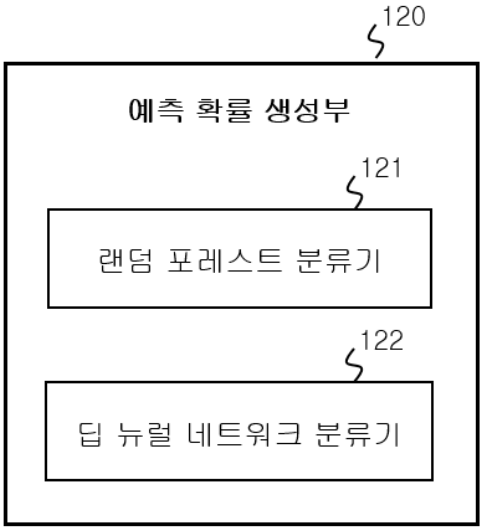

【도 5】

n_estimators	100
random_state	42

【도 6】

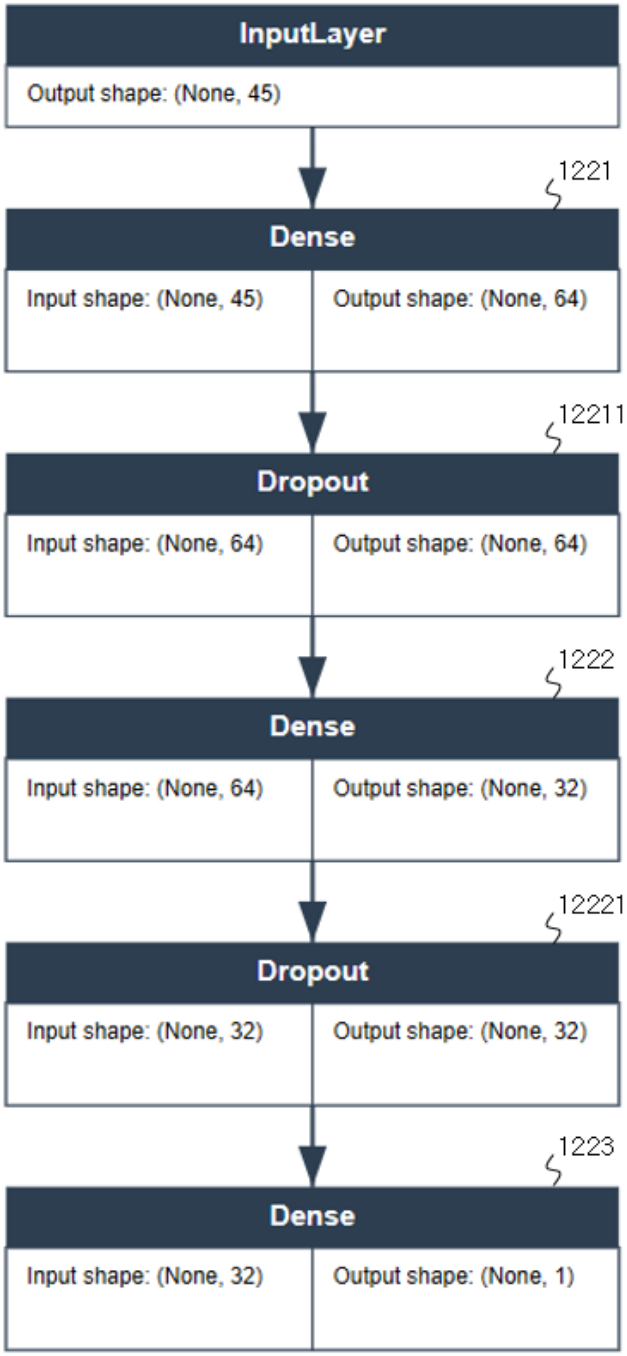
InputLayer
Output shape: (None, 45)
1221
Dense
Input shape: (None, 45)
Output shape: (None, 64)
12211
Dropout
Input shape: (None, 64)
Output shape: (None, 64)
1222
Dense
Input shape: (None, 64)
Output shape: (None, 32)
12221
Dropout
Input shape: (None, 32)
Output shape: (None, 32)
1223
Dense
Input shape: (None, 32)
Output shape: (None, 1)

【도 7】

하이퍼변수	값
Optimizer	Adam
Learning Rate	0.001
Loss Function	binary_crossentropy
Epochs	150
Batch Size	8
Callbacks	EarlyStopping(patience=10)

【도 8】

평가 지표	값
총 평가 샘플 수	992 개
정탐	980 개
오탐	12 개
정확도	98.8%
오탐률	1.2%

【도 9】

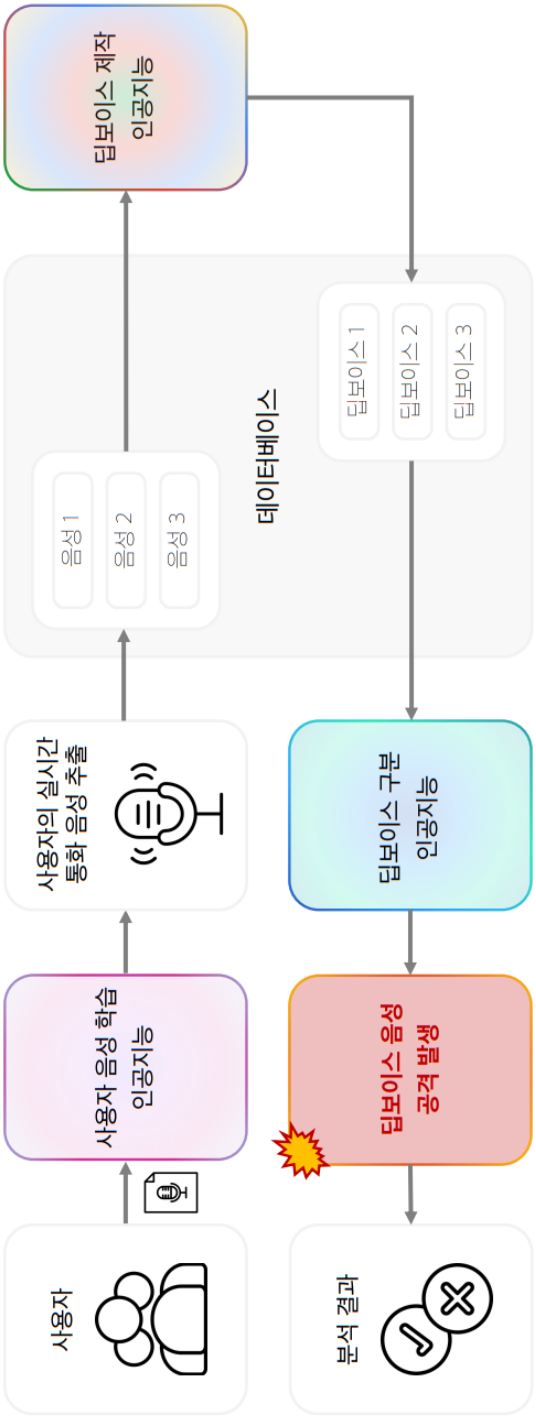
사용자
사용자 음성 학습
인공지능
사용자의 실시간
통화 음성 추출
음성 1
음성 2
음성 3
데이터베이스
딥보이스 1
딥보이스 2
딥보이스 3
딥보이스 제작
인공지능
딥보이스 구분
인공지능
딥보이스 음성
공격 발생
분석 결과

【도 10】

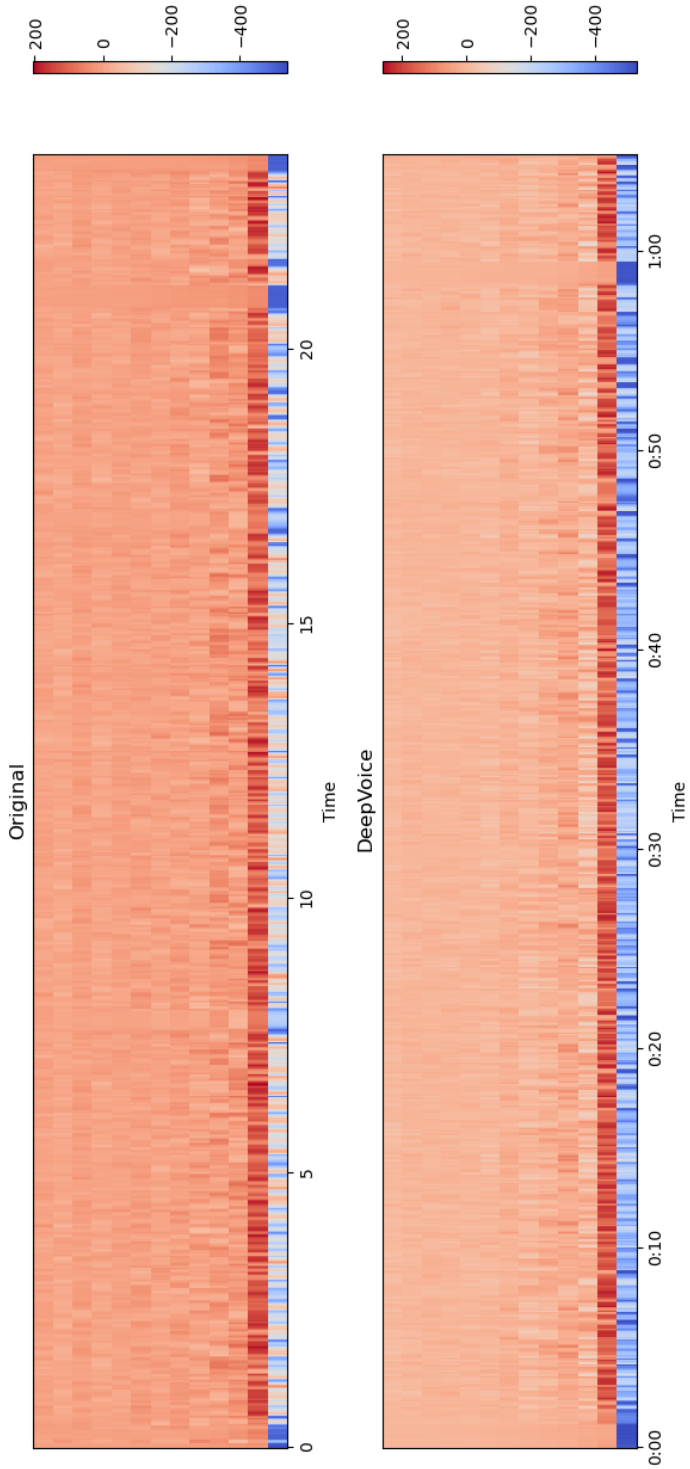
Original
Time
0
5
10
15
20
200
0
−200
−400
DeepVoice
Time
0:00
0:10
0:20
0:30
0:40
0:50
1:00
200
0
−200
−400

【도 11】

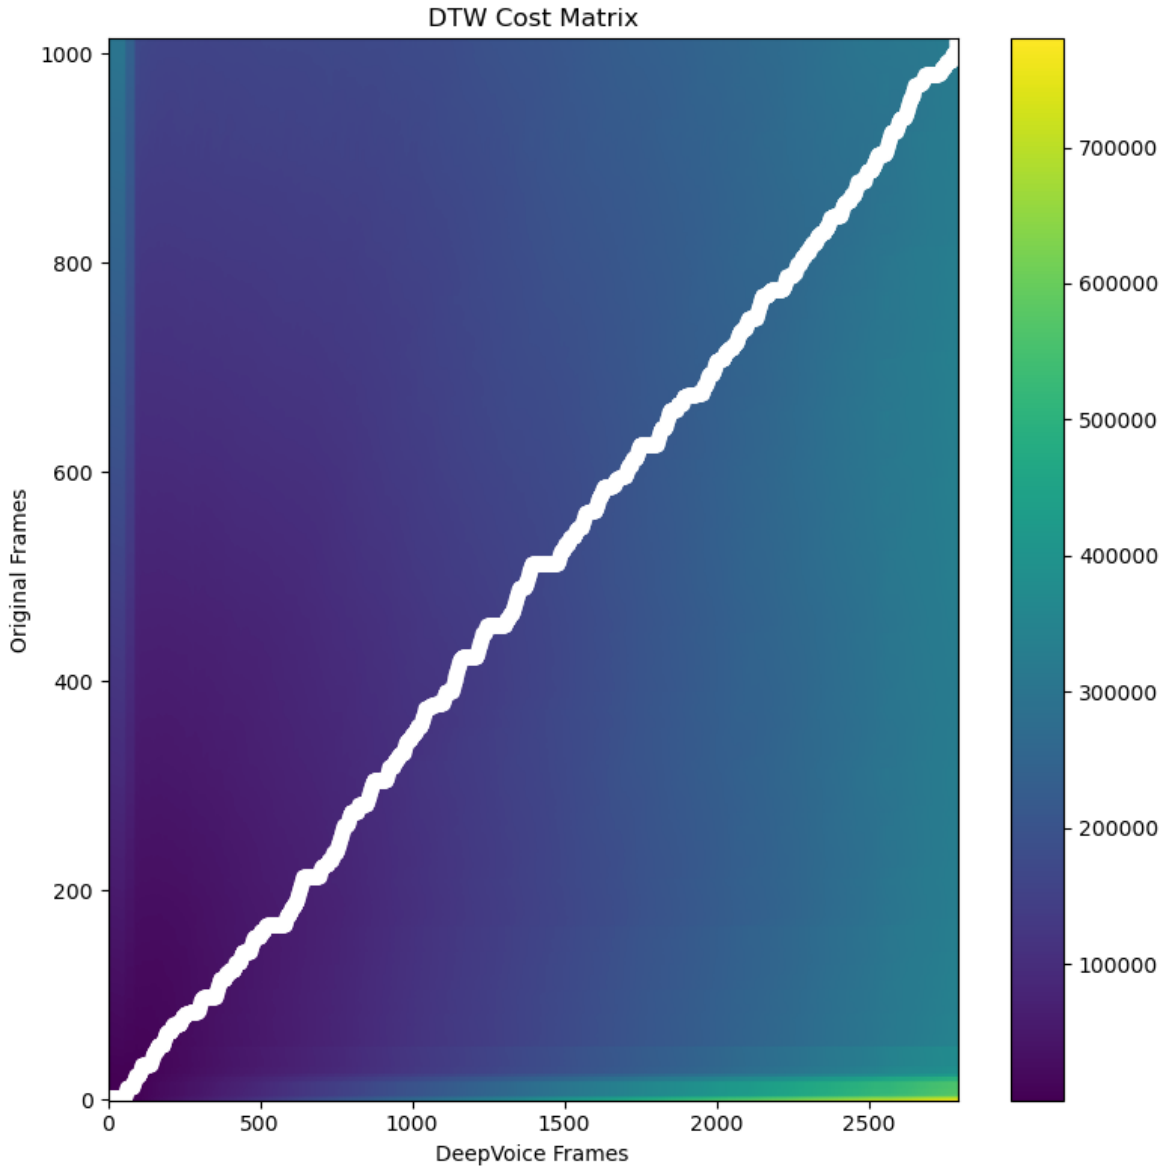
DTW Cost Matrix
Original Frames
DeepVoice Frames
0
200
400
600
800
1000
0
500
1000
1500
2000
2500
100000
200000
300000
400000
500000
600000
700000

【도 12】

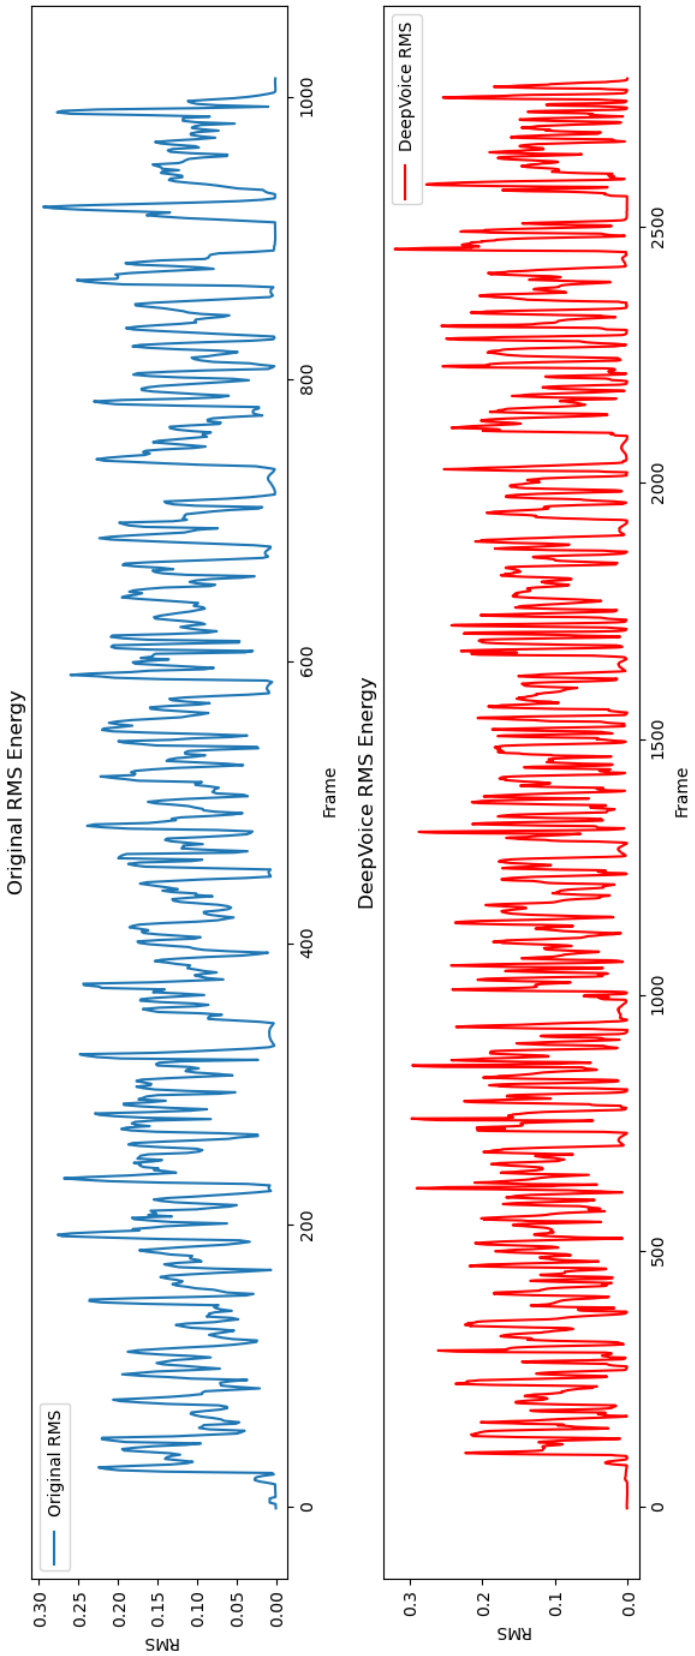
Original RMS Energy
Original RMS
RMS
0.30
0.25
0.20
0.15
0.10
0.05
0.00
0
200
400
600
800
1000
Frame
DeepVoice RMS Energy
DeepVoice RMS
RMS
0.3
0.2
0.1
0.0
0
500
1000
1500
2000
2500
Frame

【도 13】

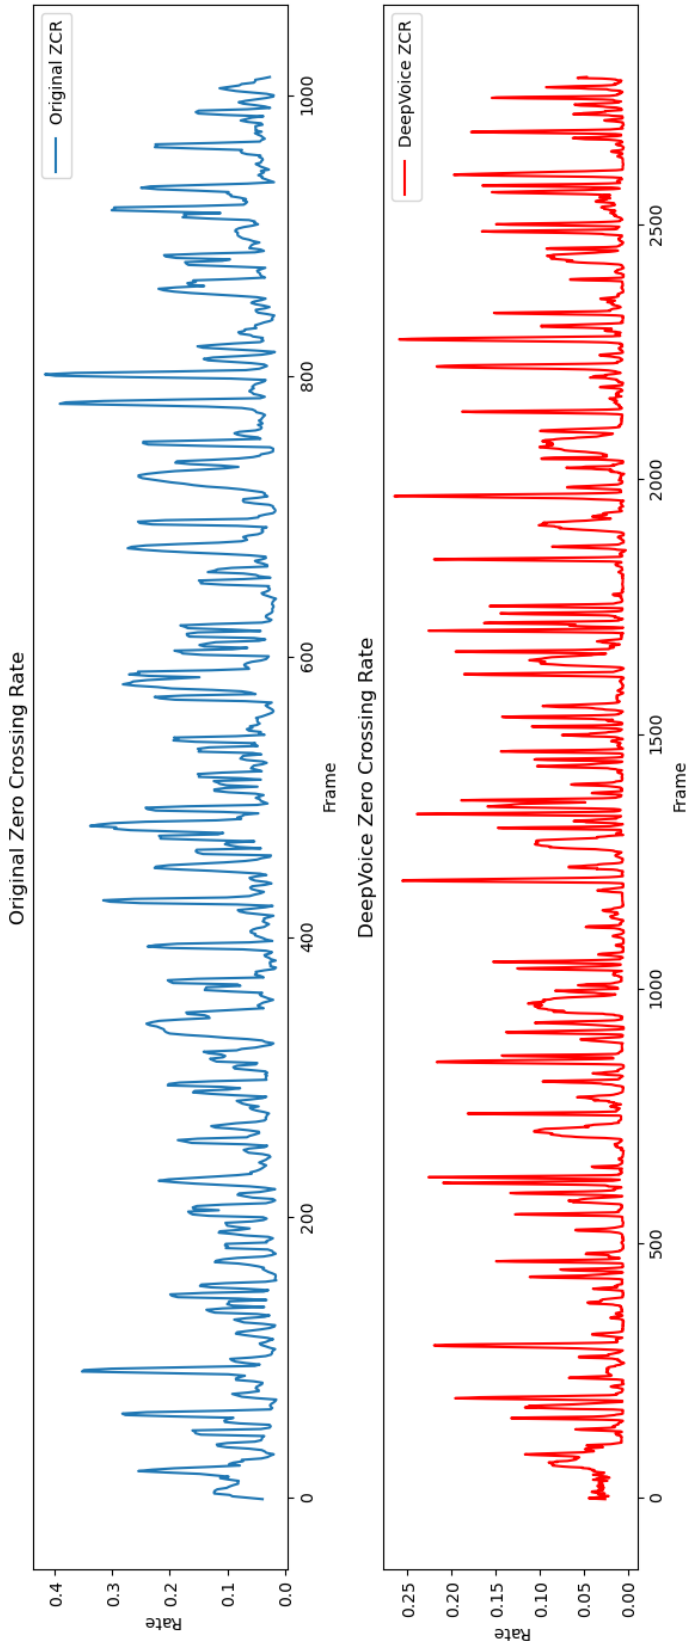
Original Zero Crossing Rate
Original ZCR
Rate
Frame
0.0
0.1
0.2
0.3
0.4
0
200
400
600
800
1000
DeepVoice Zero Crossing Rate
DeepVoice ZCR
Rate
Frame
0.00
0.05
0.10
0.15
0.20
0.25
0
500
1000
1500
2000
2500

【도 14】

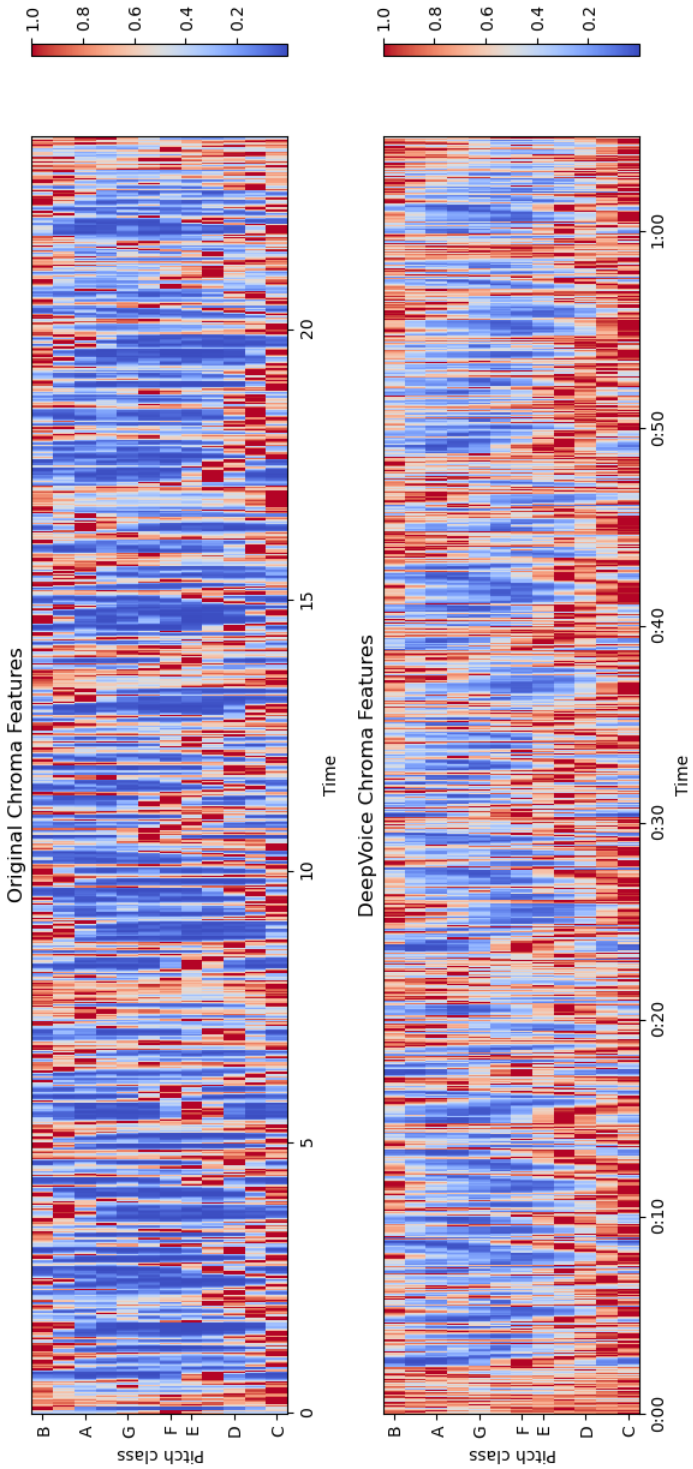
Original Chroma Features
Pitch class
B
A
G
F
E
D
C
0
5
10
15
20
Time
1.0
0.8
0.6
0.4
0.2
DeepVoice Chroma Features
Pitch class
B
A
G
F
E
D
C
0:00
0:10
0:20
0:30
0:40
0:50
1:00
Time
1.0
0.8
0.6
0.4
0.2

【도 15】

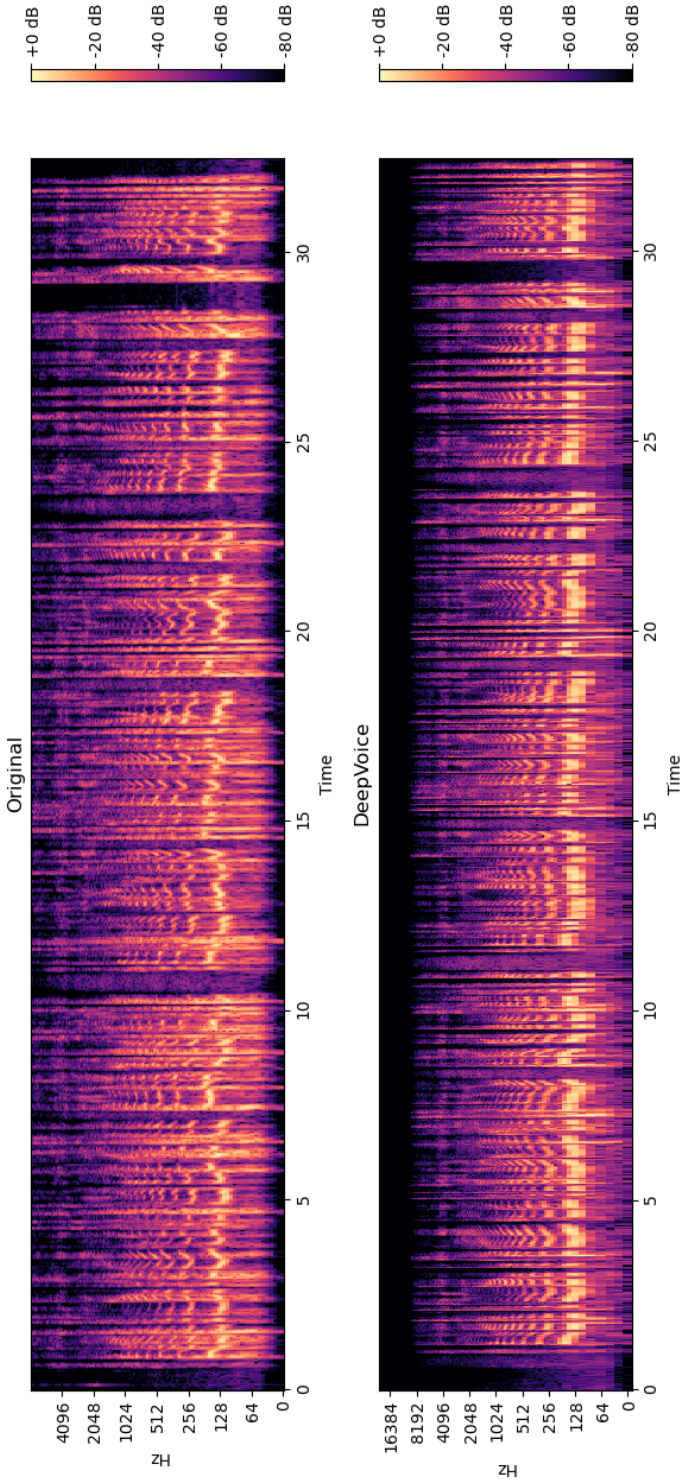
Original
DeepVoice
Hz
Time
+0 dB
-20 dB
-40 dB
-60 dB
-80 dB
16384
8192
4096
2048
1024
512
256
128
64
0
5
10
15
20
25
30

【도 16】

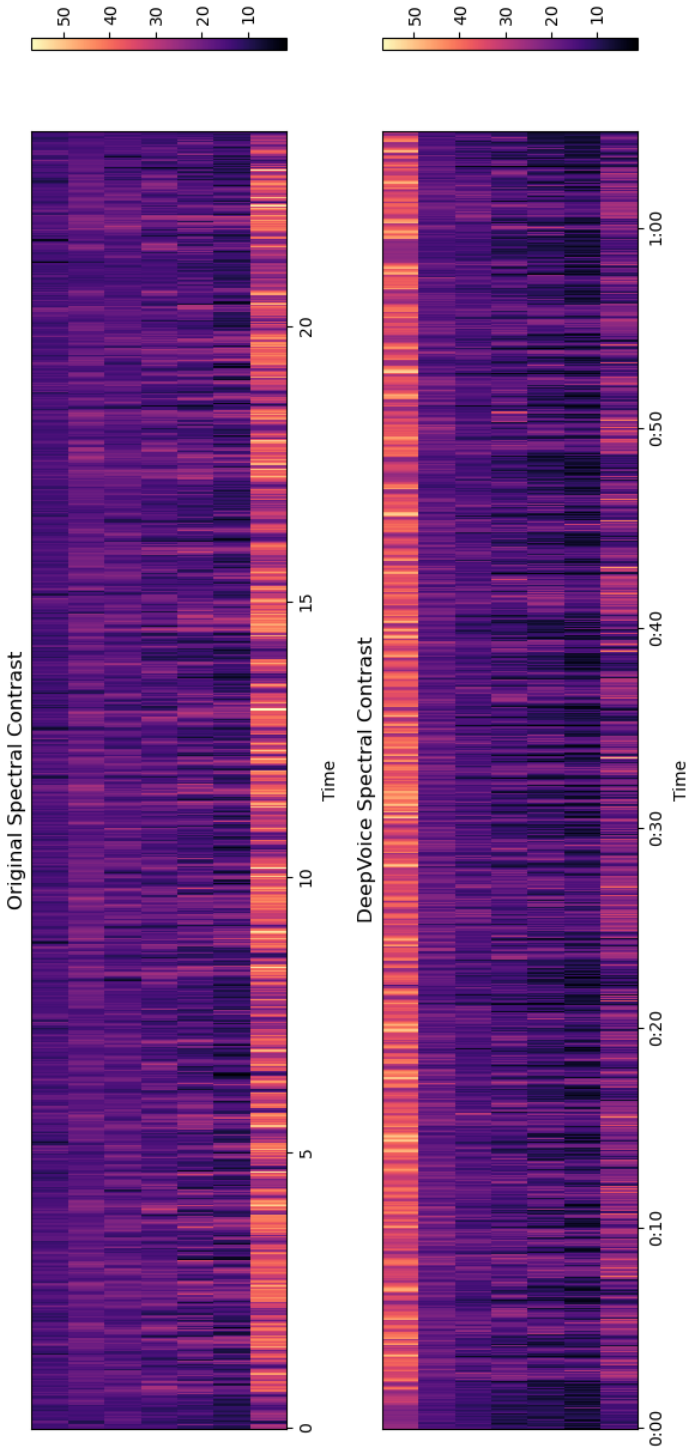
Original Spectral Contrast
50
40
30
20
10
0
5
10
15
20
Time
DeepVoice Spectral Contrast
50
40
30
20
10
0:00
0:10
0:20
0:30
0:40
0:50
1:00
Time

【도 17】

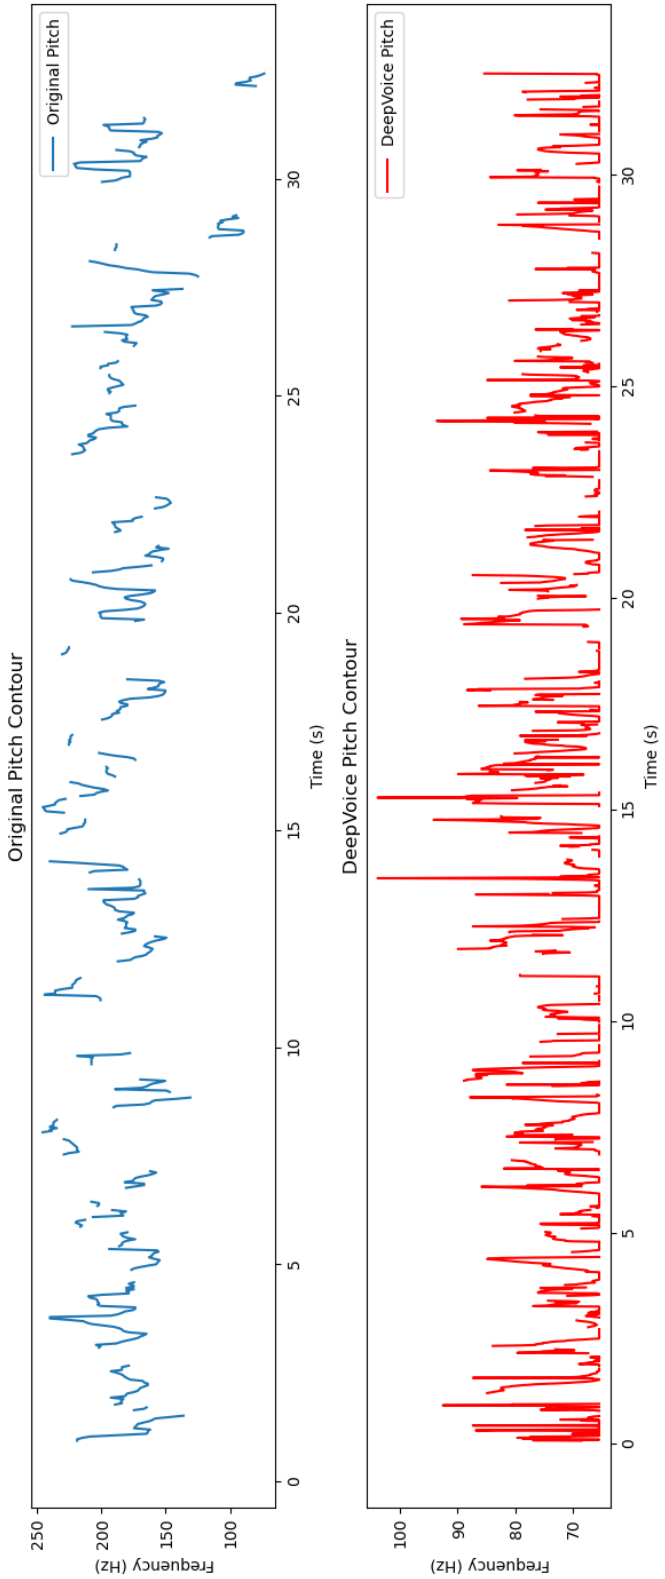
Original Pitch Contour
Original Pitch
Frequency (Hz)
250
200
150
100
0
5
10
15
20
25
30
Time (s)
DeepVoice Pitch Contour
DeepVoice Pitch
Frequency (Hz)
100
90
80
70
0
5
10
15
20
25
30
Time (s)