XGBoost를 이용한 불법 · 유해 사이트 차단 시스템 연구

정진호[1], 박우경[1], 최수민[1*], 홍준희[1], 김평안[1], 김민수[2]
중부대학교 정보보호학전공 학부생[1], 중부대학교 정보보호학전공 교수[2]

Research on illegal and harmful site blocking systems using XGBoost

Jin-Ho Jung[1], Woo-Kyung Park[1], Su-Min Choi[1*], Jun-Hee Hong[1], Pyeong-An Kim[1], Min-Su Kim[2]

요약 : 대한민국 한류 콘텐츠의 급증하는 인기와 함께 저작권 문제 및 불법 복제가 증가하고 있으며, 기존의 차단 시스템으로는 근본적인 해결이 어렵다는 문제가 대두되었다. 본 논문에서는 이러한 한계를 극복하기 위해 인공지능 기반의 불법 유해 사이트 차단 방안을 제안한다. 제시된 방법은 웹 크롤링과 데이터 전처리, XGBoost 알고리즘을 활용해 불법 유해 사이트를 효과적으로 차단하는 모델, HitAnt를 개발했다. 특히 HitAnt는 기존 차단 프로그램에 비해 현저히 높은 차단율을 보임으로써 그 우수성을 확인했다. 이 연구는 불법 유해 사이트 차단 분야에 있어 중요한 진전을 보여주며, 보다 안전한 인터넷 환경 조성에 기여할 것으로 기대된다.

Key Words : XGBoost, Blocked, Web crawling, HTML

1. 서 론

나날이 증가하고 있는 대한민국 한류 열풍 속에 드라마, 영화, 웹툰 등의 다양한 K-콘텐츠가 국내뿐만 아니라 세계 각국으로 급속히 전파되고 있다. 하지만, 한류의 인기가 급증할수록 콘텐츠에 대한 저작권 침해도 증가하고 있다. 2023년 저작권 보호 연차 보고서 자료[1]에 의하면 2019년 이후 OTT(Over The Top)에서 제공되는 스트리밍, 웹툰, 게임 등의 서비스가 불법 유해 사이트 등 다양한 경로를 통해 유통되고 있다.

이에 정부는 불법 유통에 대한 피해를 줄이기 위해 서버 IP 및 DNS 차단, 보안 프로그램 설치 운영 등 다양한 방식으로 불법 유해 사이트를 차단하고 있다[2]. 그러나 탐지된 유해 사이트 정보의 한에서만 차단이 이루어지는 한계가 있어, 실질적인 차단의 한계를 보인다[3].

따라서, 본 연구는 저작권 보호를 위한 차단 프로그램의 한계를 보완하기 위해 인공지능 기반의 불법 유해 사이트 탐지 및 차단 시스템을 제안한다.

2. 관련 연구

2.1. 웹 크롤링

웹 크롤링이란 인터넷상의 웹 페이지를 자동으로 탐색하고 정보를 수집하는 기술이다. 특히, 불법 유해 사이트의 식별과 차단에 있어 이 기술은 중요한 역할을 수행한다[4].

BeautifulSoup, Scrapy 등 파이썬 라이브러리를 활용한 웹 크롤러 기술은 주어진 URL을 시작으로 웹 페이지의 링크를 따라가며, HTML 문서를 수집 후 필요한 정보를 추출하고, 새로운 링크를 발견하면 이를 다시 탐색하는 과정을 반복한다[4].

웹 크롤링 기술을 이용해 불법 유해 사이트를 식별 및 차단하기 위해서는, Meta Tag, Title, 외부 링크 등 다양한 요소를 종합적으로 분석해야 한다[4].

2.2. HTML Meta Tag

Meta Tag는 서버와 인터넷 간의 통신에서 주고받는 정보를 정의하며 태그의 헤드(Head) 안에 keywords, description, content 등의 정보가 존재한다. 해당 데이터는 웹 페이지에 표시되지 않고, 시스템에서 구문 분석에 도움이 되어 검색 엔진 및 페이지 탐색 시 연관 자료로 사용된다[5].

```
1 <meta name="description" content="뉴토끼 - 웹툰 미리보기 각종 웹툰
    미리보기 No.1 뉴토끼, 뉴토끼에서 최신 정보를 받아보세요!">
2 <meta name="keywords" content="뉴토끼, 웹툰미리보기, 웹툰미리보기사이트,
    네이버웹툰미리보기, 다음웹툰, 네이버웹툰, 밤토끼, 밤토키, 툰코, 호두코믹스,
    무료웹툰, 유료웹툰, 웹툰사이트, 웹툰, 성인웹툰, 무료만화, 유료만화, 만화,
    포토툰, 만화미리보기, 레진코믹스, 짬툰, 탑툰, 썰만화, 썰툰, 뉴토끼 - 웹툰
    미리보기">
```

Fig 1. Meta Tag element inside HTML head

Fig 1.과 같이 keywords 요소는 해당 단어들로 불법 유해 사이트의 검색 노출 빈도를 향상 시키고, description 요소는 검색 결과로 보이는 값을 담은 데이터이다. 즉, 이 요소들은 불법 유해 사이트의 노출을 늘리도록 도와주는 매개체이다[5].

HTML 문서에서 웹 크롤링을 통해 수집한 정보를 머신러닝에 바로 넣을 수 없기 때문에 데이터 전처리(Preprocessing) 과정이 필요하다. 데이터 전처리 과정에는 정제, 결측치 처리, 특징 추출, 불균형 처리 등 여러 단계를 거쳐, 데이터 분석 및 처리 과정에 필요한 자료로 변환하는 단계이다[6]. 이 단계를 거쳐 만들어진 데이터를 머신러닝을 제작하는 데 이용된다.

2.3. 학습 알고리즘

머신러닝 알고리즘에는 랜덤 포레스트(RF), XGBoost 등 다양한 방법이 존재하지만, 학습시킬 자

료와 데이터 전처리 과정, 높은 정확도로 원하는 결과값을 도출해 낼 수 있는 알고리즘을 선택하는 것이 중요하다[6].

랜덤 포레스트 알고리즘은 다양한 의사결정 트리를 만들어 내고, 각각의 예측을 종합해 최종 값을 도출해 내는 알고리즘이다. 각 트리를 구성할 때, 일부 특징을 무작위로 선택하여 트리를 만들고, 회귀 작업을 통해 각 트리의 예측 값을 평균낸다. 그리고 분류 작업을 통해 가장 많은 트리의 예측된 결과를 이용한다[6].

XGBoost 알고리즘은 수치가 낮은 의사결정 트리를 순차적으로 학습해 최종 예측 모델을 도출해 내는 알고리즘이다. 즉, 이전 트리의 예측 오차를 보완해 최종 모델의 정확도를 향상시키는 과정으로 진행된다. 이 과정에서 모델의 복잡성과 과적합을 줄여나가 일반화된 예측 결과를 향상시킨다[6].

3. 제안하는 방법

본 연구에서는 방송통신위원회의 법률 시행령[7]에 규정된 음란물, 도박, 불법 스트리밍 및 웹툰으로 4가지 카테고리를 선정하고, 학습에 필요한 데이터로 불법 유해 사이트 1,500개와 비유해 사이트 1,500개를 수집 및 적용했다.

그리고 카테고리 별 차단율을 높이는데 적합한 알고리즘으로 학습 과정에서 모델의 복잡성과 과적합을 줄여 이전 트리의 예측 오차를 보완해 최종 모델의 정확도가 가장 높았던 XGBoost 알고리즘을 선택하여 최종 모델(HitAnt)을 생성했다.

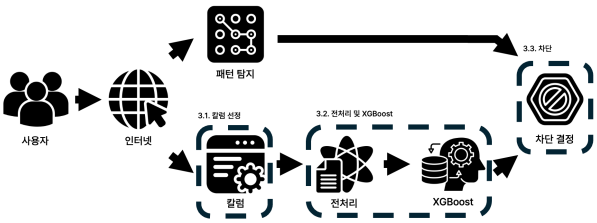

Fig 2. Process of blocking illegal and harmful sites

3.1. 칼럼 선정

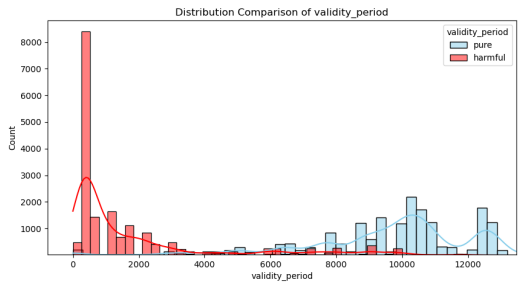

Fig 3. Distribution Comparison of validity period

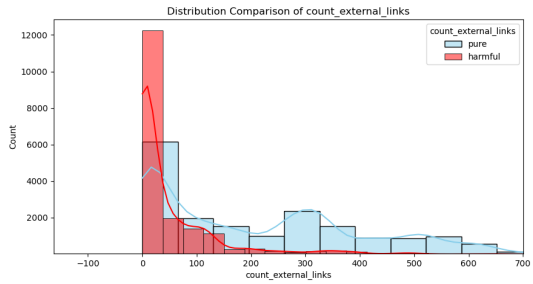

Fig 4. Distribution Comparison of count external links

칼럼 선정 과정은 불법 유해 사이트 오탐율 및 차단율에 영향을 미치는 중요한 요소로, 불법 유해 사이트와 비유해 사이트를 구분하고 효과적인 차단율에 기여한다. 따라서 본 연구에서는 도메인 생성 기간, 리다이렉션 수 등 총 20개의 칼럼을 지정하여 유해/비유해 사이트 데이터 셋 구축에 활용하였다.

Fig 3.의 도메인 생성 기간과 Fig 4.의 외부 링크 수 칼럼 분석 결과를 통해, 불법 유해 사이트와 비유해 사이트 간의 데이터가 명확하게 구별되는 것을 확인할 수 있으며, 이는 칼럼 선정 과정이 유해 사이트 판별에 있어 중요한 기준이 된다.

3.2. 전처리 및 XGBoost

앞서 정한 칼럼 속 정보들은 숫자형(Int)의 자료와 문자형(String)의 자료로 구성되어 있다. 이 데이터는 머신러닝이 바로 학습에 이용할 수 없어, 숫자형으로 변환하는 데이터 전처리 과정이 필요하다.

기존 숫자형 자료의 칼럼은 numeric 방식으로, Meta, a, Title과 같은 문자형 자료의 칼럼은 TF-IDF 벡터화 방식 등 데이터 전처리 단계를 통해 머신러닝이 학습 가능한 자료로 변환해준다.

변환을 마친 데이터 셋을 가지고 20개의 칼럼을 하나로 묶어 X 값으로, 차단 여부를 y 값으로 지정해 준 뒤 XGBoost 알고리즘을 이용해 94% 정확도인 머신러닝 모델, HitAnt를 최종적으로 생성했다.

3.3. 차단

사이트의 유해성 판단 과정은 접속하고자 하는 도메인을 웹 크롤링하여 20개의 칼럼 자료를 수집하고, 데이터 전처리한 결과를 HitAnt 머신러닝이 가중치를 두고 비교 분석 단계를 거친다.

지정된 값에 따라 해당 도메인이 유해하면 차단 페이지로 리다이렉션 시켜 사용자들의 불법 유해 사이트 접속을 방지한다.

4. 검증

국내/외 불법 유해 사이트 20,000개의 데이터 셋을 통해 비교 검증 단계를 실시하였다. 기존 차단 프로그램과 제안한 HitAnt 시스템을 비교 검증한 결과, Table 1.과 같이 현재 공개된 유해 사이트 차단 프로그램들은 전반적으로 50% 미만의 차단율에 비해, 제안한

HitAnt는 98.7%의 높은 차단율을 보였다.

차단 프로그램	차단율(%)	차단 프로그램	차단율(%)
PC 보안케어	12.1	사이버가디언	20.3
K9 Web Protection	47.4	아이눈	8.1
i 안심	5.5	기본	2.9
맘아이	33.7	HitAnt	**98.7**
X 키퍼	37.4		

Table 1. Blocking rate of illegal and harmful sites

5. 결론

기존 불법·유해 사이트 차단 프로그램들은 시그니처 기반의 수동적 입력 방식으로 기술적 한계의 단점을 보완하기 위하여, 본 연구에서는 XGBoost 머신러닝 알고리즘을 이용한 능동적 차단 시스템을 제안하였다.

검증 결과, 제안한 HitAnt는 98.7%의 차단율을 기록하여 실용성이 뛰어남을 확인할 수 있었다.

향후 생성될 불법·유해 사이트와 관련한 다양한 칼럼과 데이터 셋에 대하여 지속적 수집 및 학습을 통해 제안한 시스템의 차단율을 높일 수 있을 것으로 기대한다.

참고문헌

[1] Korean Copyright Commission, “2023 Copyright Protection Annual Report”, 2023.

[2] Jung-Su Han, “https://www.ttimes.co.kr/article/2019021518277767308”, 2019.02.15.

[3] Na-Hee Lee, “https://www.polinews.co.kr/news/articleView.html?idxno=348316”, 2018.02.28.

[4] Seung-Yong Choo, Ye-Seong Hwang, Sang-Jin Lee, “Methods for Collecting Harmful Websites Using Web Crawling”, Journal of Digital Forensics, Vol.15, No.3, pp.127-138, 2021.

[5] Jun-Young Jang, “An Harmful site collection system using Characteristic of HTML and URL”, Journal of Digital Forensics, Vol.16, No.1, pp.55-57, 2022.06.10.

[6] Sung-Min Jang, Jun-Hak Kim, Hee-Jung Kwon, Eun-Hee Oh, Chang-Min Seo, “Development of Malicious Code Detection System Using RandomForest and XGBoost”, The 54th KIEE Summer Conference 2023, pp.2465-2466, 2023.07.12.

[7] Korea Communications Commission, “https://kcc.go.kr/user.do?boardId=1113&page=A05030000&%3Cspan%20class=%27keyword%27%3EDC%3C/span%3E=K00000001&boardSeq=46840&mode=view”, 2019.02.14.