딥보이스로 제작된 음성 탐지 시스템 연구

정진호[1], 박우경[1], 이하영[1], 최수민[1]*, 홍준희[1], 김민수[2]
중부대학교 정보보호학전공 학부생[1], 중부대학교 정보보호학전공 교수[2]

Researching speech detection systems made with DeepVoice

Jin Ho Jung[1], Woo Kyung Park[1], Ha Young Lee[1], Su Min Choi[1]*, Jun Hee Hong[1], Min Su Kim[2]

요약 : 인공지능 기술이 급속하게 발전하면서 디지털 미디어의 신뢰성을 저하시키는 딥페이크(DeepFake) 기술을 통해, 다양한 유형의 공격 기법이 늘어나고 있다. 본 논문에서는 음성과 관련된 딥페이크 유형을 중점으로 DeepVoice를 탐지하는 시스템을 제안한다. 머신러닝(RF)과 딥러닝(DNN)을 결합하여, 실제 음성과 딥보이스 간 특징을 효과적으로 학습시켜 모델 정확도를 향상시켰다. 이를 기반으로 딥페이크와 관련된 사이버 보안 피해로부터 안전한 환경을 조성하는 데 도움을 제공할 수 있을 것이라고 기대한다.

Key Words : DeepVoice, DeepFake, Machine Learning(ML), RandomForest, Deep Learning(DL), DNN

1. 서 론

오늘날 인공지능 기술이 발전하면서 디지털 미디어의 신뢰성을 위협하는 딥페이크(DeepFake) 기술이 부상하고 있다. 딥페이크를 활용하여 실제와 구분하기 어려운 조작된 동영상, 오디오, 이미지 등 다양한 딥페이크 유형이 존재한다[1].

공격자는 딥페이크로 제작한 딥보이스를 이용하여 금융 기관 및 수사 기관과 같은 국가 기관을 사칭해 조직적으로 범죄를 진행하고, 성별, 연령에 관계 없이 금융 피해가 지속적으로 증가하고 있다[2].

본 연구에서는 오디오와 관련된 딥페이크 유형을 중점으로 발생하는 보이스피싱 범죄 피해[2] 예방에 도움을 제공하고자, 머신러닝(ML) 및 딥러닝(DL)을 활용하여 딥보이스로 제작된 음성 탐지 시스템을 제안하고자 한다.

2. 관련 연구

2.1. DeepFake

딥페이크는 인공지능 기술을 활용해 사진, 영상, 음성 등의 디지털 콘텐츠를 조작 및 합성하는 기술로, 이를 활용해 제작된 결과물은 일반 사용자들이 차이점을 구분하기 어려워한다[2].

딥페이크의 생성 과정은 데이터를 수집하고 데이터 전처리 과정을 수행하여 GAN, Autoencoder 등의 딥러닝 모델을 이용해 새로운 결과물을 만들어낸다[2].

최근 딥페이크를 이용해 얼굴 부분만 다른 사람으로 조작하여 사회·정치적으로 문제를 일으키거나, 음성을 조작하여 보이스피싱과 같은 사이버 보안 문제가 빈번하게 발생한다[1].

2.2. 음성 합성 기술

여러 가지 딥페이크 유형 중, 음성과 관련된 유형에서 사용되는 음성 합성 기술의 기본 원리는 음성 자동 변환(TTS, Text To Speech) 기술이다. 과거에는 제한적인 단어와 문장으로 규칙과 연결에 있어 한계가 존재했지만, 최근에는 딥러닝 기술과 결합하여 사람의 목소리를 학습해 음성의 높낮이, 발음 등을 고려하여 습득하는 방식으로 변하고 있다[2].

2.3. 학습 알고리즘

실제 보이스와 딥보이스 간의 뚜렷한 피처를 선정할수록 모델의 정확도를 향상시킬 수 있다. 본 연구에서는 머신러닝과 딥러닝을 융합하여 모델 학습에 이용하고, RandomForest와 DNN을 이용하여 음성 데이터를 학습한다.

직접 피처를 선정하여 모델을 생성하는 과정에는 머신러닝이 적합하고, 음성의 크기가 크고 복잡한 형태의 파일을 학습하기에는 딥러닝이 적합하여 두 알고리즘을 이용해 모델을 학습시켜야 한다[3]. 정적으로 선정된 피처 데이터는 DNN의 앙상블 학습 과정에 효율적인 결과를 나타낸다[3].

3. 제안하는 방법

Fig 1. DeepVoice Speech Detection Flow Chart

Fig 1.의 Flow Chart는 실제 보이스 데이터셋과 딥보이스 데이터셋을 가지고 지도 학습을 통해 제작된 모델로 음성 파일의 딥보이스 유무를 선정한다.

본 연구에서는 Fig 1.을 기반으로 기초 데이터셋 5초 분량의 음성 파일 약 700개 이용하여 분석 모델을 제작하고, 해당 모델을 통해 딥보이스 음성 파일 유무를 판단해주는 로직을 제안하고자 한다.

3.1. 피처 선정

5초 분량의 음성 파일 약 700개를 분석 모델에 적용시킬 수 없어, 음성의 특징 및 패턴을 학습시킬 수 있는 피처 선정 과정이 필요하다. 실제 보이스와 딥보이스 간의 차이 유무를 피처에 반영하여 모델을 제작해야 정확도를 높이고 오탐률을 낮출 수 있다.

모델 학습에 선정한 여러 가지의 피처 중에 대표적인 주파수 피처와 12반음계의 피처를 소개한다.

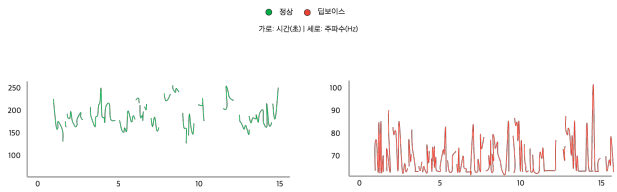

Fig 2. Frequency variation feature

Fig 2.은 주파수에 대한 변화를 나타내는 피처이며, 음성의 억양, 리듬 등을 파악하는데 활용한다.

왼쪽 그래프가 실제 보이스이고, 오른쪽 그래프가 딥보이스이다. 왼쪽은 100~250Hz 범위에서 다채롭게 이동하며, 단어와 단어 사이, 문장이 끝날 때 음성이 존재하지 않기 때문에 그래프가 끊겨 있는 반면, 오른쪽은 낮은 주파수 범위에서 변동 폭도 낮고, 딥보이스로 합성하는 과정에서 잡음이 들어가면서 끊기지 않는 그래프의 모습을 확인할 수 있다.

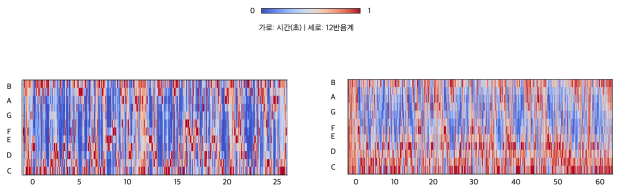

Fig 3. 12 semitone changes feature

Fig 3.은 소리의 피치를 나타내는 12개의 반음 단계를 표현한 피처이다. 해당 피처는 사람마다 목소리에 존재하는 높낮이(Tone)의 정보를 이용해 실제 보이스와 딥보이스 간의 음성 차이를 구분하는데 활용한다.

왼쪽 그래프가 실제 보이스이고, 오른쪽 그래프가 딥보이스이다. 왼쪽은 짧은 구간에 다양한 색상 변화가 일어나고 여러 반음 단계가 존재하지만, 오른쪽은 분석 구간이 길고 특정 반음 단계에 쏠려있음을 확인할 수 있다,

3.2. 머신러닝, 딥러닝

선정한 피처들은 벡터화하여 복잡한 데이터의 원본을 간략하게 만들고, 음성 간의 패턴 분석에 용이하도록 차원화하여 학습 속도를 높인다.

본 연구에서는 피처를 직접 선정하여 학습에 유리한 머신러닝과, 복잡한 음성 파일 데이터셋의 이용에 유리한 딥러닝을 서로 융합하여 모델을 제작했다. 모델의 과적합 방지를 위해 RandomForest(RF)과 DNN을 이용해 모델의 정확도를 향상했다.

RF는 의사결정 트리를 기반으로 앙상블 학습을 수행하며, 각 단계의 무작위성과 추출된 결과을 사용하여 단일 특징에 대한 의존성을 줄여 음성 탐지 시스템에 적합한 머신러닝 모델이다[4]. 또한 DNN은 여러 계층을 통해 인공 신경망을 이용한 학습 알고리즘이다. 학습에 필요한 데이터셋의 미세한 차이를 쉽게 파악하여 보이스와 딥보이스 간의 뚜렷한 판별이 가능하다[5].

3.3 딥보이스 음성 탐지

음성 파일의 판단 과정은 분석하고자 하는 음성 파일을 업로드하여 본 연구에서 선정한 피처를 기준으로 머신러닝(RF)와 딥러닝(DNN)이 학습할 수 있는 벡터화와 차원을 설정해 전처리 과정을 분석 후, 제작된 모델을 통해 실제 음성과 딥보이스 음성을 분석한다.

4. 검 증

모델 학습에 이용한 음성 파일 외에 새로 녹음한 보이스 음성 파일과 딥보이스 음성 파일 992개를 이용해 제작한 모델을 비교 분석했다. 제작한 모델의 정확도는 Table 1.과 같은 결과가 나왔다.

검증 데이터 셋	992개
정확도	98.8%
오탐률	1.2% (12개)

Table 1. DeepVoice Detection rate

제작한 모델을 통해 실제 보이스 음성 파일 496개와 딥보이스 음성 파일 496개를 분석한 결과, 98.8%의 높은 정확도로 실제 음성과 딥보이스를 분석했다.

5. 결 론

현재 딥보이스를 이용한 보이스피싱 범죄율은 지속적으로 증가하고 있다. 기관 사칭형 피싱 범죄 외에도 가족 간의 보이스피싱 범죄가 늘고 있어, 본 연구에서 제안한 모델을 활용해 인증된 사용자만을 바탕으로 안전하게 통화하다가, 본인 음성을 위조한 딥보이스 음성으로 판단 될 경우 알림 서비스를 제공하는 서비스를 개발하는 데 용이할 것으로 생각한다. 또한, 딥페이크와 관련된 사이버 보안 피해로부터 안전한 환경을 제공할 수 있을 것이라고 기대한다. (+제언)

참고문헌

[1] Reshma Sunil, Parita Mer, Anjali Diwan, Rajesh Mahadeva, Anuj Sharma, “Exploring autonomous methods for deepfake detection: A detailed survey on techniques and evaluation”, Heliyon, Vol.11, No.3, '25.02.15.

[2] Soowoon Kim, Sungtaek Lee, “Developmentof Voice Phishing Damage Prevention Service Misusing Deep Voice”, The Journal of Korean Institute of Communications

and Information Sciences, Vol.47, No.10, 1677-1685, '22.10.

[3] Harsh Chotaliya, Mohammed Adil Khatri, Shubham Kanojiya , Mandar Bivalkar, “DeepFake Detection Techniques using Deep Neural Networks(DNN)”, IEEE Xplore, '24.03.

[4] Tushar Kapoor, Abhi Gaur, Tushar Rajora, Yogya Prashar, Jyoti Parashar, “Deepfake Audio Detection System”, iJRASET, '24.05.07.

[5] Run Wang, Felix Juefei-Xu, Yihao Huang, Qing Guo, Xiaofei Xie, Lei Ma, Yang Liu, “DeepSonar: Towards Effective and Robust Detection of AI-Synthesized Fake Voices”, arXiv:2005.13770, '20.08.15.