중부대학교

💡[밝은 조명]

정진호 | 박우경 | 이하영 | 최수민

Safety For AI

나날이 발전하는 생성형 AI, 좋기만 한 걸까?

목차

목차

중부대학교

주제 선정 이유

생성형 AI란

이점에 가려진
생성형 AI의 단점

밝은 조명이 생각하는
대응책

프로토타입 소개

밝은 조명이
추구하는 바

마무리

중부대학교

주제 선정 이유

나날이 발전하는 생성형 AI, 좋기만 한 걸까?

주제 선정 이유

중부대학교

① 대표적인 생성형 AI인 Chat GPT의 출시로 인해 일상 생활 속에서의 변화를 느낄 수 있었음

밝은 조명원들도 2020년 펜데믹 이전의 대학 생활에서 생성형 AI가 본격적으로 출시되기 이전에 큰 불편함이 없었지만,
Chat GPT의 출시 이후 이전의 삶이 되게 많은 불편함이 있었다는 걸 몸소 느낌

② 이렇게 새롭게 출시된 '생성형 AI들을 이용하는 과정에서 이에 대한 단점은 없을까'라는 고민이 생김

대학 과제물에 대한 정확한 피드백, 필요한 자료 등과 같은 이점 속에서만 생활하다 보니 반항적으로 의문이 듦
이런 고민을 하게 된 영향에는 이탈리아에서 Chat GPT 서비스 제공 중단('23.03.30.),
EU 및 회원국들의 AI 규제 논의('23.04.27) 등과 같은 뉴스 기사 등을 통해 편리함만 느낀 밝은 조명원들은
'왜 규제가 필요할까'라는 의문이 있기 때문에 이런 고민이 생겼을 수도 있다 판단함

③ 만약에 생성형 AI에 치명적인 단점이 존재할 경우, 이를 보다 좋은 방향으로 개선시킬 수 있는 방법은 무엇이 있을 지 생각하게 됨

📌 그렇기 때문에 '나날이 발전하는 생성형 AI, 좋기만 한 걸까?'라는 부주제를 선정하게 됨

생성형 AI란

기존 콘텐츠를 활용한 학습 데이터를 기반으로 유사한 콘텐츠를 새롭게 만들어 내는 인공지능 기술

생성형 AI

중부대학교

* 생성형 AI

머신러닝 알고리즘을 활용하여 텍스트, 비디오, 오디오 및 이미지 등 기존 콘텐츠를 활용한 학습 데이터를 기반으로 유사한 콘텐츠를 새롭게 만들어 내는 인공지능 기술

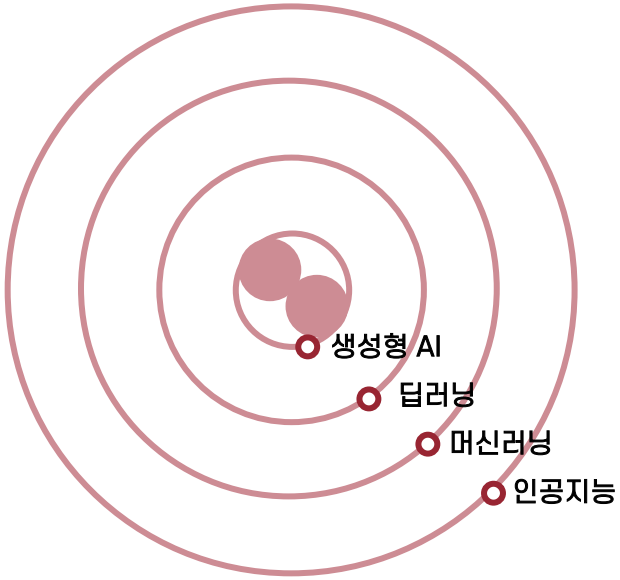

- 2012년: 이미지 처리 딥러닝 본격화
- 2014년: 생성형 AI의 새로운 혁신
- 2015년: 오픈소스 문화에 기여
- 2016년: 인공지능의 대중화
- 2017년: 언어 모델의 혁신적 돌파구 마련
- 2018년: OpenAI에서 ChapGPT 출시

1) TTA 한국정보통신기술협회
2) 한국저작권위원회

Chat GPT

중부대학교

* Chat GPT

샘 알트만이 2015.12. 설립한 인공지능 기업 OpenAI에서 GPT계열 거대 언어 모델, DALL-E 계열 이미지 생성 AI 등과 같은 서비스 제공

* GPT-3.5 언어 모델을 기반한 대화형 인공지능 챗봇(22'11.30)

사용자의 의도와 니즈에 부합하는 답변을 도출할 수 있도록, 인간 피드백 기반 강화학습(RLHF)을 적용하여 대화에 최적화

* GPT-4 언어 모델 공개(23'03.)

* 기본 챗봇은 단답형 대화나 주어진 정보 내에서 답변이 가능했다면, Chat GPT는 사용자가 입력한 텍스트의 맥락을 이해하고 과거 대화를 기억함으로써 일상적인 언어를 통해 사람과 의사소통 가능

* 파급력

관심이 촉발되어 다양한 서비스들 출시, 시장 규모 확대 등

* Chat GPT의 이용 현황

의료	• 실제 환자 데이터를 사용해 만든 '합성환자'를 대거 양산하여 치료받는 환자와 비교하기 위한 대규모 통제집단 데이터 확보 가능 • 다양한 질병변종을 만들어 교육현장에서 학생들이 무한한 사례학습을 통해 특정 질병을 식별 • 진단 • 다만 편향된 데이터로 생성된 합성환자들을 통한 결과는 부정확 할 수 있음
예술	• 작곡, 그림 그리기 등 예술작품 제작이 가능해지며 창작 과정에서 아이디어와 상호작용하며 새로운 창작물을 만들어내는 등 창작과정을 보조하는 도구로 사용 • 인공지능이 창작물을 완전히 대체할 수 없으며, 규제가 없는 상황에서 교육에 있어 딥페이크 및 표절문제 우려
법	• 개인 법률대리인 판사의 보조적 역할 수행 • 생성시를 통해 개인은 필요한 법률문서를 준비하고, 변호사는 법률연구와 문서작업을 도움 받고, 판사는 판결의 정확성과 효율성을 개선시킬 수 있음 • 법적 의사결정에서 공정성과 신뢰성이 최우선 가치이므로 생성AI가 잘못된 정보를 제공하고 사례들을 만들어 낼 경우 커다란 문제 발생
노동	• 전문가가 수행하던 작업을 자동화 고도화 하면서 업무를 보조하는 형태로 생산성 증대 • 예) 미국 주별 투표 패턴과 경제성장 변화의 상관관계를 시각화 하는 작업 (기존) 데이터확보, 코딩, 시각화 도구 작업 등 여러 시간 소요 ➡️ (생성형 AI) 몇 초 안으로 단축 • 생산성 증가로 임금이 증가할 수 있으나, 노동자가 AI 대체될 수 있어 정책 입안자 등 여러 경제주체들의 선택에 의해 노동시장이 변화할 예정
교육	• 학생들에게 맞춤형 프로그램을 제공,실시간 모니터링을 통한 개별적인 피드백을 제공하는 등의 방식으로 학습 불균형 해결 가능 • 글쓰기의 질은 사람의 사고능력에 기반하므로 학습현장에서 생성형 AI에 과의존시 학생의 사고력과 창의력 저해

이점에 가려진

생성형 AI의 단점

단점

중부대학교

① 관심으로 인해 각 기업들에서 성급하게 출시

무료로 대규모 언어 모델 기반 Chat GPT의 API가 공개되었기 때문

② 거짓 답변을 사실처럼 대답, 최신 정보에 대한 내용은 답변하지 못하는 다양한 기술적 한계점 존재

할루시네이션(hallucination) 이슈 : AI가 존재하지 않는 환각을 보는 것처럼 없는 답변 혹은 틀린 답변을 제시

③ 대규모 언어 모델(LLM)의 한계

데이터에 포함된 정보만을 이용해 학습하고 생성하기 때문에 데이터의 양과 질에 영향

만약 학습 데이터가 부족하거나 이에 대한 오류나 편향이 존재할 경우 성능 저하

학습 데이터를 실시간적으로 연동하지 않으면 올바르지 못한 정보를 제공

④ 생성된 문장의 일관성과 신뢰성의 문제, 윤리적 문제, 환경적 문제 등

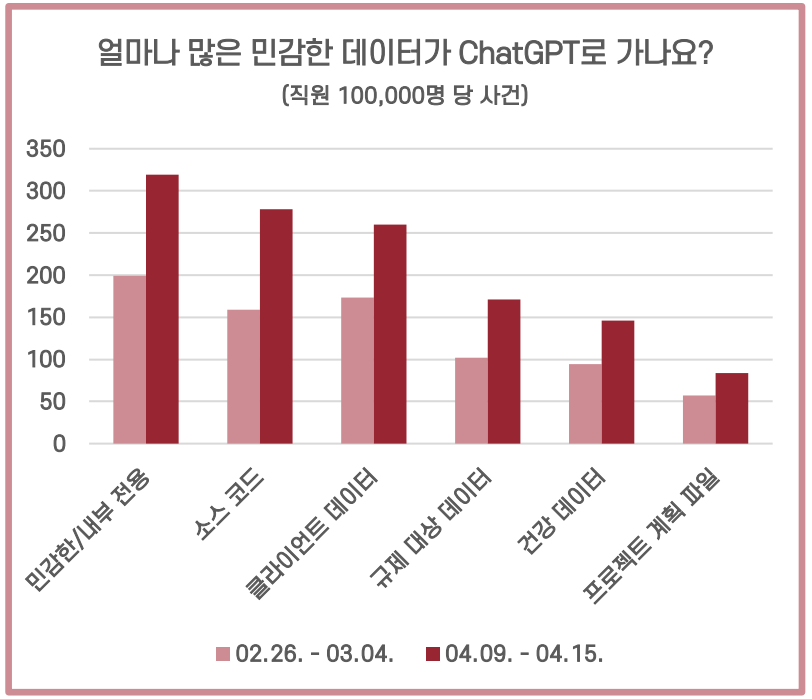

▲ 위 그래프 설명

기업에서 ChatGPT 사용으로 인한 민감한 데이터를 유출

즉, 더욱 생성형 AI가 활성화 될 수록 민감한 데이터 유출 증가로 이어질 것

현재 생성형 AI에 대한 규제

중부대학교

[국외]	주요 내용	시작 일시
미국	CAIDP는 ChatGPT가 개인정보보호와 공공안전에 위협이 되어 FTC의 AI 기업에 대한 공개 지침을 위반한다면서 OpenAI를 고발('23.03.30)	'23.04.11.
EU	ChatGPT 출시에 따라 기존 발의·논의 중이던 'AI Act (AI 법안)' 내용 중 "고위험군 AI" 분류에 ChatGPT를 추가하는 등 법안 수정 검토	'23.03.05.
	EDPB는 인공지능에 대한 프라이버시 규칙을 설정하기 위한 첫 단계로 ChatGPT에 대한 TF(태스크포스)를 결성	'23.04.13.
독일	BfDI는 개인정보 유출 등이 우려됨에 따라 ChatGPT의 사용 및 접속을 금지하는 방안 검토	'23.04.01.
일본	문부과학성은 ChatGPT 관련 글로벌 활용 사례, 동향 조사 및 ChatGPT 사용 주의사항을 담은 가이드라인 개발 착수	'23.04.06.
중국	중국 내에서 ChatGPT 홈페이지 등 접속 차단	'23.02.24.
	국가인터넷정보판공실에서 생성형 AI 서비스 관리 방안 초안 발표	'23.04.11.

[국내]	주요 내용	시작 일시
공공기관 (교육부)	교육현장에서 ChatGPT 활용할 때 지켜야 할 원칙을 담은 "ChatGPT 활용 원칙" 개발 착수	'23.03.17.
삼성전자	ChatGPT 사용으로 정보 유출 사건 이후, ChatGPT 사용을 금지하고 임직원 대상 ChatGPT 관련 설문조사를 통해 내부 지침 수립	'23.04.02.
SK 하이닉스	사내 내부망을 통해 ChatGPT 접속 시, 기업 및 개인정보 유출을 우려하여 ChatGPT 사용에 대해 원칙적 차단	'23.04.02.
금융권	우리은행과 기업은행은 정보 유출 등의 문제로 사내에서 ChatGPT 활용을 금지하였으며, KB국민은행, 하나은행, 신한은행은 유의사항 별도 배포	'23.05.09.

생성형 AI의 출시와 동시에 세계 모든 곳에서 관심이 쏠림으로써 미흡한 부분의 개선 속도가 개발 속도에 못 맞춰 간다고 느낌

안정기에 도달하기 전까지 많은 규제가 생길 것으로 생각 됨

5) 한국인터넷진흥원(KISA)

밝은 조명이

생각하는

대응책

대응책

중부대학교

* 배경

① 각광받는 생성형 AI, 규제로만은 제어가 되지 않음

극심한 규제는 생성형 AI 발전에 부정적인 영향을 미칠 수 있음

국내/외 규제 사례들만 봐도 개발 회사에 대한 소송 및 서비스 차단이 주를 이룸

② 우리가 알지 못한 생성형 AI를 전부 포함하면, 단기간에 엄청나게 발전한 것을 알 수 있음

우측 그래프 참조

* 밝은 조명이 생각하는 대응책

생성형 AI는 꾸준한 업데이트가 이루어 질 것이고, 지속적인 모니터링이 필요하다고 분명하게 생각

생성형 AI는 현재 우리가 알고 있는 것보다 수백 개, 수천 개 이상이 존재할 수 있음

기업의 규제도 중요하지만, 생성형 AI를 이용하는 사용자들도 주의를 갖고 이용하는 게 중요

📌 **그렇기 때문에 수 많은 생성형 AI를 이용하는 사이트가 안전한 지부터 파악 우선**

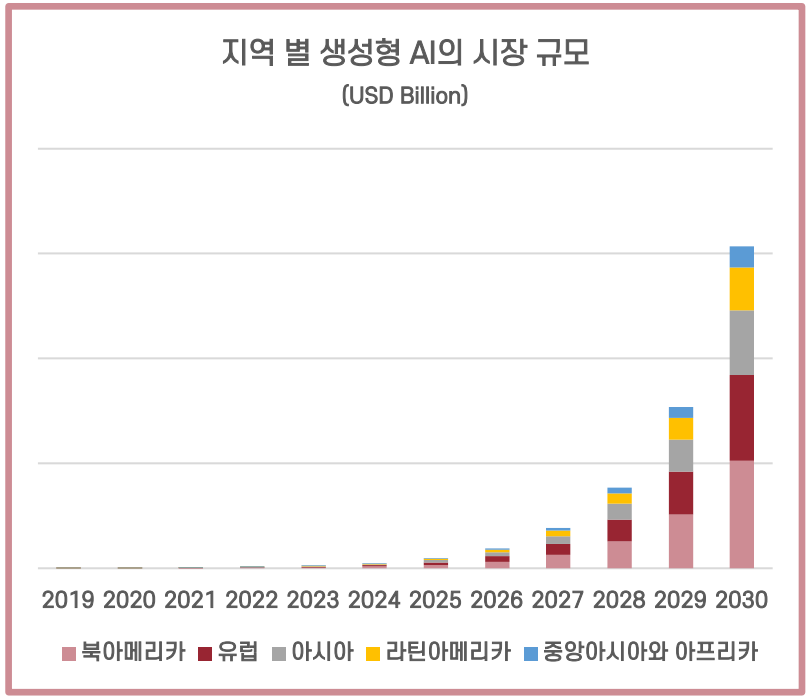

▲ 위 그래프 설명

생성형 AI 시장은 연 평균 35%의 성장률로 예측

성장 요인으로는 다양한 분야에서 인공지능 통합 시스템의 사용 확대, 기계학습과 딥러닝의 디지털 역량, 정부 지원 등

6) Polaris Market Research

프로토타입 소개

서비스 흐름도

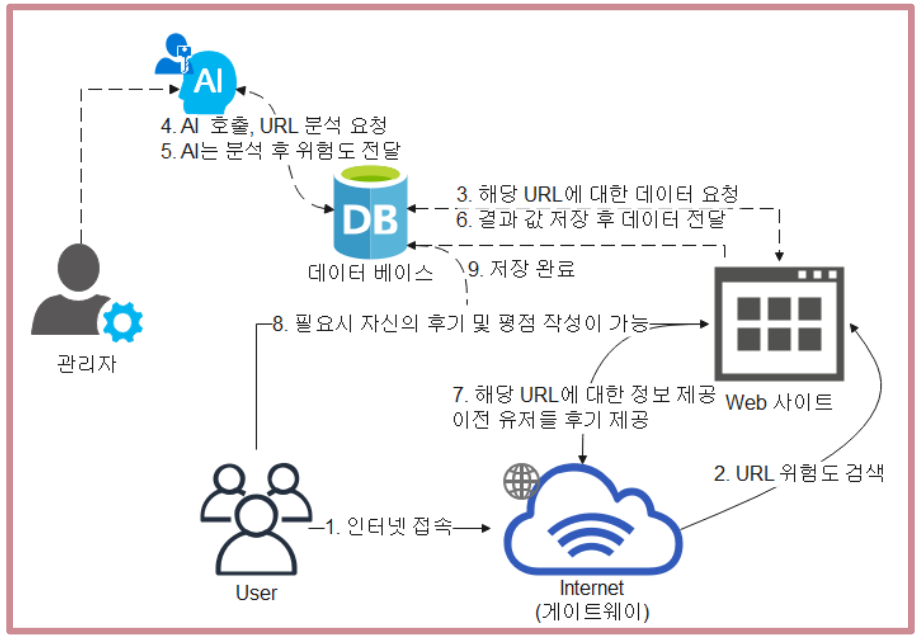

1. 사용자가 인터넷에 접속
2. URL 위험도 검색 후 웹 서버를 통해 사이트 접속
3. DB로 부터 해당 URL에 대한 데이터를 요청
4. AI 호출한 후, URL에 대한 정보를 분석 요청
5. AI는 분석 후 결과 값(위험도 자료)을 DB로 전송
6. 해당 결과 값을 저장 후 웹 서버로 데이터를 전송
7. 해당 URL에 대한 정보와 이전 사용자들의 후기 제공
8. 필요 시 자신의 후기 및 리뷰 작성 가능
9. 작성한 자료를 DB에 저장

구성도 (시나리오)

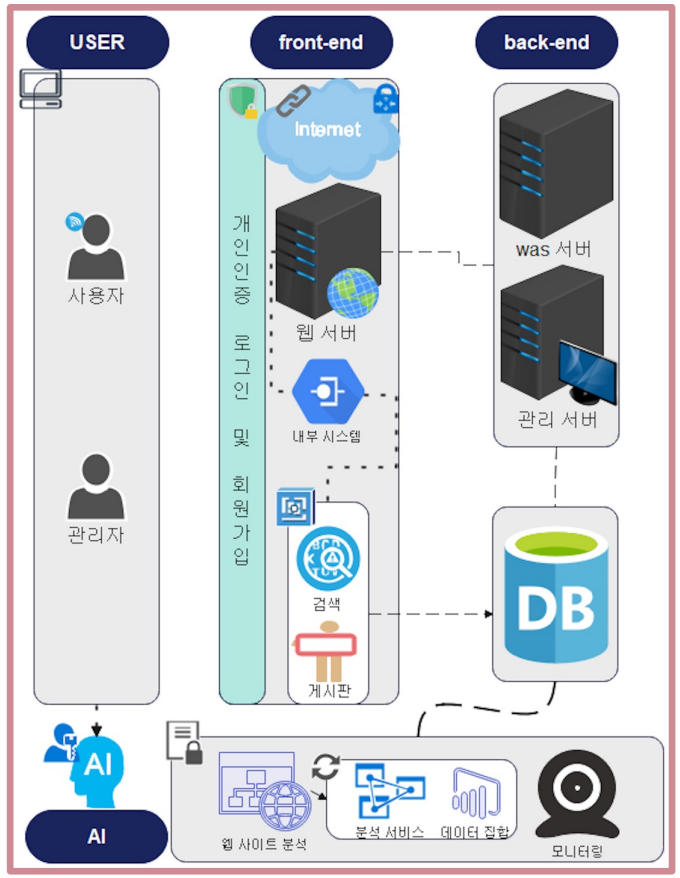

서비스 구성도	1. 사용자가 웹 사이트 주소(URL) 입력 2. 프론트 엔드가 이 요청을 받아 백 엔드로 전달 3. 백 엔드가 해당 URL에 대한 데이터 베이스 조회 4. 해당 URL에 대한 정보가 없다면 A 모듈 호출, 새로운 분석 주행 5. AI는 해당 사이트 분석 후 위험도 판정 6. 결과값을 데이터 베이스에 저장 및 프론트 엔드로 전달 7. 프론트 엔드는 이 정보를 바탕으로 사용자에게 사이트의 위험 정보 제공 / 이전 유저들 후기 제공(참고) 8. 사용자는 필요 시 자신의 후기 및 평점 작성이 가능 / 데이터 베이스에 저장되어 후속 사용자들의 참고 자료가 됨
프론트 엔드	1. 사용자로부터 URL 요청을 받아 백 엔드로 전달 2. 백 엔드에서 받은 정보를 사용자에게 사이트의 위험 정보 제공
백 엔드	1. 프론트 엔드로 받은 URL에 대한 데이터베이스 조회를 수행 2. 해당 URL 정보가 없다면 AI 호출 요청 3. AI에 받은 결과 값을 데이터베이스에 저장 후 프론트 엔드로 전달
생성형 AI	1. 백 엔드로부터 호출을 받으면 해당 사이트 분석 후 위험도 판정 2. 결과 값을 백 엔드에 전달

알고리즘 1

중부대학교

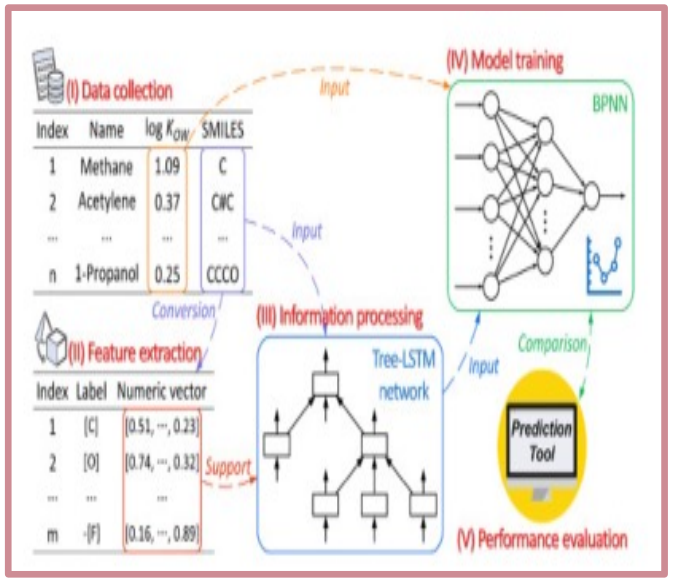

<딥러닝 접근 방식을 사용하여 QSPR 모델을 개발하는 프로세스의 개략도>

(I) 데이터 수집	1. 실험적으로 측정된 log k 값과 단순화된 SMILES(분자 입력 라인 입력 시스템) 문자열은 QSPR 모델 개발에 필요하기 때문에 수집 2. 기본 분자 구조 정보를 표현하는 데 SMILES 문자열이면 충분
(II) 특징 추출	1. SMILES 화합물 문자열은 원자 서명으로 구현 제안된 원자 임베딩 알고리즘을 기반으로 숫자 벡터 목록을 생성하는 데 활용 2. 벡터는 분자 구조를 설명하고, 그 특징을 나타낼 수 있음
(III) 정보 처리	1. SMILES 문자열은 정규화 분자 그래프 이론을 사용하여 표준 분자 서명으로 변환 2. 이 서명은 BPNN 입력으로 벡터를 생성할 목적으로 Tree-LSTM 네트워크에 매핑
(IV) 모델 훈련	1. BPNN은 Tree-LSTM 네트워크로부터 입력을 받은 후, 상관관계 프로세스를 지원하고 만족스러운 QSPR 모델을 학습하기 위해 반복적으로 실행 2. 훈련 과정에서 DNN 모델의 매개변수를 최적화하기 위해 매개변수를 업데이트 3. 최종적으로 log K 값 추정을 위해 더 나은 성능을 가진 QSPR 모델이 보존
(V) 성과 평가	1. 개발된 QSPR 모델을 기반으로 외부 데이터 세트의 예측 성능을 통해 일반화 능력을 평가 2. 권위있는 예측 모델과의 비교를 통해 QSPR 모델의 대외 경쟁력을 평가

알고리즘 2

중부대학교

Child-sum Tree-LSTM		N-ary Tree-LSTM	
$\tilde{h}_j = \sum_{k \in C_j} h_k$	(2)	–[a]	
$i_j = \sigma W^i x_j + U^i \tilde{h}_j + b^i$	(3)	$i_j = \sigma W^i x_j + \sum_{l=1}^{N} U^i_l h_{jl} + b^i$	(9)
$f_{jk} = \sigma(W^{(f)} x_j + U^{(f)} h_k + b^{(f)})$	(4)	$f_{jk} = \sigma W^f x_j + \sum_{l=1}^{N} U^f_{kl} h_{jl} + b^f$	(10)
$o_j = \sigma W^o x_j + U^o \tilde{h}_j + b^o$	(5)	$o_j = \sigma W^o x_j + \sum_{l=1}^{N} U^o_l h_{jl} + b^o$	(11)
$u_j = \tanh W^u x_j + U^u \tilde{h}_j + b^u$	(6)	$u_j = \tanh W^u x_j + \sum_{l=1}^{N} U^u_l h_{jl} + b^u$	(12)
$c_j = i_j \cdot u_j + \sum_{k \in C_j} f_{jk} \cdot c_k$	(7)	$c_j = i_j \cdot u_j + \sum_{l=1}^{N} f_{jl} \cdot c_{jl}$	(13)
$h_j = o_j \cdot \tanh(c_j)$	(8)	$h_j = o_j \cdot \tanh(c_j)$	(14)

a

▲ <Child-sum Tree-LSTM과 N-ary Tree-LSTM의 전이 방정식>

분류에 대한 두 개의 Tree-LSTM 모델의 성능 평가는 두 Tree-LSTM 모델이 모두 순차 LSTM 모델보다 우수하고 더 나은 분류 기능을 제공할 수 있음을 나타냄

따라서 본 연구에서는 N-ary Tree-LSTM 네트워크를 사용하여 분자를 묘사하고 입력 변수는 임베딩 알고리즘에 의해 변환 된 벡터임

QSPR 모델에서 변수xj는 결합의 하위 문자열("A" 또는 "-B")을 나타내는 입력 벡터이고, 벡터$_{hj}$는 분자 구조를 나타내는 출력 벡터, 벡터hj_최종적으로 BPNN의 속성과 연결됨

BPNN은 입력층, 은닉층, 출력층으로 구성, 표의 기타 변수 및 함수의 경우 $W^{(i,o,u,f)}$, $U^{(i,o,u,f)}$,

$b^{(i,o,u,f)}$는 학습이 필요한 매개변수이며, σ는 활성화 함수 시그모이드를 나타냄

중요한 원자가 입력으로 주어지면 1에 가까운 값(즉, “open”)을 갖고, 덜 중요한 원자가 입력되면 0에 가까운 값(즉, “closed”)을 가짐

즉, 다른 분자 구조를 학습하면 Tree-LSTM 네트워크가 자동으로 계산 그래프를 변경 BPNN은 Tree-LSTM 네트워크의 출력 벡터를 받아들이고 이를 속성 값과 연관 이러한 방식으로 Tree-LSTM 네트워크와 BPNN을 기반으로 DNN이 구축

알고리즘 3

중부대학교

DNN 핵심 코드

```
import tensorflow as tf
from tensorflow.keras.datasets import mnist
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense

# 데이터 로드
(x_train, y_train), (x_test, y_test) = mnist.load_data()

# 이미지를 28*28=784 픽셀의 1D 배열로 변환
x_train = x_train.reshape(60000, 784)
x_test = x_test.reshape(10000, 784)

# 입력값을 [0-255]에서 [0-1]로 정규화
x_train = x_train.astype('float32') / 255.
x_test = x_test.astype('float32') / 255.

# 레이블을 원-핫 인코딩으로 변환
y_train = tf.keras.utils.to_categorical(y_train, num_classes=10)
y_test = tf.keras.utils.to_categorical(y_test, num_classes=10)

# DNN 모델 생성
model = Sequential()
model.add(Dense(512, activation='relu', input_shape=(784,))) # 첫 번째 은닉층 (512개의 뉴런)
model.add(Dense(256, activation='relu')) # 두 번째 은닉층 (256개의 뉴런)
model.add(Dense(10, activation='softmax')) # 출력층 (10개 클래스에 대한 확률 출력)

# 모델 컴파일
model.compile(loss='categorical_crossentropy', optimizer='adam', metrics=['accuracy'])

# 학습 실행
history=model.fit(x_train,y_train,batch_size=128 ,epochs=5 ,verbose=1 ,validation_data=
(x_test,y_test))
```

프로토타입 단계 1

중부대학교

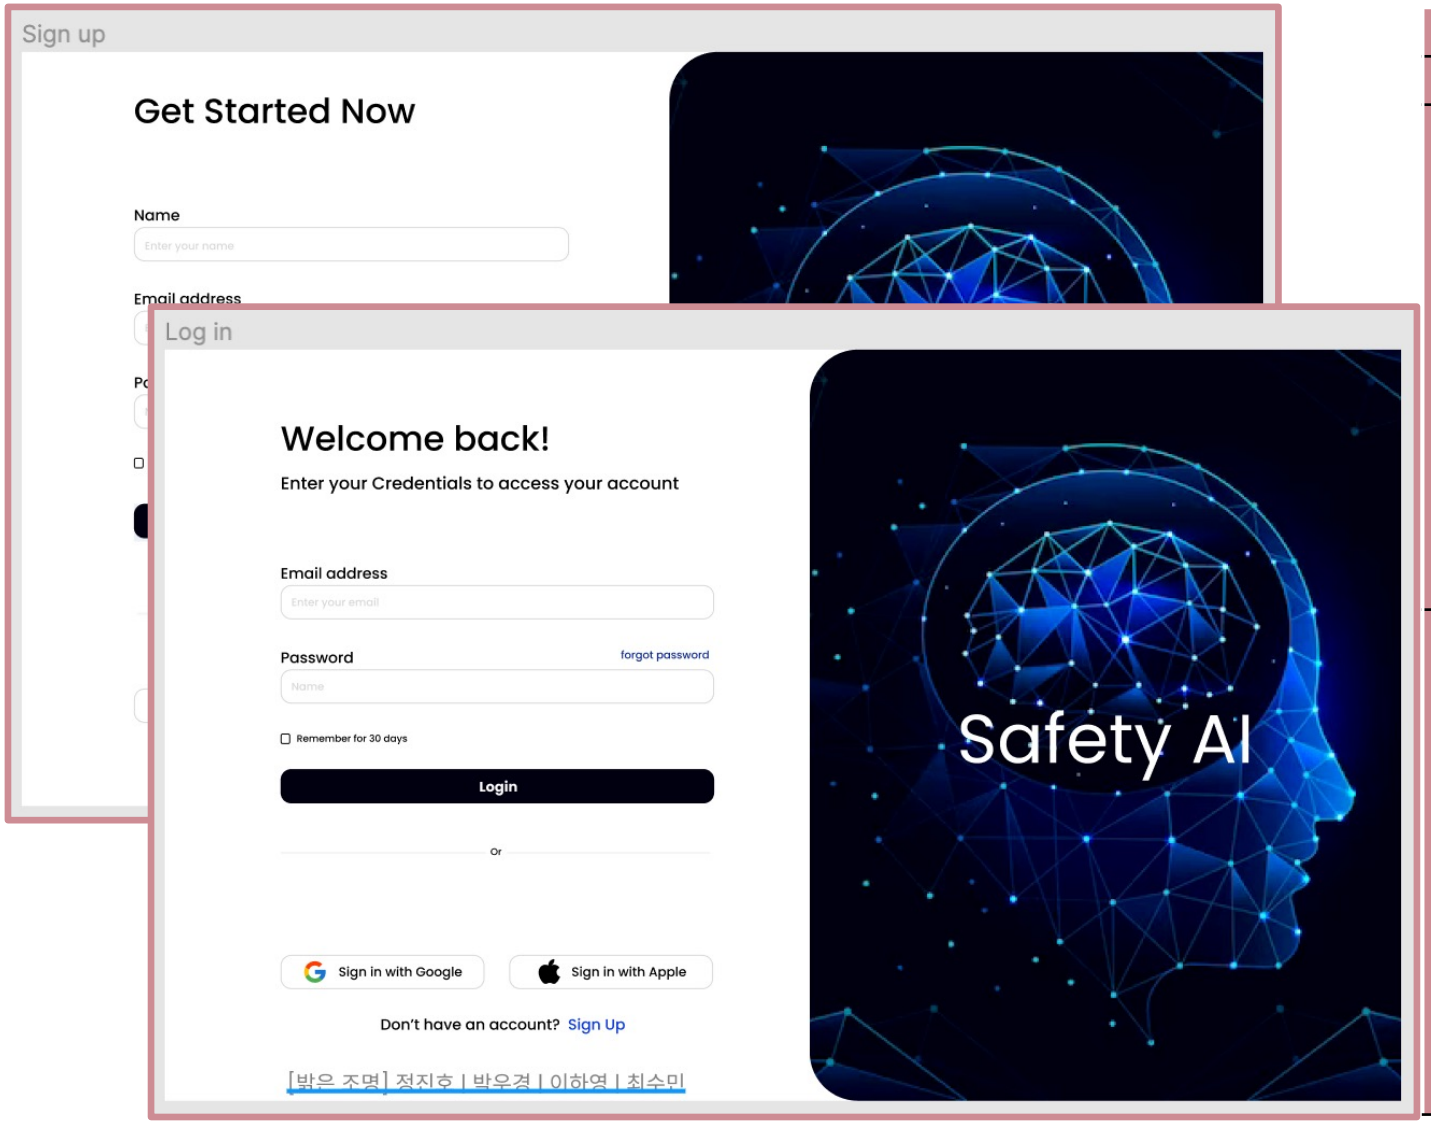

기능 번호	LOG-01, LOG-02 (Login)
기능 명	로그인 및 회원가입
기능 설명	Safety AI 사이트를 이용하기 위해 로그인, 회원가입이 가능한 창
처리 내용	1 – 1 로그인: 로그인 할 수 있는 기능 사용자가 이메일 주소, 비밀번호를 입력 후 회원 정보 확인 ➡️ 일치 할 경우 로그인 완료 / 모든 서비스는 로그인 후 이용 가능 1 – 2 회원가입: 서비스를 이용하고 싶으면 해야 하는 절차 이름, Email, PW을 입력(필요한 회원 가입 정보) 후, 새로운 회원 정보 저장 1 – 3 비밀번호 찾기: 비밀번호를 찾기 위해, 이메일로 인증번호를 보낸 후, 확인 절차를 밟은 후 새롭게 비밀번호 작성

프로토타입 단계 2-1

중부대학교

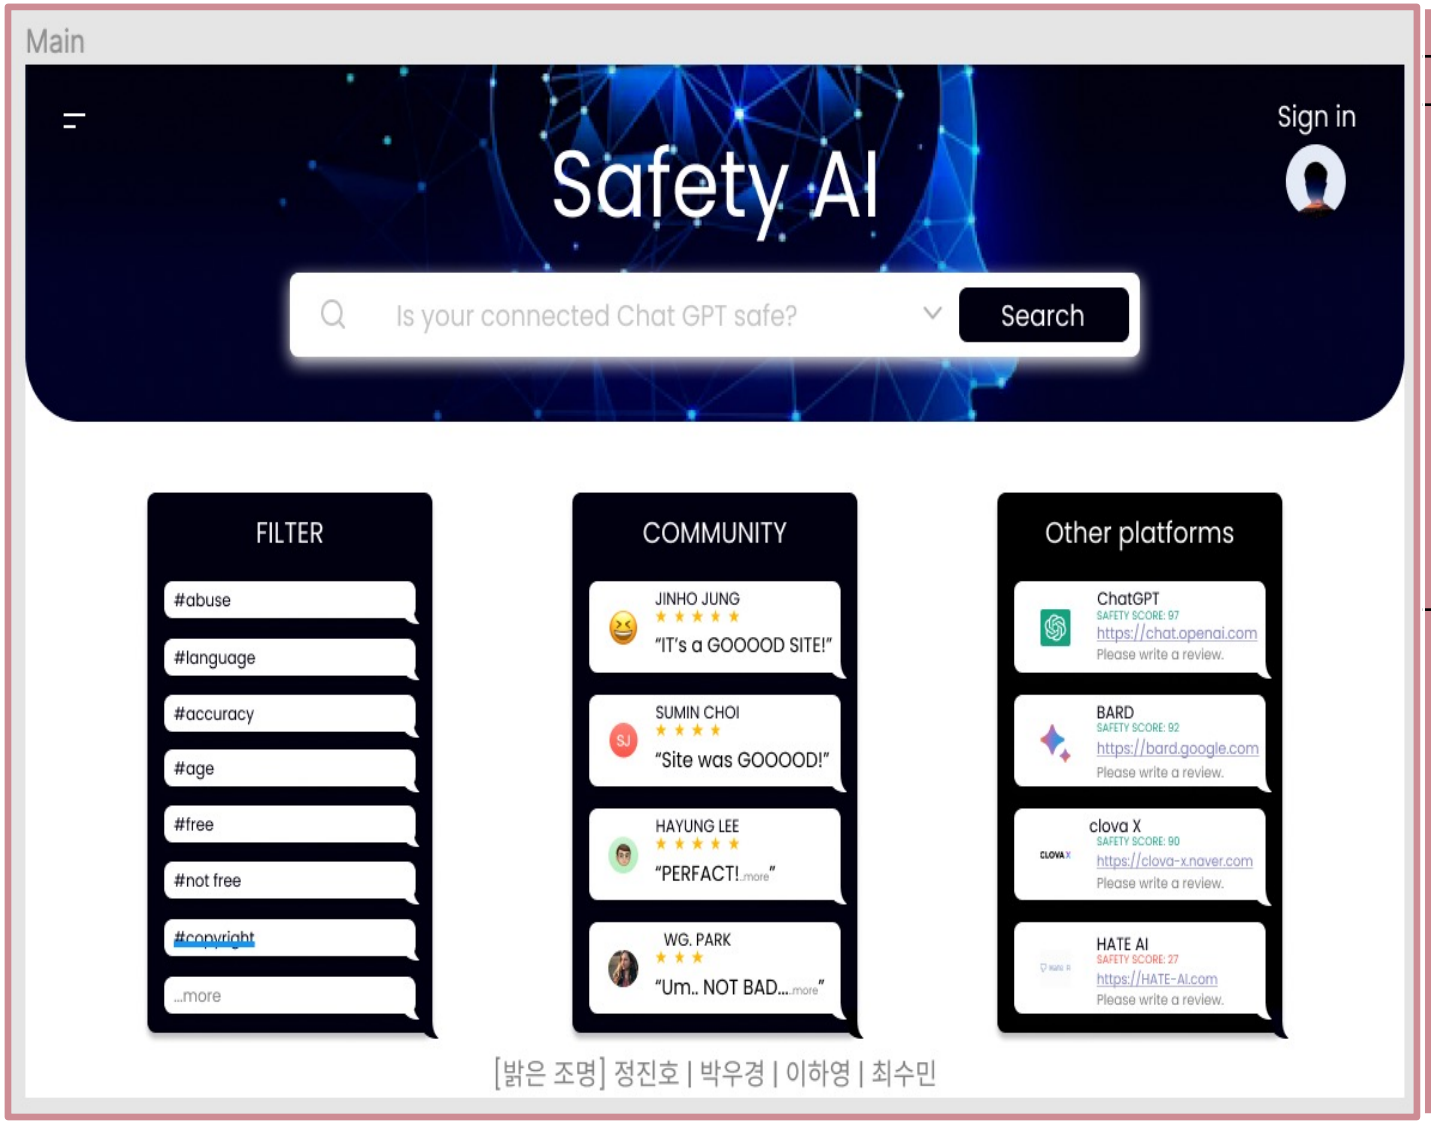

기능 번호	F-01(Function)
기능 명	메인 화면
기능 설명	**중간에 있는 검색창**에 사용할 생성형 AI의 주소나 이름을 입력해 **Safety Score** 확인 **Filter**을 통해 **사용자가 지정한 필터**대로 Safety Score 조건을 지정할 수 있음 **Community**을 통해 해당 생성형 AI 사이트의 장, 단점의 **의견**을 나눔 **Other Platforms**을 통해 현재 존재하는 생성형 AI의 사이트들을 알 수 있음
처리 내용	메인 화면이며, 화면에 표시하여 전체적인 서비스를 볼 수 있음 2 – 1 – 1 Safety Score 확인: 사용자가 생성형 AI 주소 또는 사이트 이름 입력 시 해당 AI의 Safety Score 조회 2 – 1 – 2 Filter: 사용자가 설정한 필터 조건을 전송하여 조건에 맞는 AI 정보를 조회 2 – 1 – 3 Community: 사용자의 작성 의견은 DB에 저장 2 – 1 – 4 Other Platforms: 타 생성형 AI 사이트 리스트를 조회해 제공

프로토타입 단계 2-2

중부대학교

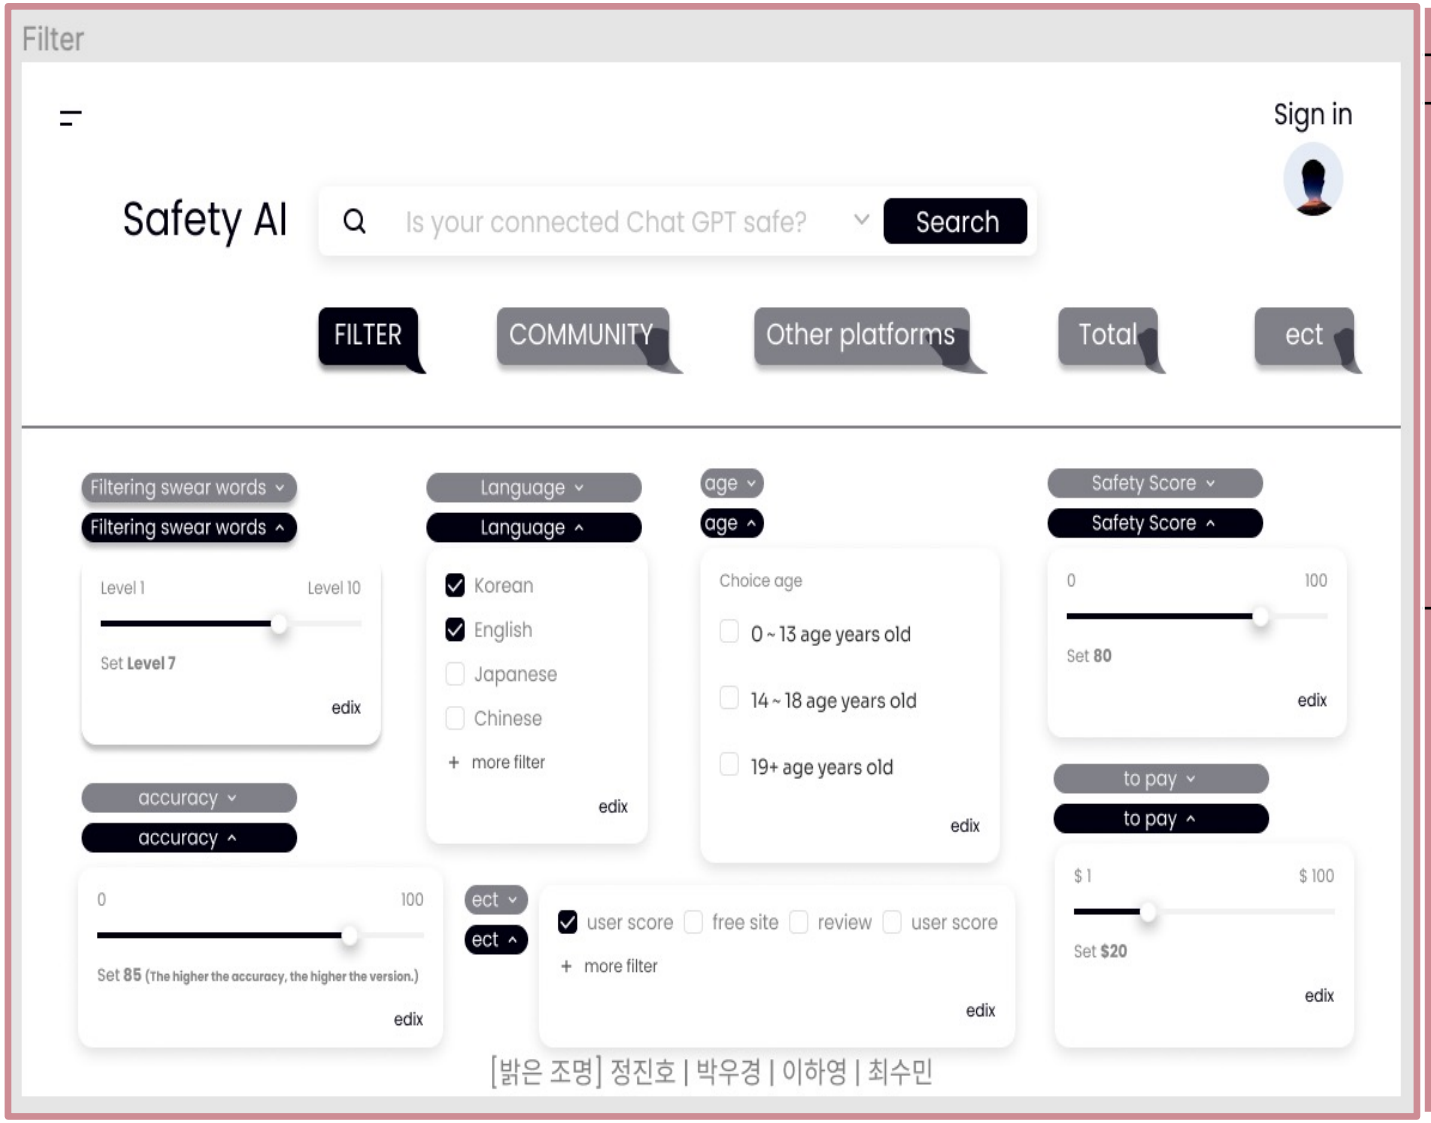

기능 번호	F-02
기능 명	Filter
기능 설명	Main 창에서 Filter을 누르면 이 페이지로 이동 큰 블록으로 **욕설, 정확도, 언어, 나이, Safety Score, 유료**에서 **필터링** 가능 (큰 블록에서도 **세부적(단계적)으로 조절 가능**) 기타(etc) 부분에서는 **그 외의 필터링을 사용자가 직접 추가**해줄 수 있음
처리 내용	필터링 해주는 기능(ex. 욕설, 정확도, 언어, 나이 등) 2 – 2 – 1 메인 화면에서 Filter 클릭 시, Filter 페이지로 리다이렉트함 2 – 2 – 2 사용자가 필터 조건을 설정하면 받은 필터 조건에 맞게 조회 후(DB) 결과 값 반환 2 – 2 – 3 화면에 출력

프로토타입 단계 2-3

중부대학교

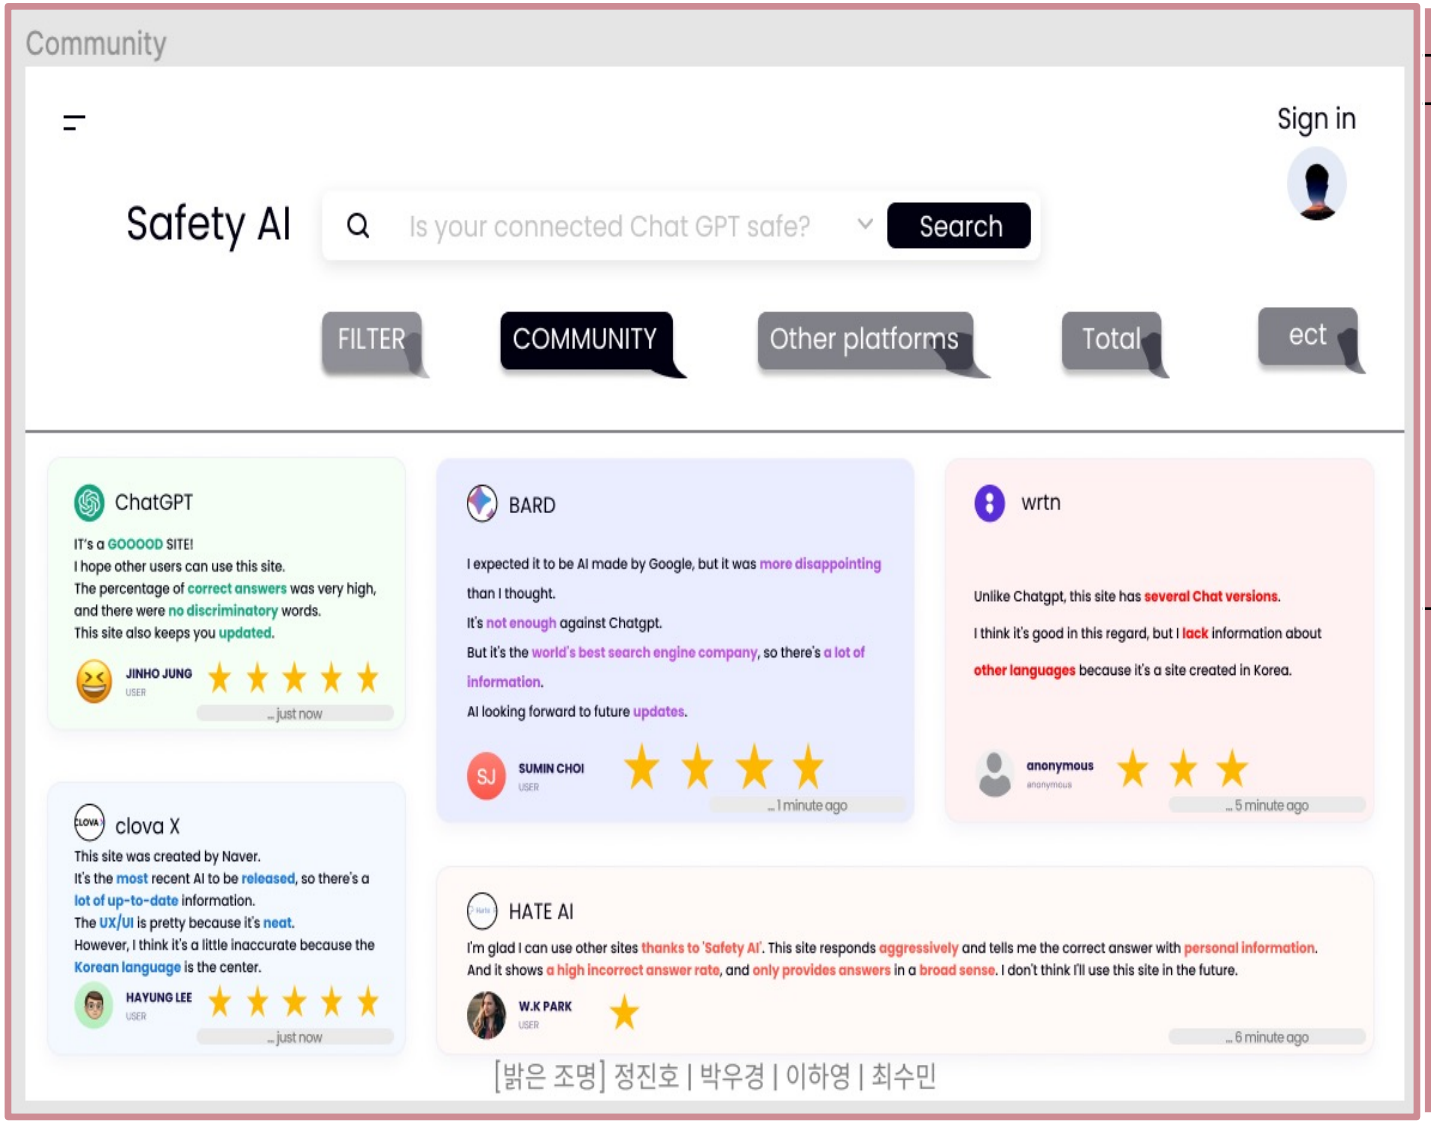

기능 번호	F-03
기능 명	Community
기능 설명	Main 창에서 Community를 누르면 이 페이지로 이동 현재 존재하는 생성형 AI의 사이트들을 각 나라별 사용자들이 사용 후 느낀 점을 공유하는 공간 사용자가 지정한 점수는 **또 다른 Filter 조건**이 됨 (**즉, 별의 개수가 Safety Score에 영향**을 미침) 이 후기는 **실시간으로 업로드** 되기 때문에 최신 정보를 빠르게 습득 작성된 후기를 보고 **문장의 핵심 단어를 파악해 필터링 조건에 포함**
처리 내용	생성형 AI 사이트의 사용자들의 후기를 볼 수 있음 2 – 3 – 1 메인 화면에서 Community 클릭 시, Community 페이지로 리다이렉트함 2 – 3 – 2 사용자가 점수 작성 시, DB에 저장 2 – 3 – 3 지정한 점수는 Safety Score 계산에 반영, 이 계산은 DB에 업데이트 2 – 3 – 4 실시간으로 표기 되기 때문에, 주기적으로 요청하고 받아와서 화면에 출력하는 방식으로 구현 2 – 3 – 5 핵심 단어를 파악해서 필터링 하고 싶다면, 알고리즘을 활용해 구현, 알고리즘은 핵심 단어 추출, 결과 값을 DB에 저장

프로토타입 단계 2-4

중부대학교

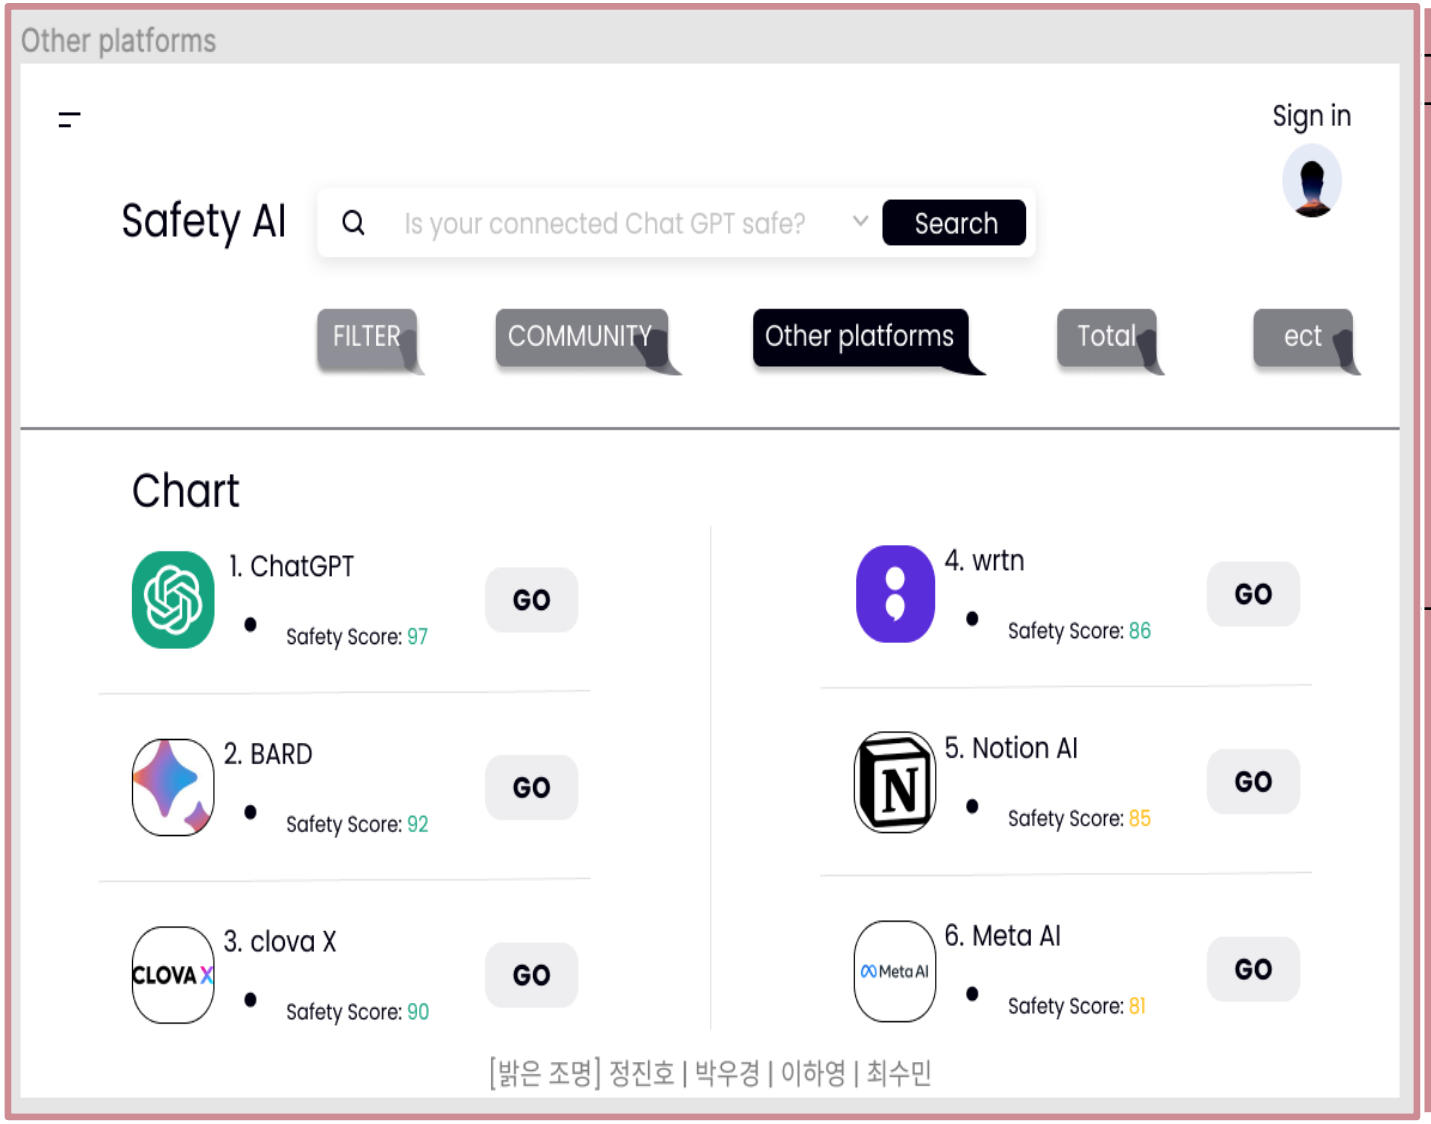

기능 번호	F-04
기능 명	Other Platforms
기능 설명	Main 창에서 Other platform을 누르면 이 페이지로 이동 **현재 사용되고 있는 생성형 AI가 어떤 게 있는 지 확인**할 수 있음 **Safety Score을 기준**으로 생성형 AI 사이트 **순위**도 간편하게 확인 주소를 알지 않아도 GO 버튼 클릭 한 번으로 사이트 접속 가능 (이렇게 접속했을 때도 프로토타입 3-4 화면이 보일 수 있음)
처리 내용	다른 생성형 AI의 종류 파악 가능 / 각 사이트 연결이 되어 있음 2 – 4 – 1 메인 화면에서 Other Platforms 클릭 시, Other Platforms 페이지로 리다이렉트함 2 – 4 – 2 Other Platforms 페이지에 들어갈 때, 현재 사용되고 있는 생성형 AI의 목록을 DB에서 조회, 결과 값 반환 / 반환 된 결과 값 화면에 출력하여, 사용자가 확인 할 수 있음 2 – 4 – 3 Safety Score을 기준으로 AI 사이트의 순위를 계산, 계산 정보 화면에 출력 2 – 4 – 4 원하는 사이트 링크를 클릭 시, 해당 AI 사이트의 URL을 브라우저에 요청하여, 사이트에 접속 할 수 있음

프로토타입 단계 3-1

중부대학교

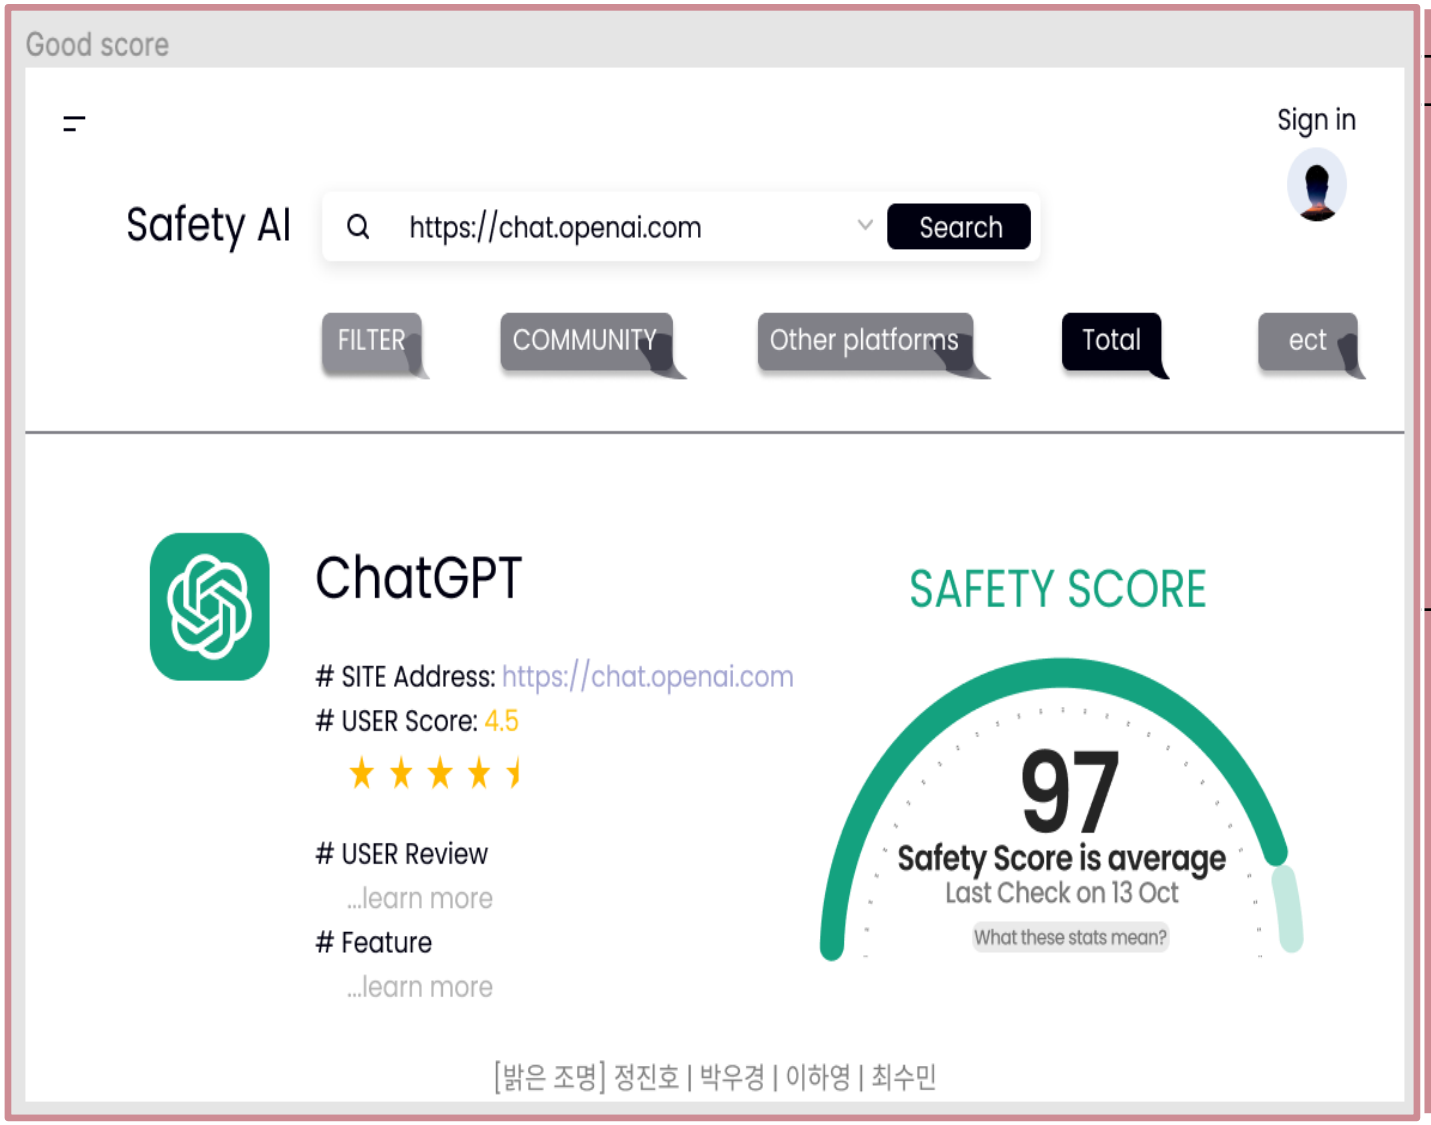

기능 번호	SS-01(Safe Score)
기능 명	Safety Score 확인 1
기능 설명	검색창에 이용할 생성형 AI 주소를 입력했을 때 이 사이트에 대한 Total 정보를 확인할 수 있음 **Safety Score은 0점부터 100점**까지 존재하며, **점수가 높을 수록 초록색으로 안전**하다는 것을 보여 줌 해당 사이트의 사용자들이 이용한 점수도 확인이 가능하고, 이 점수에 대한 리뷰를 확인할 수 있음 또한, Feature을 통해 해당 사이트의 정보, 특징도 파악 가능
처리 내용	사용자가 검색창에 생성형 AI 주소를 입력하고 검색을 요청하면, 받은 주소에 해당하는 AI의 정보를 DB에서 조회, 결과 값 반환 후 화면에 출력하여 사용자가 확인 할 수 있음 3 – 1 – 1 0 ~ 100점까지 존재, 점수에 따라 색상이 변경 3 – 1 – 2 해당 사이트의 사용자들이 부여한 점수도 조회, 화면에 출력 3 – 1 – 3 Feature 클릭 시, DB에서 조회하여 화면에 출력

프로토타입 단계 3-2

중부대학교

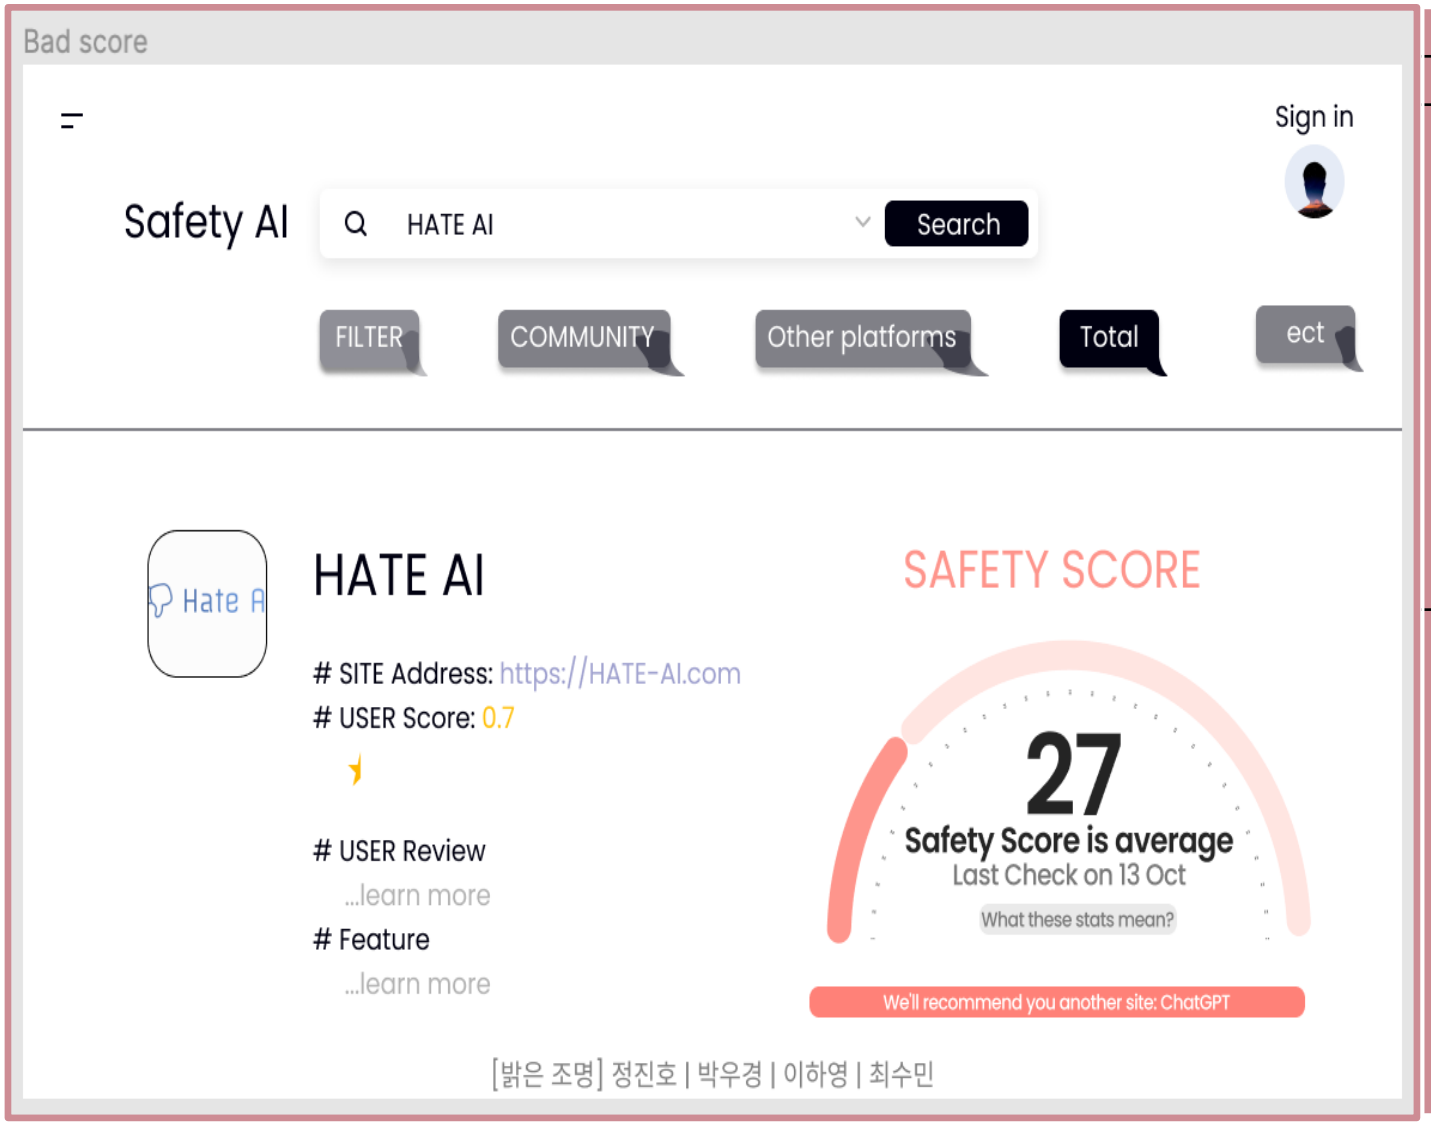

기능 번호	SS-02
기능 명	Safety Score 확인 2
기능 설명	검색창에 이용할 생성형 AI 이름을 입력했을 때 이 사이트에 대한 Total 정보를 확인할 수 있음 **Safety Score은 0점부터 100점**까지 존재하며, **점수가 낮을 수록 빨간색으로 불안전**하다는 것을 보여 줌 앞 전의 단계와 달리 부정적인 사이트임을 알 수 있으므로, **Safety Score이 높은 사이트들 중에 랜덤으로 제안**을 해 줌 (Safety Score 그래표 아래 표시)
처리 내용	사용자가 검색창에 생성형 AI 주소를 입력하고 검색을 요청하면, 받은 주소에 해당하는 AI의 정보를 DB에서 조회, 결과 값 반환 후 화면에 출력하여 사용자가 확인 할 수 있음 3 – 2 – 1 0 ~ 100점까지 존재, 점수에 따라 색상이 변경 3 – 2 – 2 해당 사이트의 사용자들이 부여한 점수도 조회, 화면에 출력 3 – 2 – 3 만약, 사용자가 검색한 사이트의 Safety Score가 낮거나, 부정적인 경우 DB에서 Safety Score가 높은 사이트들을 조회하여, 화면에 출력

프로토타입 단계 3-3

중부대학교

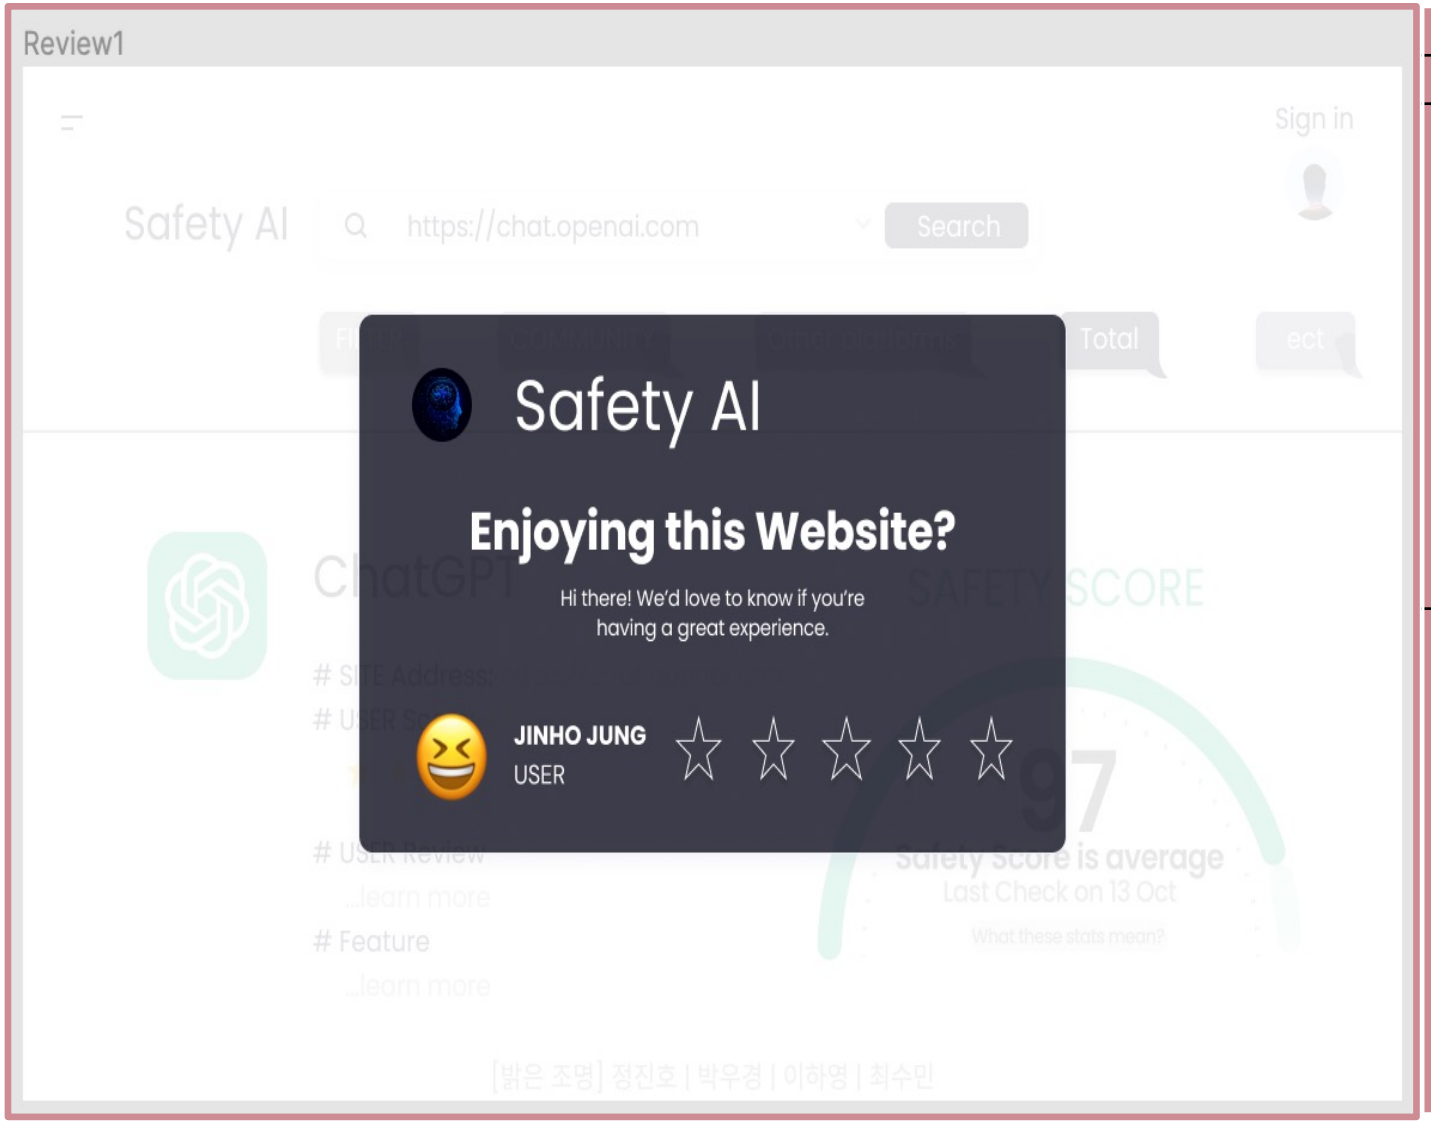

기능 번호	RV-03(Review)
기능 명	Review 작성 1
기능 설명	해당 사이트의 안전함을 Safety Score로 확인한 후 이동을 하면, **Safety AI 사이트의 리뷰 작성**이 팝업으로 뜸 5점 만점으로 별의 개수를 정해준 다음, 리뷰를 작성할 수 있게 됨 이 리뷰는 **개발자(사이트 관리자)에게만 공유**되며, Community에 기록이 남지 않음
처리 내용	해당 사이트의 안전함을 확인 후 이동 후, 리뷰 작성 팝업이 표시 3 – 3 – 1 별점 부여 후, 리뷰 작성 3 – 3 – 2 작성 된 별점, 리뷰는 DB에 저장 3 – 3 – 3 저장된 별점, 리뷰 정보는 개발자(사이트 관리자)에게만 공유

프로토타입 단계 3-4

중부대학교

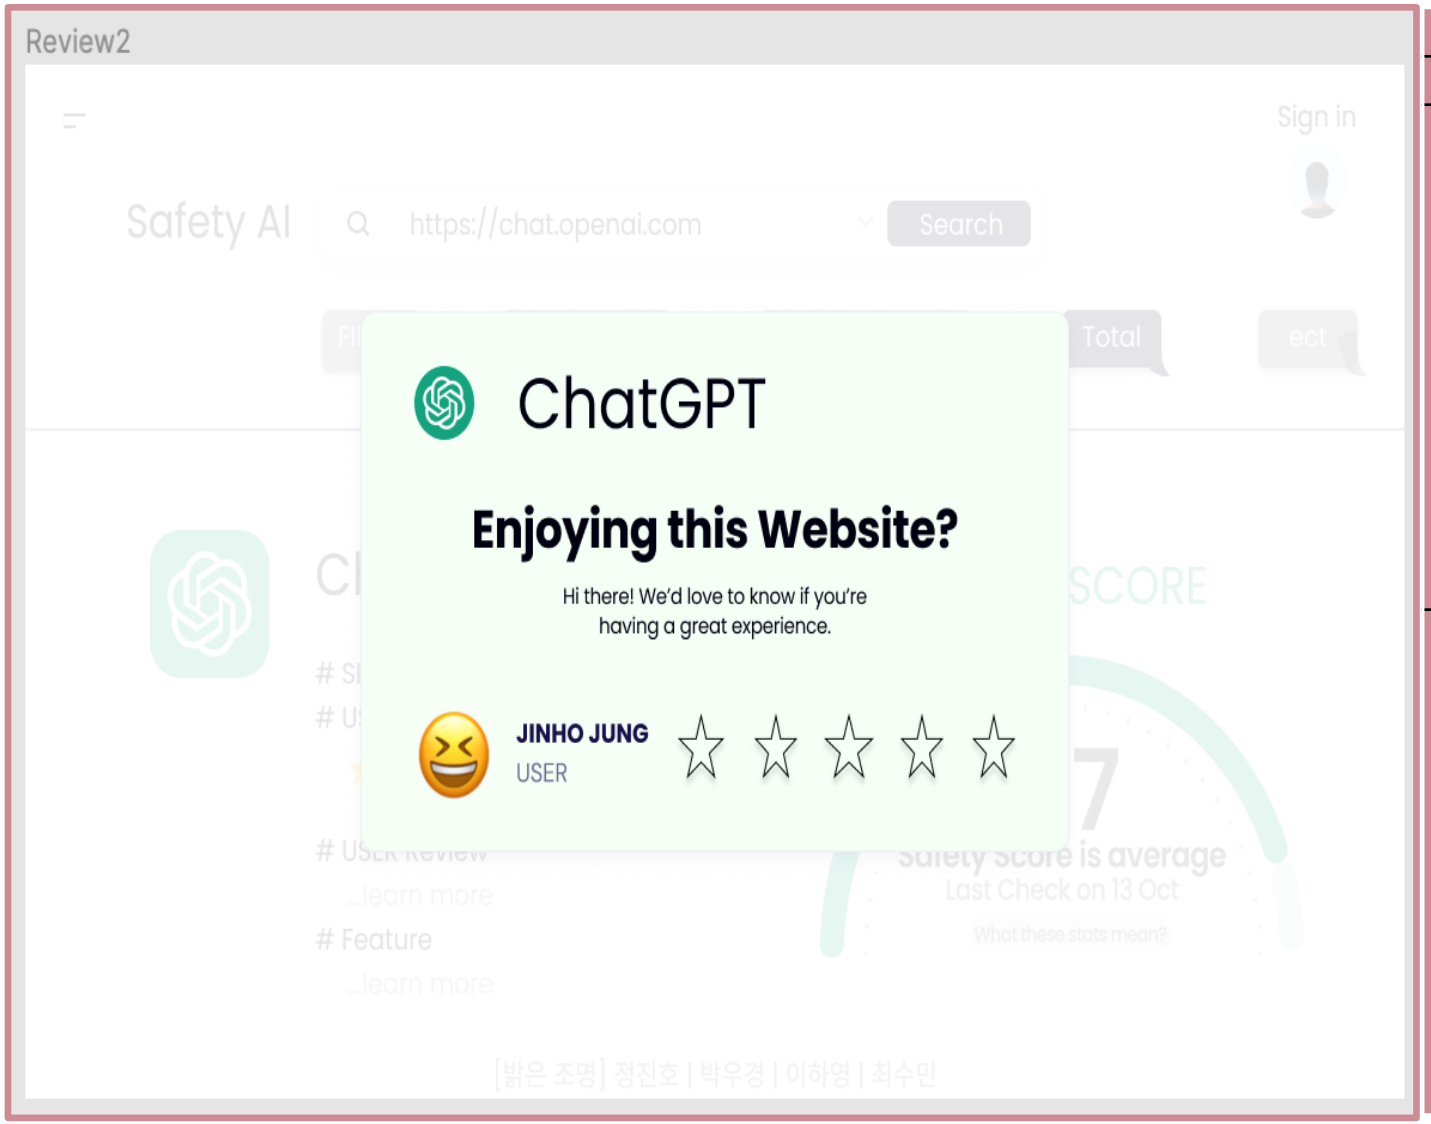

기능 번호	RV-04
기능 명	Review 작성 2
기능 설명	Safety AI 사이트의 리뷰 작성이 끝나면, 이용했던 **생성형 AI 사이트의 리뷰 작성**이 팝업으로 뜸 5점 만점으로 별의 개수를 정해준 다음, 리뷰를 작성할 수 있게 됨 이 리뷰는 **Community에 기록이 남으며, 모든 사람들과 공유**할 수 있음(프로토타입 단계 2-3 참고)
처리 내용	해당 사이트의 안전함을 확인 후 이동 시, 리뷰 작성 팝업이 표시 3 – 4 – 1 별점 부여 후, 리뷰 작성 3 – 4 – 2 작성 된 별점, 리뷰는 DB에 저장 3 – 4 – 3 저장된 별점, 리뷰 정보는 Community 페이지에서 조회 3 – 4 – 4 나중에 해당 페이지의 요청을 받으면, DB에서 작성한 리뷰를 조회, 결과를 화면에 출력(모든 사용자들이 확인 할 수 있음)

중부대학교

마무리

극심한 규제는 생성형 AI 개발에 부정적인 영향을 초래 할 수 있다.

또한, 이 규제가 생성형 AI **개발 회사에게만 전가 되어서도 아니 된다**.

즉, 생성형 AI를 **이용하는 소비자**들이 **잘 활용할 수 있도록** 도와주어야 한다.

그렇기에 현재 무수히 많이 존재하는 **생성형 AI를 판별할 수 있는 사이트**

즉, 밝은 조명이 개발 중인 **"Safety AI" 웹 사이트**에서 제공하는

"Safety Score"을 통해 간편하게 **위험도를 체크**하여 사용자들이

주의를 갖고 사용할 수 있도록 도와주는 것이 우리의 목표다.

이러한 사용이 생성형 AI의 올바른 개발로 나아갈 것이다.

중부대학교

감사합니다.