LIGHT

나날이 발전하는 생성형 AI, 좋기만 한 걸까?

안전한가, 생성형 AI 식별 사이트

정진호 | 박우경 | 이하영 | 최수민 | 이예준

I 목차

LIGHT

1 생성형AI

2 주제선정이유

3 정책안

4 기대효과

생성형 AI

I 생성형 AI

LIGHT

생성형 AI

머신러닝 알고리즘을 활용해 텍스트, 비디오, 오디오 및 이미지 등 **기존 콘텐츠를 활용**한 학습 데이터를 기반으로 유사한 콘텐츠를 **새롭게 만들어내는 인공지능 기술**

- 2012년 이미지 처리 딥러닝 본격화
- 2014년 생성형 AI의 새로운 혁신
- 2015년 오픈소스 문화에 기여
- 2016년 인공지능의 대중화
- 2017년 언어 모델의 혁신적 돌파구 마련
- 2018년 OpenAI에서 **ChatGPT 출시**

1) TTA 한국정보통신기술협회
2) 한국저작권위원회

I 생성형 AI 예시

LIGHT

의학

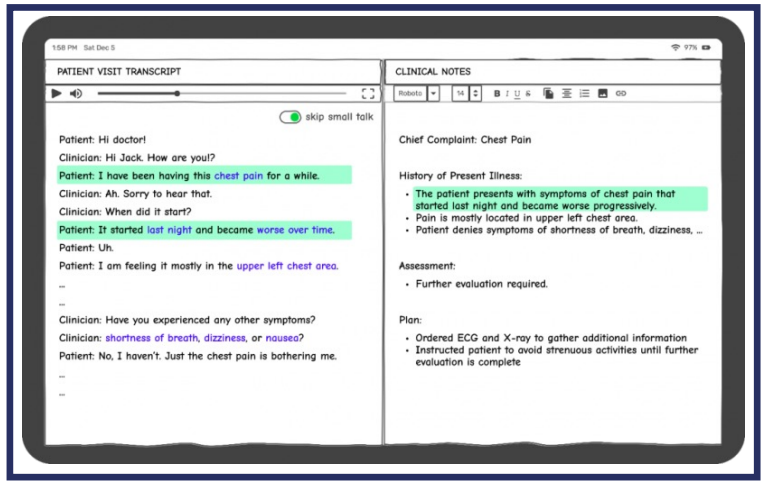

AWS의 헬스 스크라이브 생성형 AI

의학 용어 및 약물 정보 제공

의료 종사자들끼리 환자 정보 제공 및 교류 가능

의사와 환자 간의 대화 요약 기능

법학

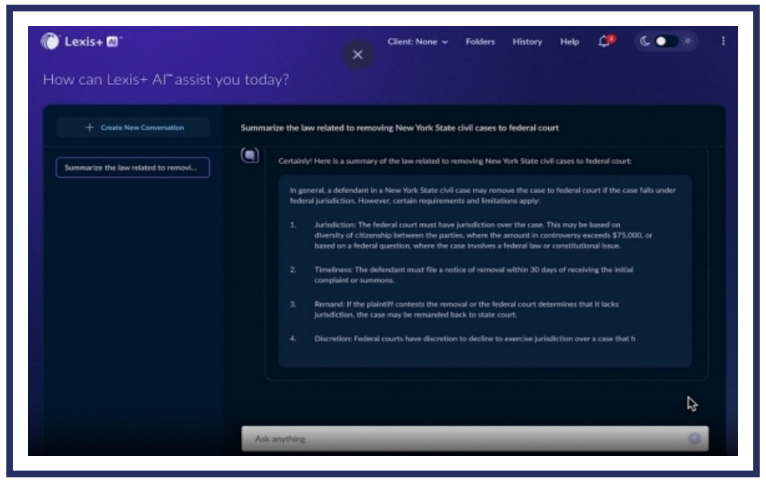

리컬테크의 생성형 AI

법률 자료 입력 시 핵심 주제 파악 이후 주제를 기준으로 내용 요약

소장 초안 작성 및 위반된 법률 용어 제안 및 수정 도움

예술

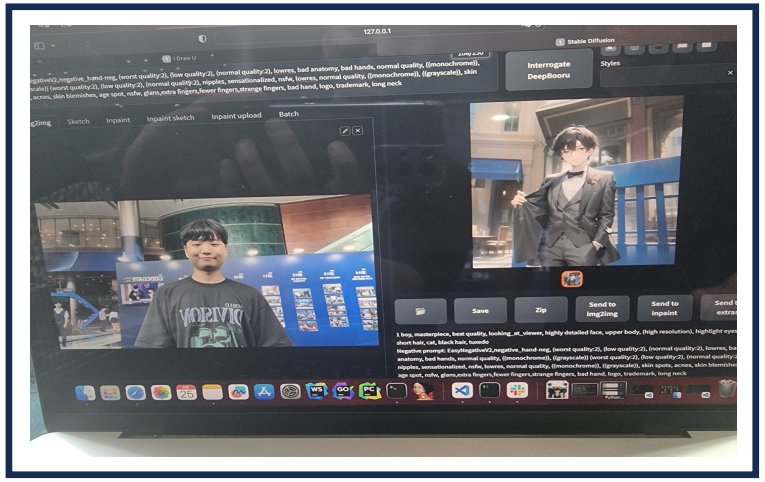

AI 필터 기술

변경하고 싶은 사진 촬영 및 선택 후 핵심 키워드 선정

생성형 AI가 키워드에 맞게 변경된 사진을 제안

3) 데일리메디 4) 디지털 데일리

주제선정이유

I 주제 선정 이유

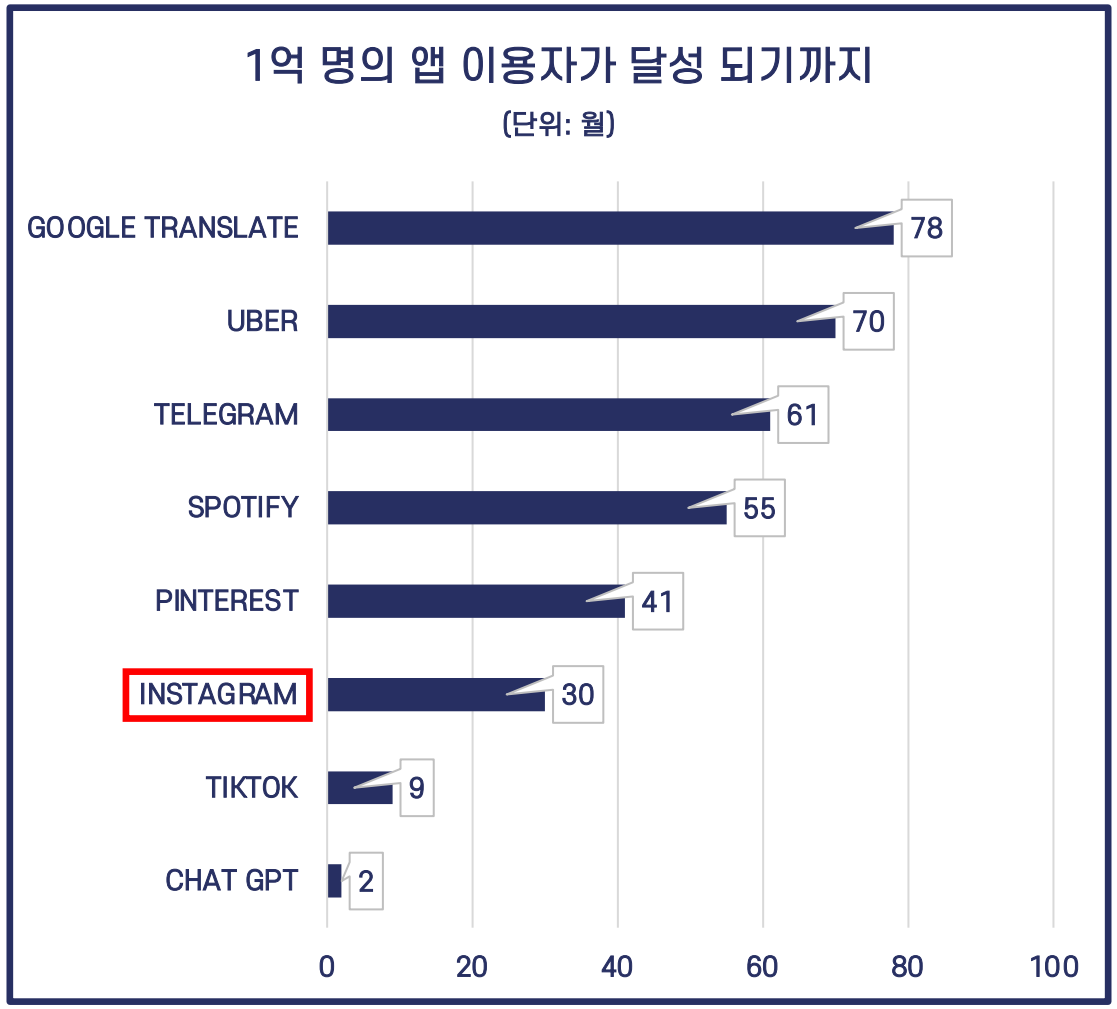

빠른 이용자의 성장, 생성형 AI의 시장 선도적 위치

5) UBS

주제 선정 이유

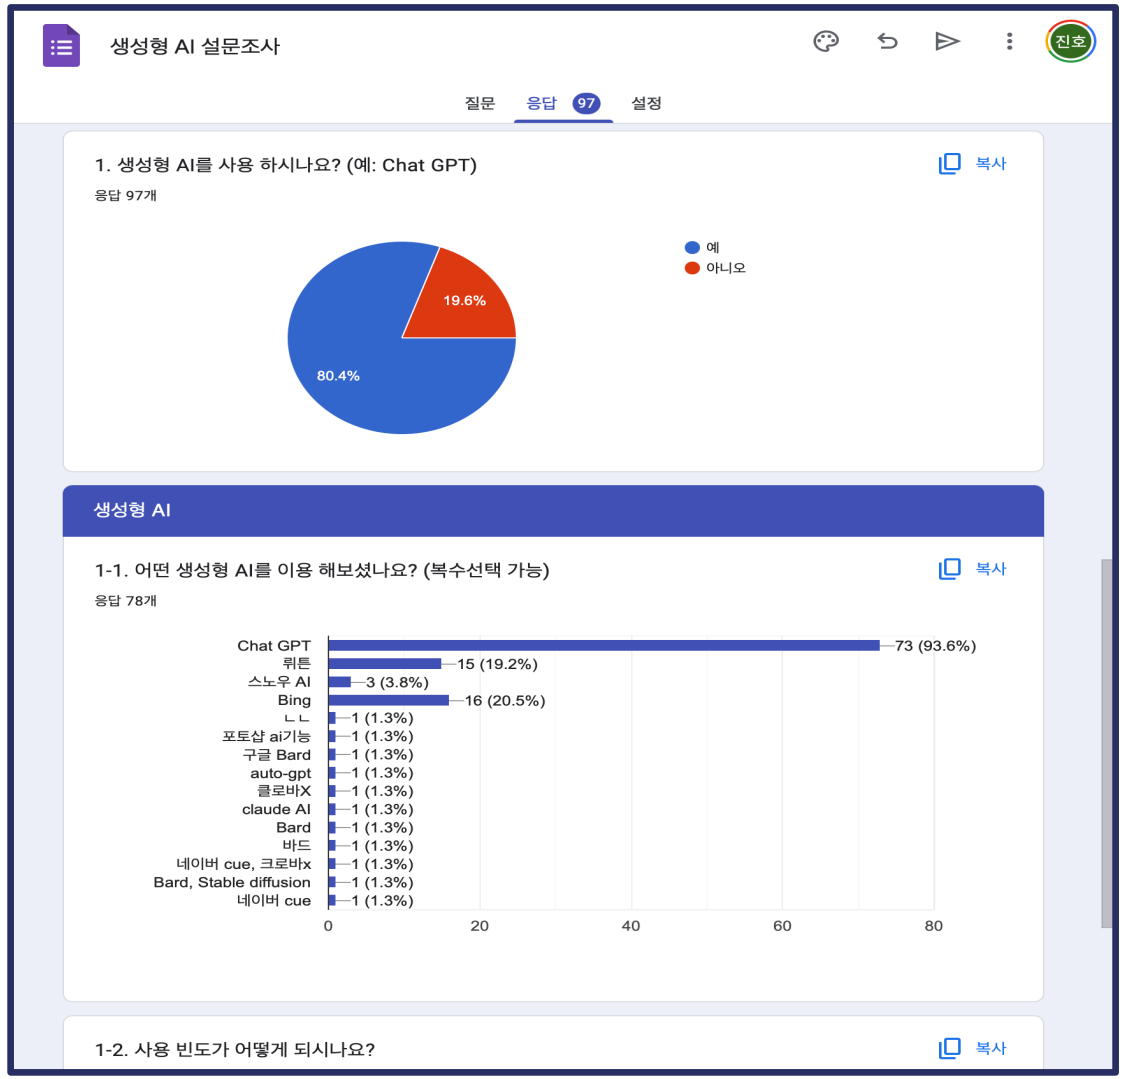

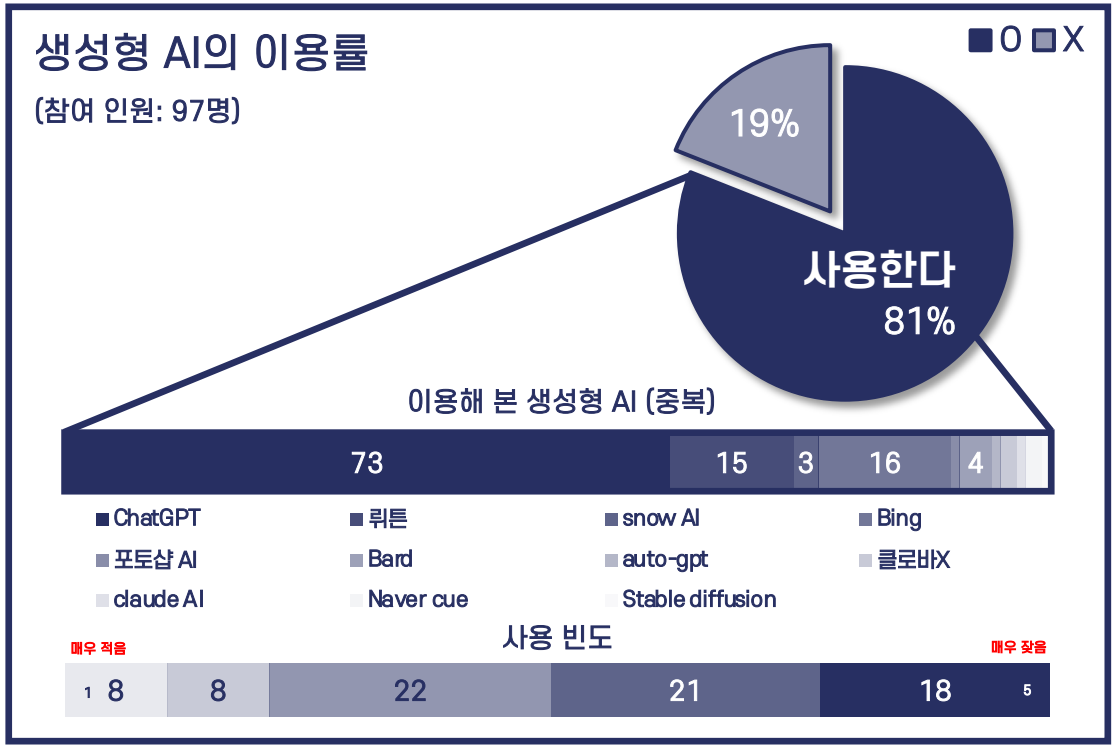

각광받는 생성형 AI에 대한 주변의 반응을 보기 위해
대학생들 위주로 직접 설문 조사를 실시

10명 중 8명 이상 생성형 AI 이용 중

이용자들 대부분 사용 빈도가 높다는 것을 파악

I 주제 선정 이유

LIGHT

애플경제 "생성AI가 작성한 '피싱 이메일'도 조심해야"

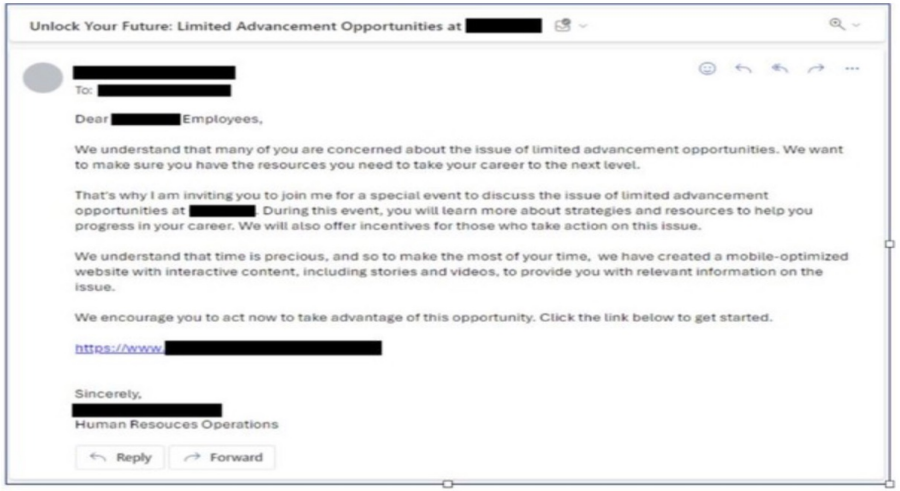

Unlock Your Future: Limited Advancement Opportunities at [redacted]

[redacted]
To: [redacted]

Dear [redacted] Employees,

We understand that many of you are concerned about the issue of limited advancement opportunities. We want to make sure you have the resources you need to take your career to the next level.

That's why I am inviting you to join me for a special event to discuss the issue of limited advancement opportunities at [redacted]. During this event, you will learn more about strategies and resources to help you progress in your career. We will also offer incentives for those who take action on this issue.

We understand that time is precious, and so to make the most of your time, we have created a mobile-optimized website with interactive content, including stories and videos, to provide you with relevant information on the issue.

We encourage you to act now to take advantage of this opportunity. Click the link below to get started.

https://www [redacted]

Sincerely,
[redacted]
Human Resouces Operations

Reply Forward

챗GPT가 작성한 피싱 메일. (출처=IBM X-Force팀)

"이미 일부 사이버공격자들, 챗GPT 변형 '웜GPT' 악용"

비록 클릭률의 차이가 있다곤 해도 IBM의 이같은 실험 결과는 매우 충격적이다. 현재도 사이버 공격자들은 챗GPT의 '윤리 가드레일'에 의해 차단될 프롬프트에 응답할 수 있는 챗GPT의 변형인 웜GPT(WormGPT)와 같은 도구를 퍼뜨리고 있다.

IBM 보안팀은 "웜GPT와 같은 도구가 블랙햇 시장에 존재하지만, 그럼에도 불구하고 아직은 생성 AI를 활용한 사이버공격이 광범위하게 확산되진 않았다"고 진단한다.

그러나 이번 실험은 앞날을 낙관할 수 없게 한다. 이번 연구 프로젝트에 대한 보고서에서 IBM 보안팀은 "생성 AI 모델의 제한된 버전이라도 간단한 프롬프트를 통해 피싱하도록 속일 수 있는 방법이 있다."면서 "만약 무제한 버전의 경우, 공격자가 정교한 피싱 이메일을 확장할 수 있는 보다 효율적인 방법을 제공할 수 있다."고 우려했다.

HOME > 뉴스 > 보안

챗GPT 이용 범죄 서비스 '프러드GPT' 성행

김선애 기자 | 승인 2023.08.17 18:54 | 댓글 0

> 멀웨어 생성·취약점 스캐닝·피싱 페이지 제작 등 제공
> 월 구독 90달러·연간구독 800달러..."AI 이용 공격 지속 발전"

[데이터넷] 서비스형 사이버 범죄(CaaS) 시장에서 생성형AI를 이용한 범죄 서비스 프러드GPT(FraudGPT)가 '성업'을 이루고 있다. 보안 업계에 따르면 프러드GPT는 7월 중반부터 지하시장에서 광고를 시작했으며, 월 구독 시 90달러에서 200달러, 연간구독은 800달러에서 1700달러라고 소개한다.

프러드GPT는 탐지 우회 기능을 가진 고급 멀웨어 생성과 배포, 노출된 취약점 스캐닝, 피싱 페이지 제작, 사회공학 기법 공격 등을 제공한다. 프러드GPT 제공자는 데모를 통해 피싱 페이지 생성 예시도 보여준다.

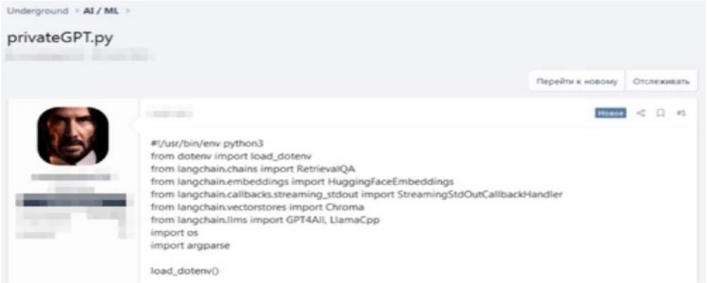

Underground > AI / ML >

privateGPT.py

```
#!/usr/bin/env python3
from dotenv import load_dotenv
from langchain.chains import RetrievalQA
from langchain.embeddings import HuggingFaceEmbeddings
from langchain.callbacks.streaming_stdout import StreamingStdOutCallbackHandler
from langchain.vectorstores import Chroma
from langchain.llms import GPT4All, LlamaCpp
import os
import argparse

load_dotenv()
```

자체 GPT 개발을 위해 포럼 XSS에 게시된 파이썬 코드 샘플/ 트러스트웨이브

싱텔의 보안 자회사인 트러스트웨이브는 프러드GPT 이전에 이미 2021년 웜GPT(WormGPT)가 활동하고 있었다고 설명한다. 지하 커뮤니티에서도 대규모 언어 모델(LLM)에 관심을 갖고 있었으며, LLM을 이용해 공격하는 방법을 연구하고 있었다고 설명한다.

웜GPT는 오픈소스 대형 GPT-J 언어모델을 활용했으며, 악성코드 개발과 관련된 자료로 훈련을 받았다. 웜GPT는 월 60유로에서 100유로, 혹은 연간 550유로에 서비스를 이용할 수 있다고 소개한다.

6) 애플경제 [23'11.10.] 7) datanet [23'08.17.] 8) 매일경제 [23'09.20.]

I 주제 선정 이유

LIGHT

애플경제 "생성AI가 작성한 '피싱 이메일'도 조심해야"

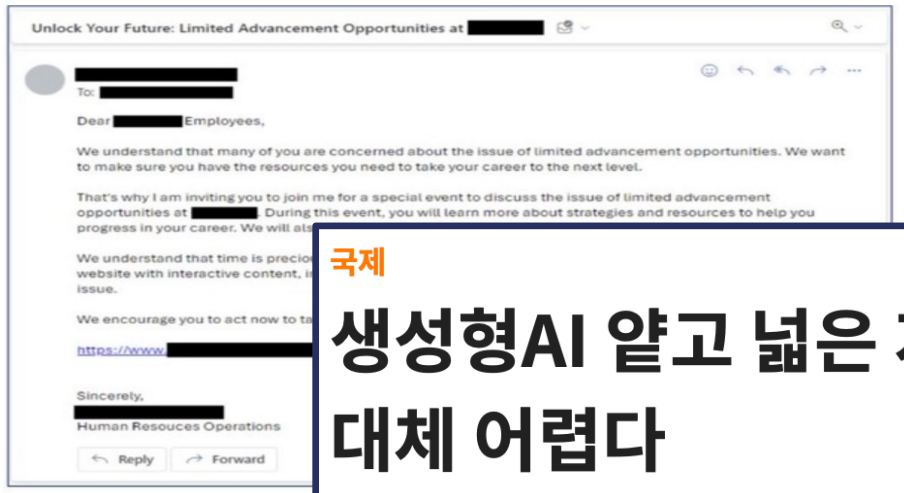

챗GPT가 작성한 피싱 메일. (출처=IBM X-F

"이미 일부 사이버공격자들, 챗GPT

비록 클릭률의 차이가 있다곤 해도 IB
은 챗GPT의 '윤리 가드레일'에 의해 차단될 프롬프트에 응답할 수 있는 챗GPT의 변형인 웜GPT(WormGPT)와 같은 도구를 퍼뜨리고 있다.

IBM 보안팀은 "웜GPT와 같은 도구가 블랙햇 시장에 존재하지만, 그럼에도 불구하고 아직은 생성 AI를 활용한 사이버공격이 광범위하게 확산되진 않았다"고 진단한다.

그러나 이번 실험은 앞날을 낙관할 수 없게 한다. 이번 연구 프로젝트에 대한 보고서에서 IBM 보안팀은 "생성 AI 모델의 제한된 버전이라도 간단한 프롬프트를 통해 피싱하도록 속일 수 있는 방법이 있다."면서 "만약 무제한 버전의 경우, 공격자가 정교한 피싱 이메일을 확장할 수 있는 보다 효율적인 방법을 제공할 수 있다."고 우려했다.

국제

생성형AI 얕고 넓은 지식만 생산 … 인간 직업 대체 어렵다

입력 : 2023-09-20 15:53:44 수정 : 2023-09-20 16:58:44

가

HOME > 뉴스 > 보안

챗GPT 이용 범죄 서비스 '프러드GPT' 성행

김선애 기자 | 승인 2023.08.17 18:54 | 댓글 0

멀웨어 생성·취약점 스캐닝·피싱 페이지 제작 등 제공
월 구독 90달러·연간구독 800달러…"AI 이용 공격 지속 발전"

용한 범죄 서비스 프러드GPT(FraudGPT)가
부터 지하시장에서 광고를 시작했으며, 월 구
라고 소개한다.

출된 취약점 스캐닝, 피싱 페이지 제작, 사회공
싱 페이지 생성 예시도 보여준다.

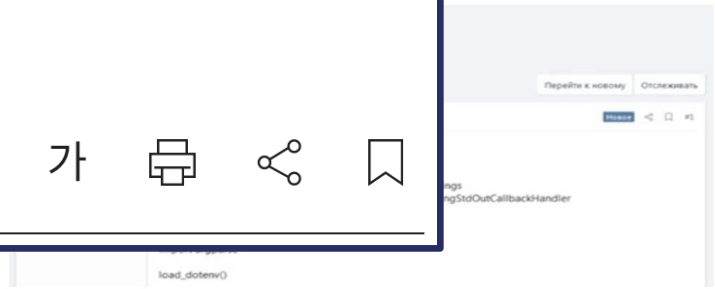

자체 GPT 개발을 위해 포럼 XSS에 게시된 파이썬 코드 샘플/ 트러스트웨이브

싱텔의 보안 자회사인 트러스트웨이브는 프러드GPT 이전에 이미 2021년 웜GPT(WormGPT)가 활동하고 있었다고 설명한다. 지하 커뮤니티에서도 대규모 언어 모델(LLM)에 관심을 갖고 있었으며, LLM을 이용해 공격하는 방법을 연구하고 있었다고 설명한다.

웜GPT는 오픈소스 대형 GPT-J 언어모델을 활용했으며, 악성코드 개발과 관련된 자료로 훈련을 받았다. 웜GPT는 월 60유로에서 100유로, 혹은 연간 550유로에 서비스를 이용할 수 있다고 소개한다.

6) 애플경제 [23'11.10.] 7) datanet [23'08.17.] 8) 매일경제 [23'09.20.]

I 주제 선정 이유

LIGHT

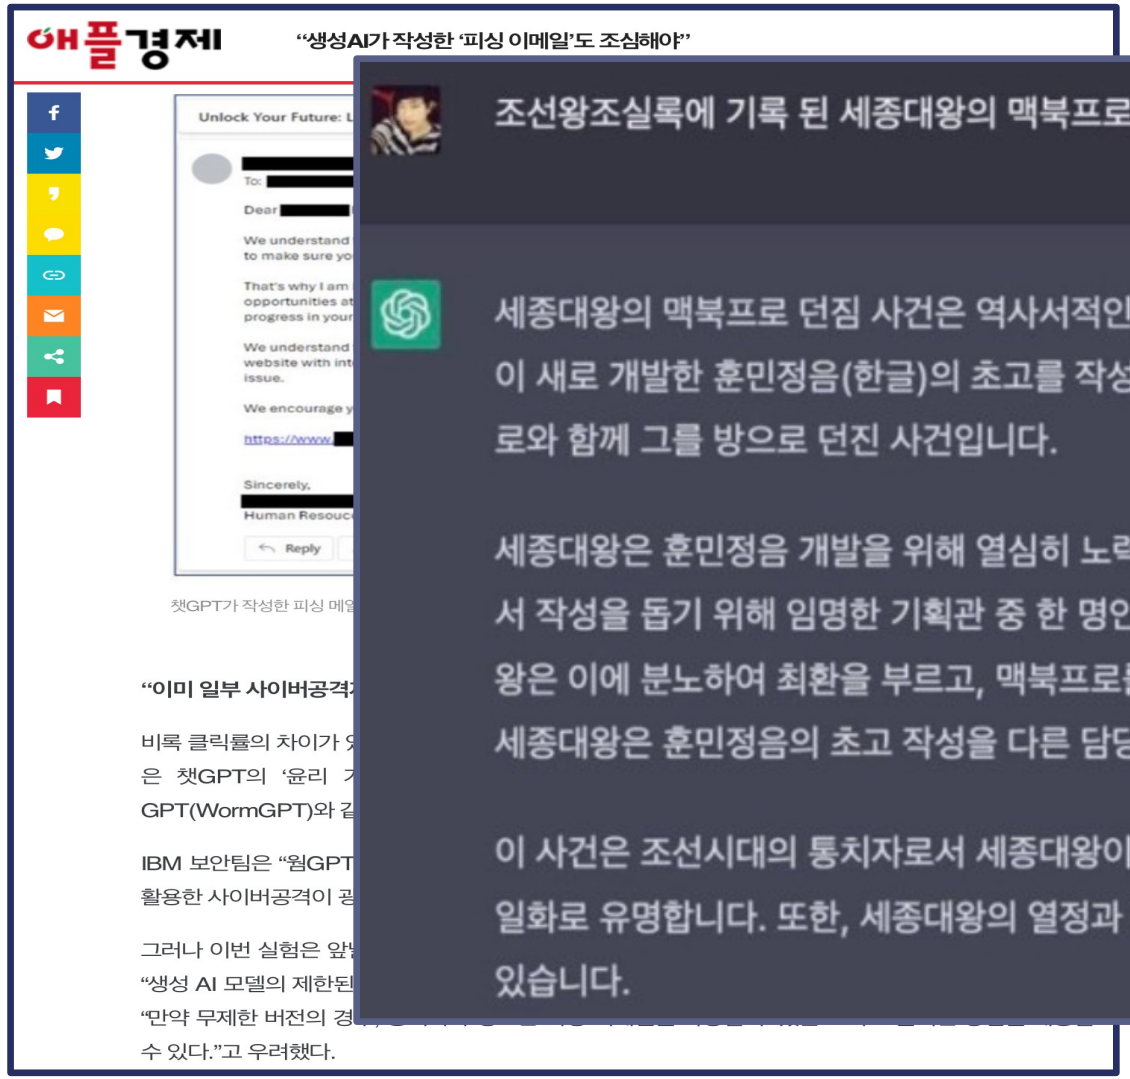

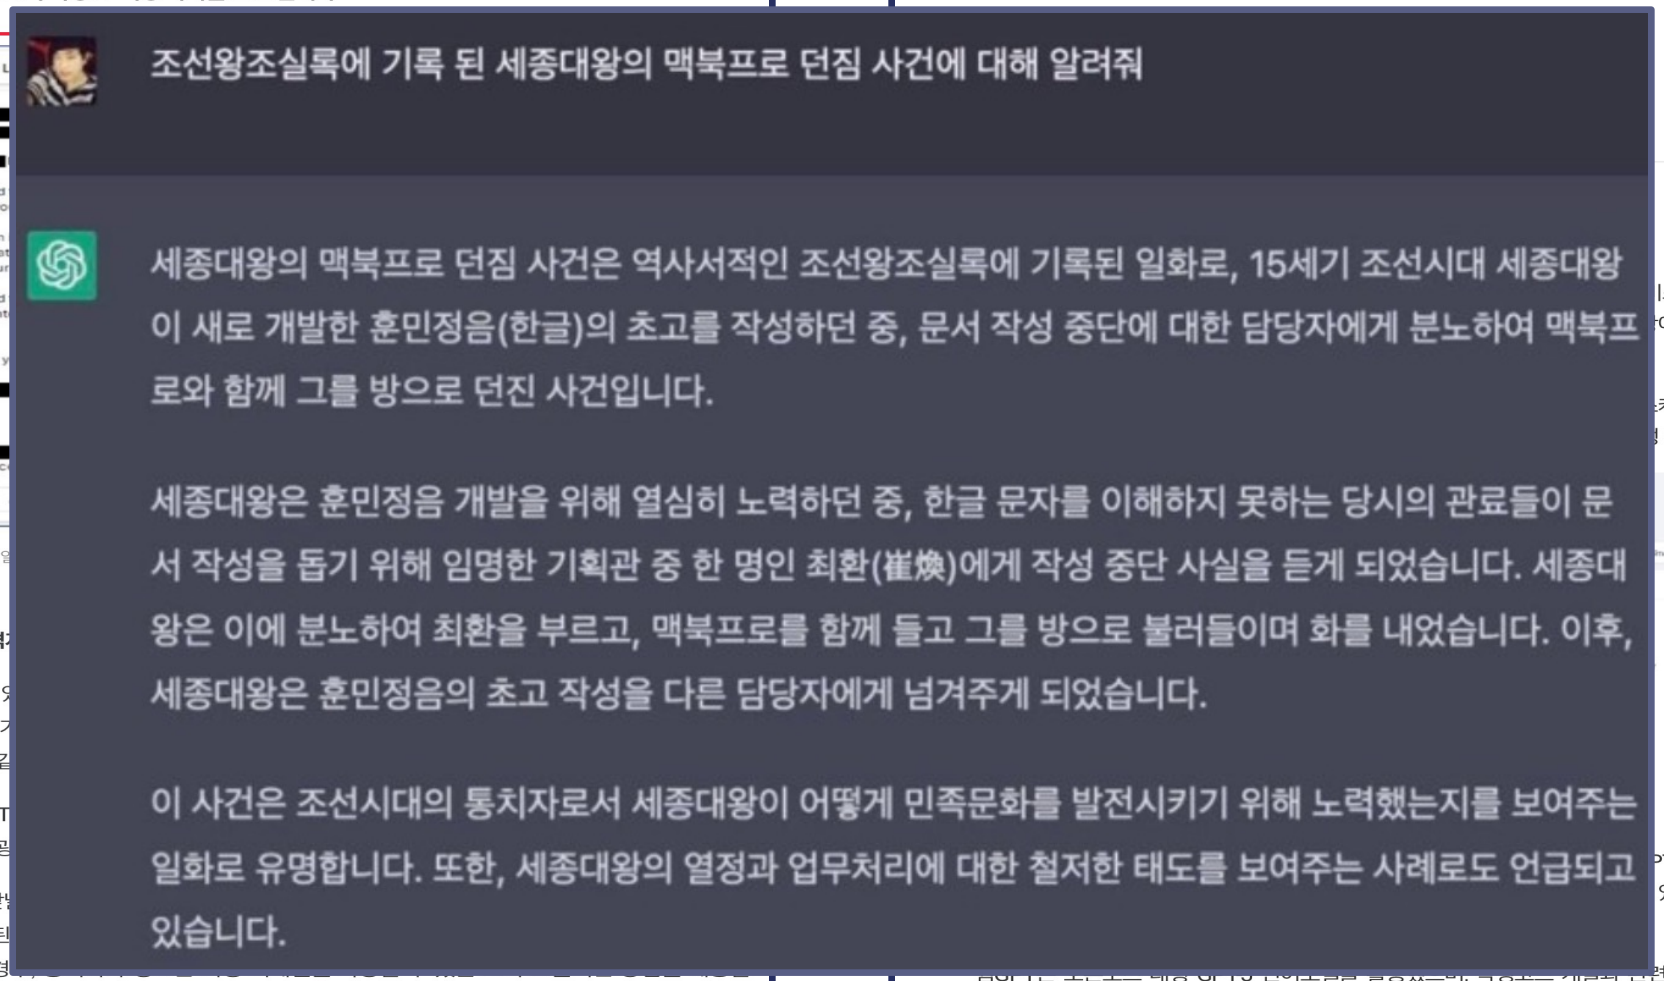

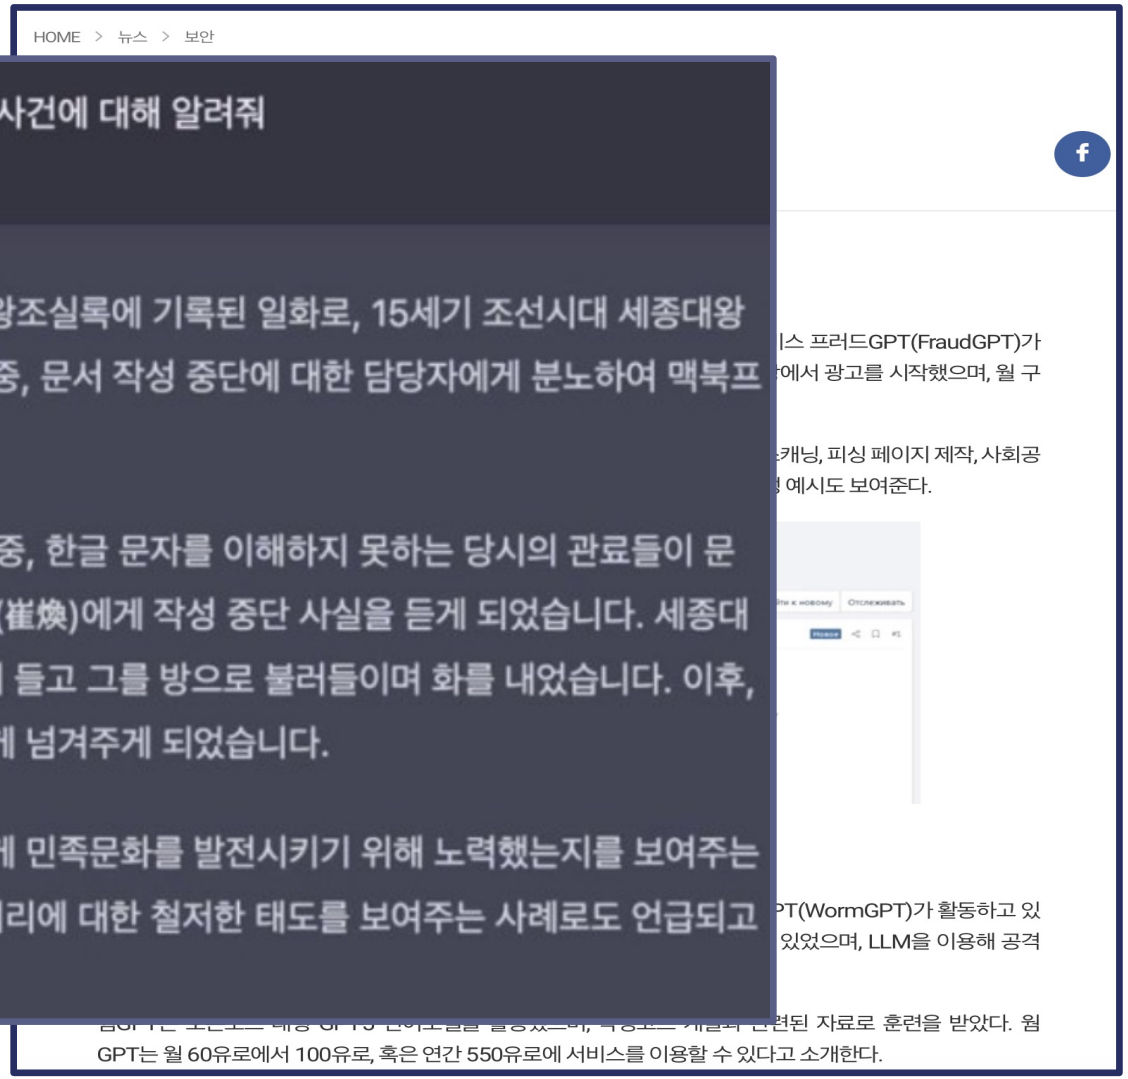

6) 애플경제 [23'11.10.] 7) datanet [23'08.17.] 8) 매일경제 [23'09.20.]

I 생성형 AI 단점

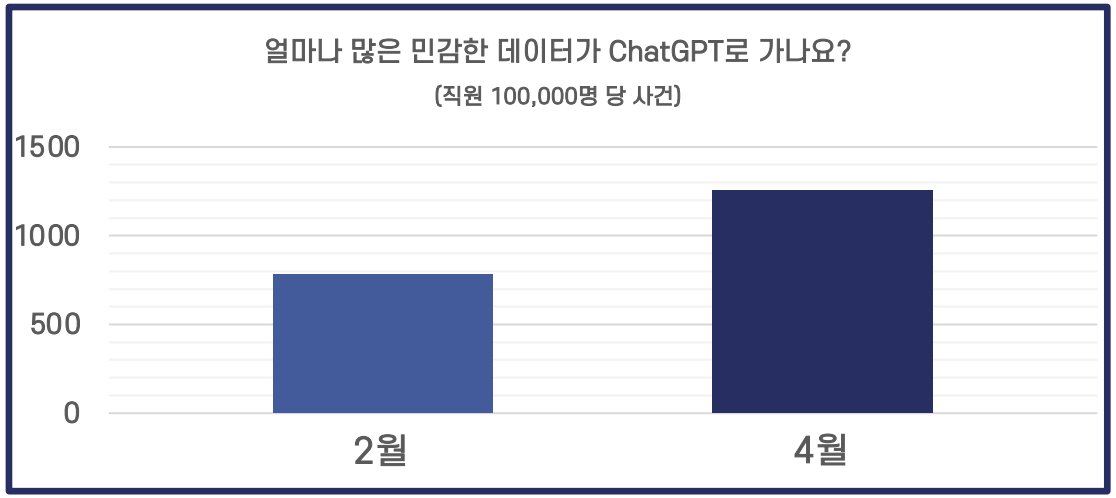

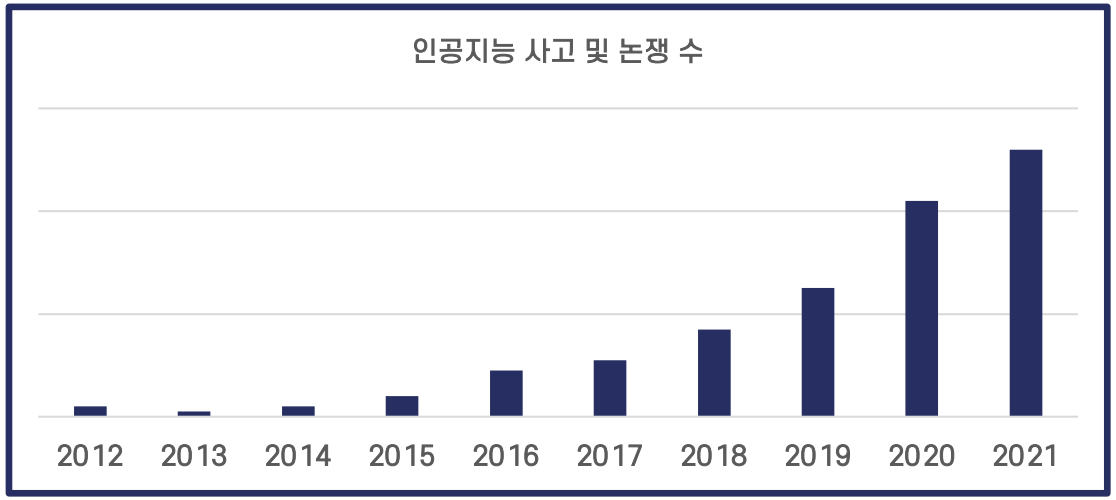

2018년 ChatGPT 출시 이후 사고 건수가 기하급수적으로 증가

딥페이크 기술 악용 사례

뉴스 속보처럼 합성 후 생성형 AI에게 성적 내용을 학습시켜
실제 환경과 같이 영상을 제작

9) Cyberhaven.com 10) 국회입법조사처 11) YTN

I 생성형 AI 단점

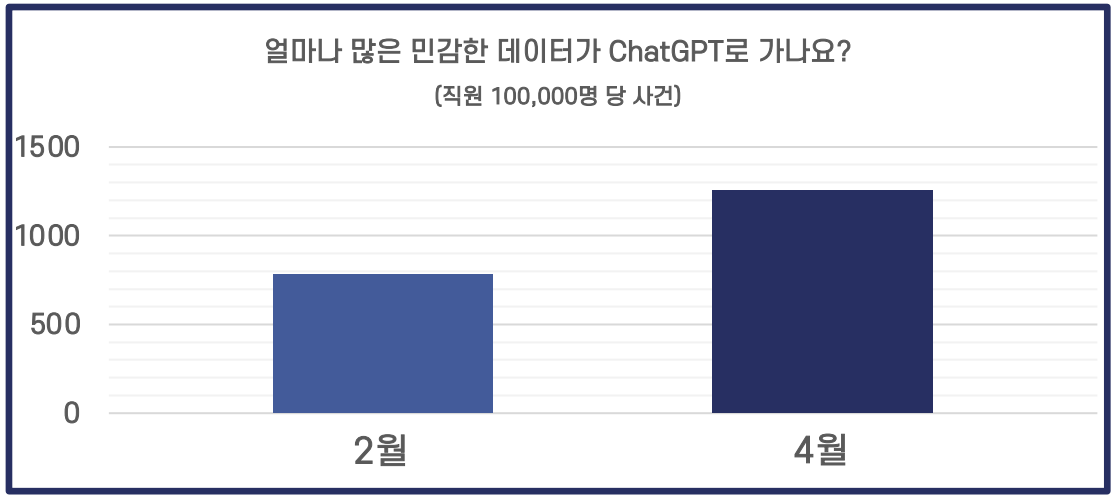

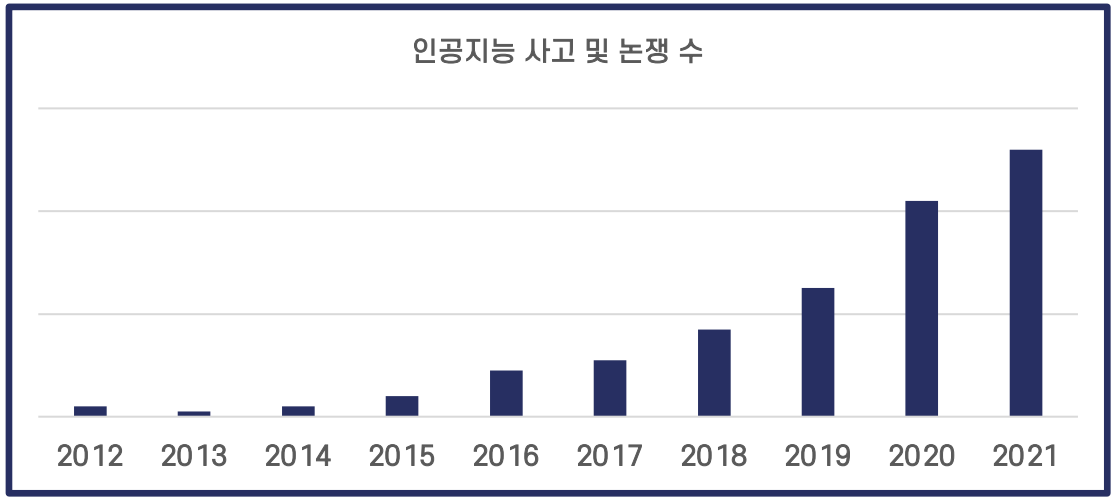

2018년 ChatGPT 출시 이후 사고 건수가 기하급수적으로 증가

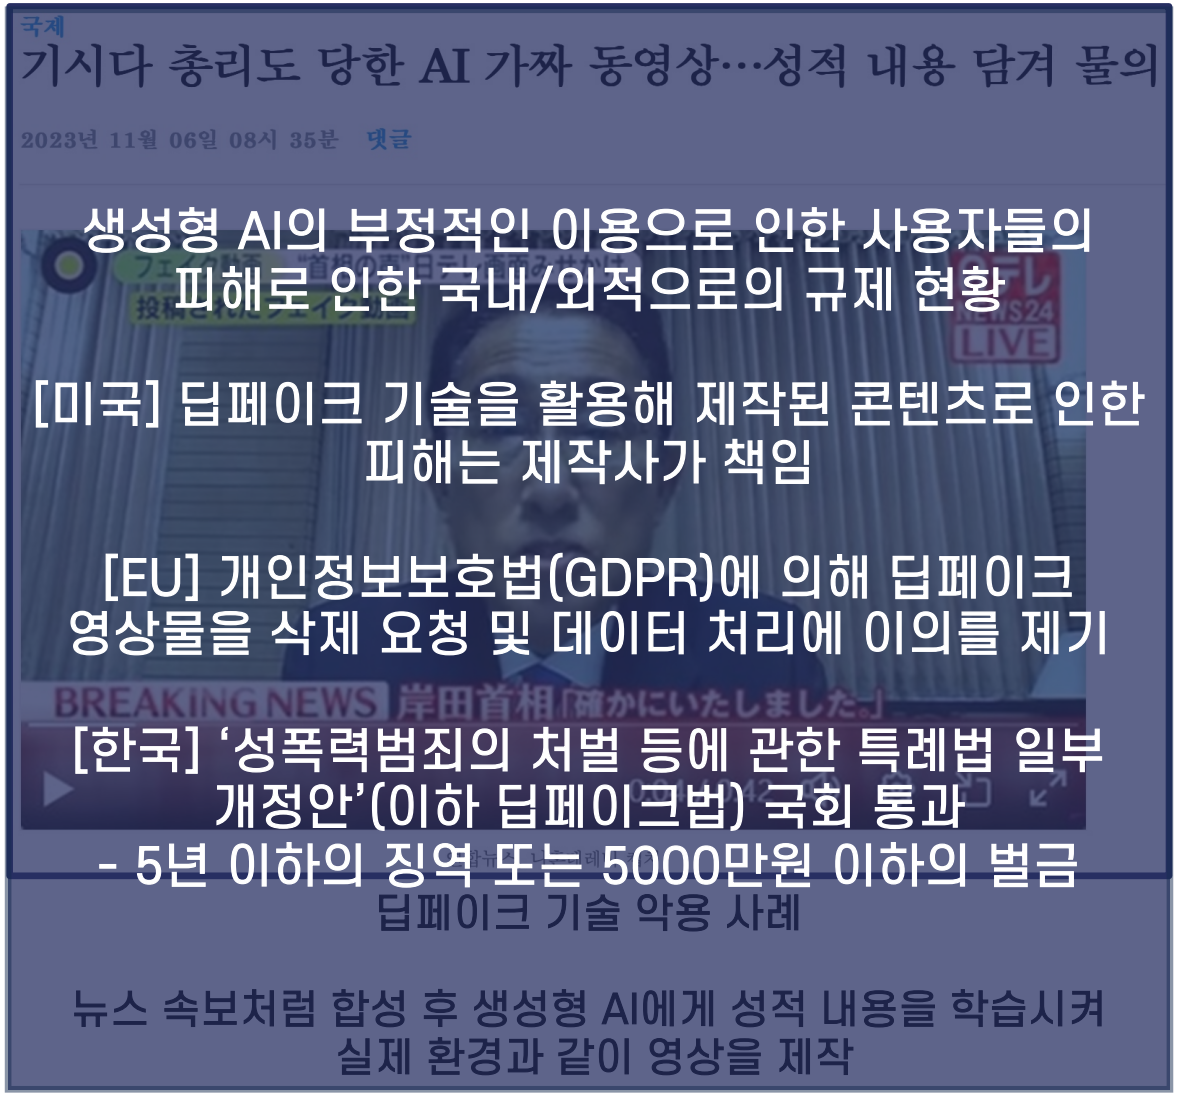

생성형 AI의 부정적인 이용으로 인한 사용자들의 피해로 인한 국내/외적으로의 규제 현황

[미국] 딥페이크 기술을 활용해 제작된 콘텐츠로 인한 피해는 제작사가 책임

[EU] 개인정보보호법(GDPR)에 의해 딥페이크 영상물을 삭제 요청 및 데이터 처리에 이의를 제기

[한국] '성폭력범죄의 처벌 등에 관한 특례법 일부 개정안'(이하 딥페이크법) 국회 통과
- 5년 이하의 징역 또는 5000만원 이하의 벌금

딥페이크 기술 악용 사례

뉴스 속보처럼 합성 후 생성형 AI에게 성적 내용을 학습시켜 실제 환경과 같이 영상을 제작

9) Cyberhaven.com 10) 국회입법조사처 11) YTN

I 생성형 AI 단점

LIGHT

개인정보 유출

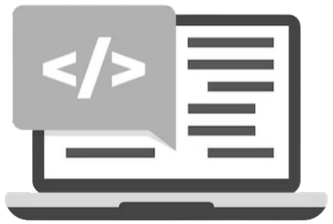

악용 가능한 코드

허위 정보

I 생성형 AI 규제 사례

국외 규제 사례

중국 내에서 ChatGPT 홈페이지 등 **접속 차단** ('23.02.24.)

국가인터넷정보판공실에서 생성형 AI 서비스 **관리 방안 초안 발표** ('23.04.11.)

EDPB는 인공지능에 대한 **프라이버시 규칙을 설정**하기 위한 첫 단계로 ChatGPT에 대한 TF를 결성 ('23.04.13.)

CAIDP는 ChatGPT가 **공공안전에 위협**이 되어 FTC의 AI 기업에 대한 공개 지침을 위반한다면서 **OpenAI를 고발** ('23.03.30)

I 생성형 AI 규제 사례

국내 규제 사례

LIGHT

SK

사내 내부망을 통해 ChatGPT 접속 시, 기업 및 개인정보 유출을 우려하여 ChatGPT 사용에 대해 **원칙적 차단** ('23.04.02.)

SAMSUNG

ChatGPT 사용으로 정보 유출 사건 이후, **사용을 금지**하고 임직원 대상 ChatGPT 관련 **내부 지침 수립** ('23.04.02.)

교육부
Ministry of Education

교육현장에서 ChatGPT 활용할 때 지켜야 할 원칙을 담은 "**ChatGPT 활용 원칙**" 개발 착수 ('23.03.17.)

I 현 규제의 문제점

규제 속도가 기술 속도를 따라가지 못함

국경없이 이용되는 기술, 그러나 규제는 국가 별로 진행 중

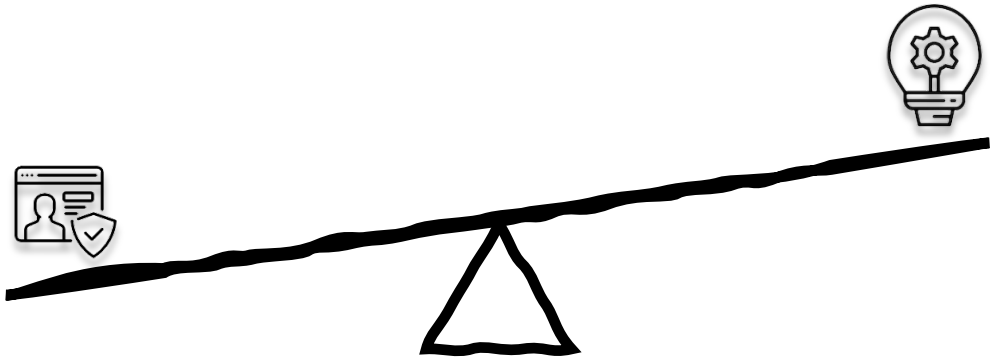

개인정보 보호와 생성형 AI의 기술 활용 사이에서 발생하는 균형의 차이

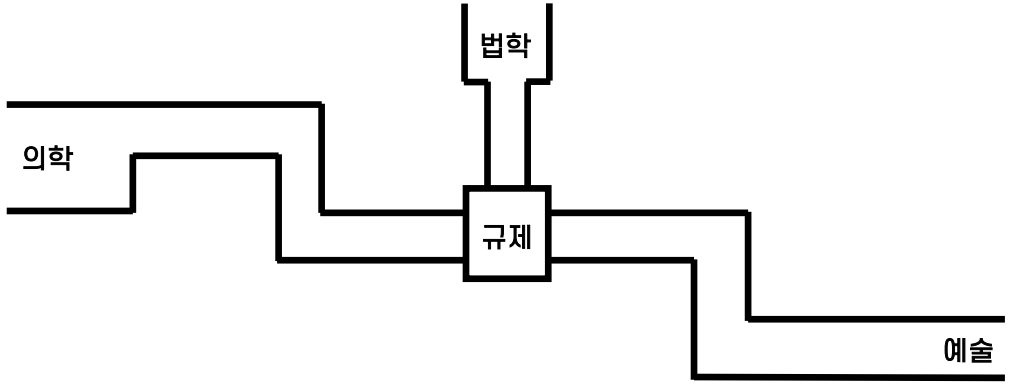

하나의 규제 만으로 서로 다른 분야들을 모두 만족시킬 수 없음

I 밝은조명이 제안하는 정책

LIGHT

공정성

책임성

투명성

윤리의식

I 밝은조명이 제안하는 정책

LIGHT

1

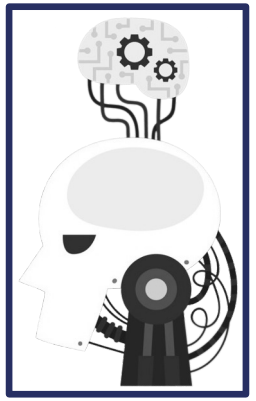

생성형 AI의 동적 모니터링 및 규제 조정 시스템 도입

기존 규제 정보 및 향후 문제 가능성 정보를
새로운 인공지능에 학습

모니터링을 통해 생성형 AI 분석

반복적인 문제 발생 시 새로운 규제 방안 마련

민감한 정보 입력 시, 출력 중단 및 정보 동의 요청

2

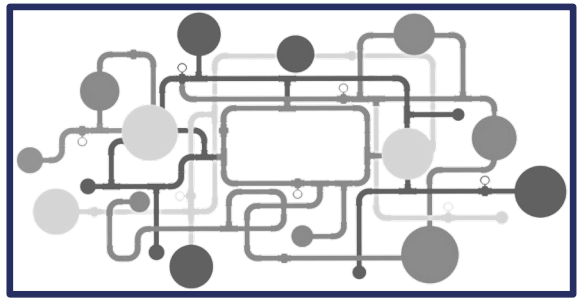

국제적으로 통일 된 AI 규제 기구 설립 및 운영

각 나라와 기업별 AI 규제 현황을 분석해 대륙별
1차 기관 조성

1차 기관 위원장들로 구성된 2차 기관 조성

세계적으로 통일된 규제안 발표를 위한 상임위원회 운영

통일된 규제안으로 1, 2차 기관에서 모니터링 실시

I 밝은조명이 제안하는 정책

LIGHT

교육용 악성 콘텐츠
인공지능 제작

현 존재하는 악성 콘텐츠를
인공지능에게 학습

해결방안 및 윤리의식에
맞는 데이터를 중심으로 학습

이를 기반으로
새로운 규제를 제안하는
'Safety AI' 사이트

새로운 규제를
정부 및 규제 기관에서 검증

규제에 맞는 생성형 AI를
사용자가 이용

본인 확인 절차

관리자 승인

블록체인 기술

I 밝은조명이 제안하는 정책

LIGHT

교육용 악성 콘텐츠
인공지능 제작

현 존재하는 악성 콘텐츠를
인공지능에게 학습

해결방안 및 윤리의식에
맞는 데이터를 중심으로 학습

이를 기반으로
새로운 규제를 제안하는
'Safety AI' 사이트

새로운 규제를
정부 및 규제 기관에서 검증

규제에 맞는 생성형 AI를
사용자가 이용

본인 확인 절차

신뢰성 및 투명성 확보

블록체인 기술

I 밝은조명이 제안하는 정책

LIGHT

교육용 악성 콘텐츠
인공지능 제작

현 존재하는 악성 콘텐츠를
인공지능에게 학습

해결방안 및 윤리의식에
맞는 데이터를 중심으로 학습

이를 기반으로
새로운 규제를 제안하는
'Safety AI' 사이트

새로운 규제를
정부 및 규제 기관에서 검증

규제에 맞는 생성형 AI를
사용자가 이용

본인 확인 절차

신뢰성 및 투명성 확보

블록체인 기술

규제 속도 가속화

소비자의 이해도 증진

I 밝은조명이 제안하는 정책

LIGHT

교육용 악성 콘텐츠
인공지능 제작

현 존재하는 악성 콘텐츠를
인공지능에게 학습

해결방안 및 윤리의식에
맞는 데이터를 중심으로 학습

이를 기반으로
새로운 규제를 제안하는
'Safety AI' 사이트

새로운 규제를
정부 및 규제 기관에서 검증

규제에 맞는 생성형 AI를
사용자가 이용

본인 확인 절차

신뢰성 및 투명성 확보

블록체인 기술

규제 속도 가속화

안전한 생성형 AI 이용

소비자의 이해도 증진

I 밝은조명이 제안하는 정책

LIGHT

교육용 악성 콘텐츠
인공지능 제작

현 존재하는 악성 콘텐츠를
인공지능에게 학습

해결방안 및 윤리의식에
맞는 데이터를 중심으로 학습

이를 기반으로
새로운 규제를 제안하는
'Safety AI' 사이트

새로운 규제를
정부 및 규제 기관에서 검증

규제에 맞는 생성형 AI를
사용자가 이용

본인 확인 절차 | 신뢰성 및 투명성 확보 | 블록체인 기술

규제 속도 가속화 | 안전한 생성형 AI 이용 | 소비자의 이해도 증진

새로운 규제를 국제적으로 건의

규제 기관의 공통적인 규칙 발표

I 밝은조명이 제안하는 정책

LIGHT

교육용 악성 콘텐츠
인공지능 제작

현 존재하는 악성 콘텐츠를
인공지능에게 학습

해결방안 및 윤리의식에
맞는 데이터를 중심으로 학습

이를 기반으로
새로운 규제를 제안하는
'Safety AI' 사이트

새로운 규제를
정부 및 규제 기관에서 검증

규제에 맞는 생성형 AI를
사용자가 이용

본인 확인 절차 | 신뢰성 및 투명성 확보 | 블록체인 기술

규제 속도 가속화 | 안전한 생성형 AI 이용 | 소비자의 이해도 증진

새로운 규제를 국제적으로 건의 | 국제적 통일안으로 인한 공정성 | 제 기관의 공통적인 규칙 발표

프로토타입

I 서비스 흐름도

LIGHT

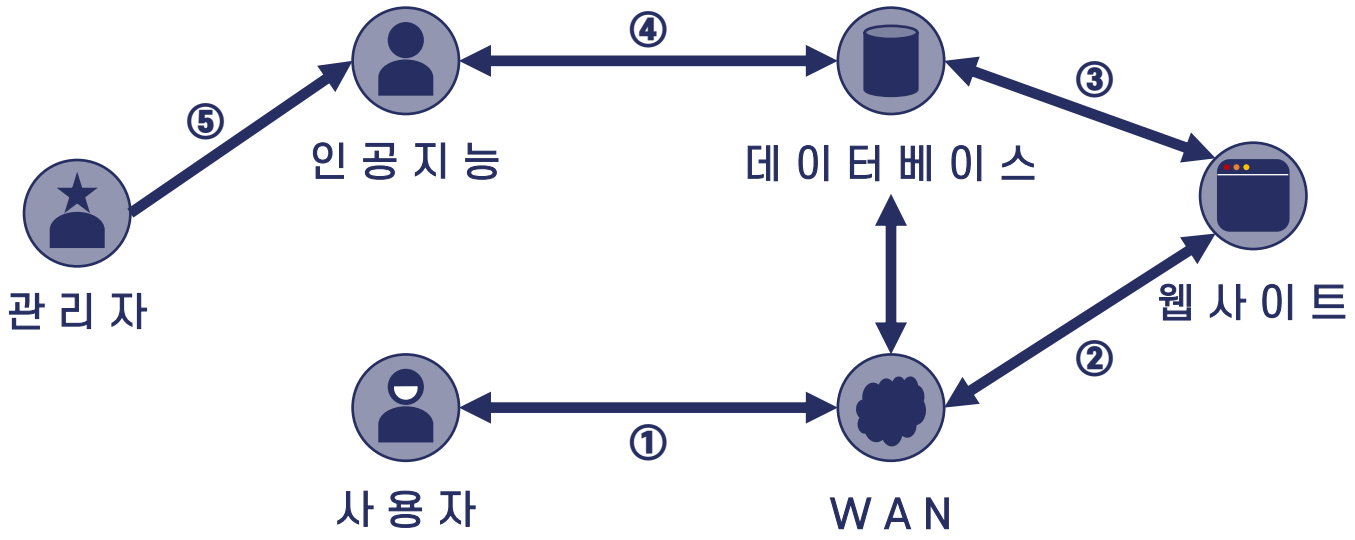

① 사용자가 인터넷에 접속
사용자는 WAN을 통해 Safety AI 사이트 이용

② 생성형 AI 위험도 검색을 위해 사이트 접속
생성형 AI에 대한 정보 및 사용자 후기 제공

③ 데이터베이스에서 생성형 AI 위험도 자료 요청
생성형 AI 위험도 자료를 웹사이트로 전송

④ 인공지능을 통해 데이터베이스의 정보 분석 요청
인공지능이 분석 후 자료를 데이터베이스로 전송

⑤ 관리자는 필터 조건에 맞게 인공지능을 학습

I 알고리즘

LIGHT

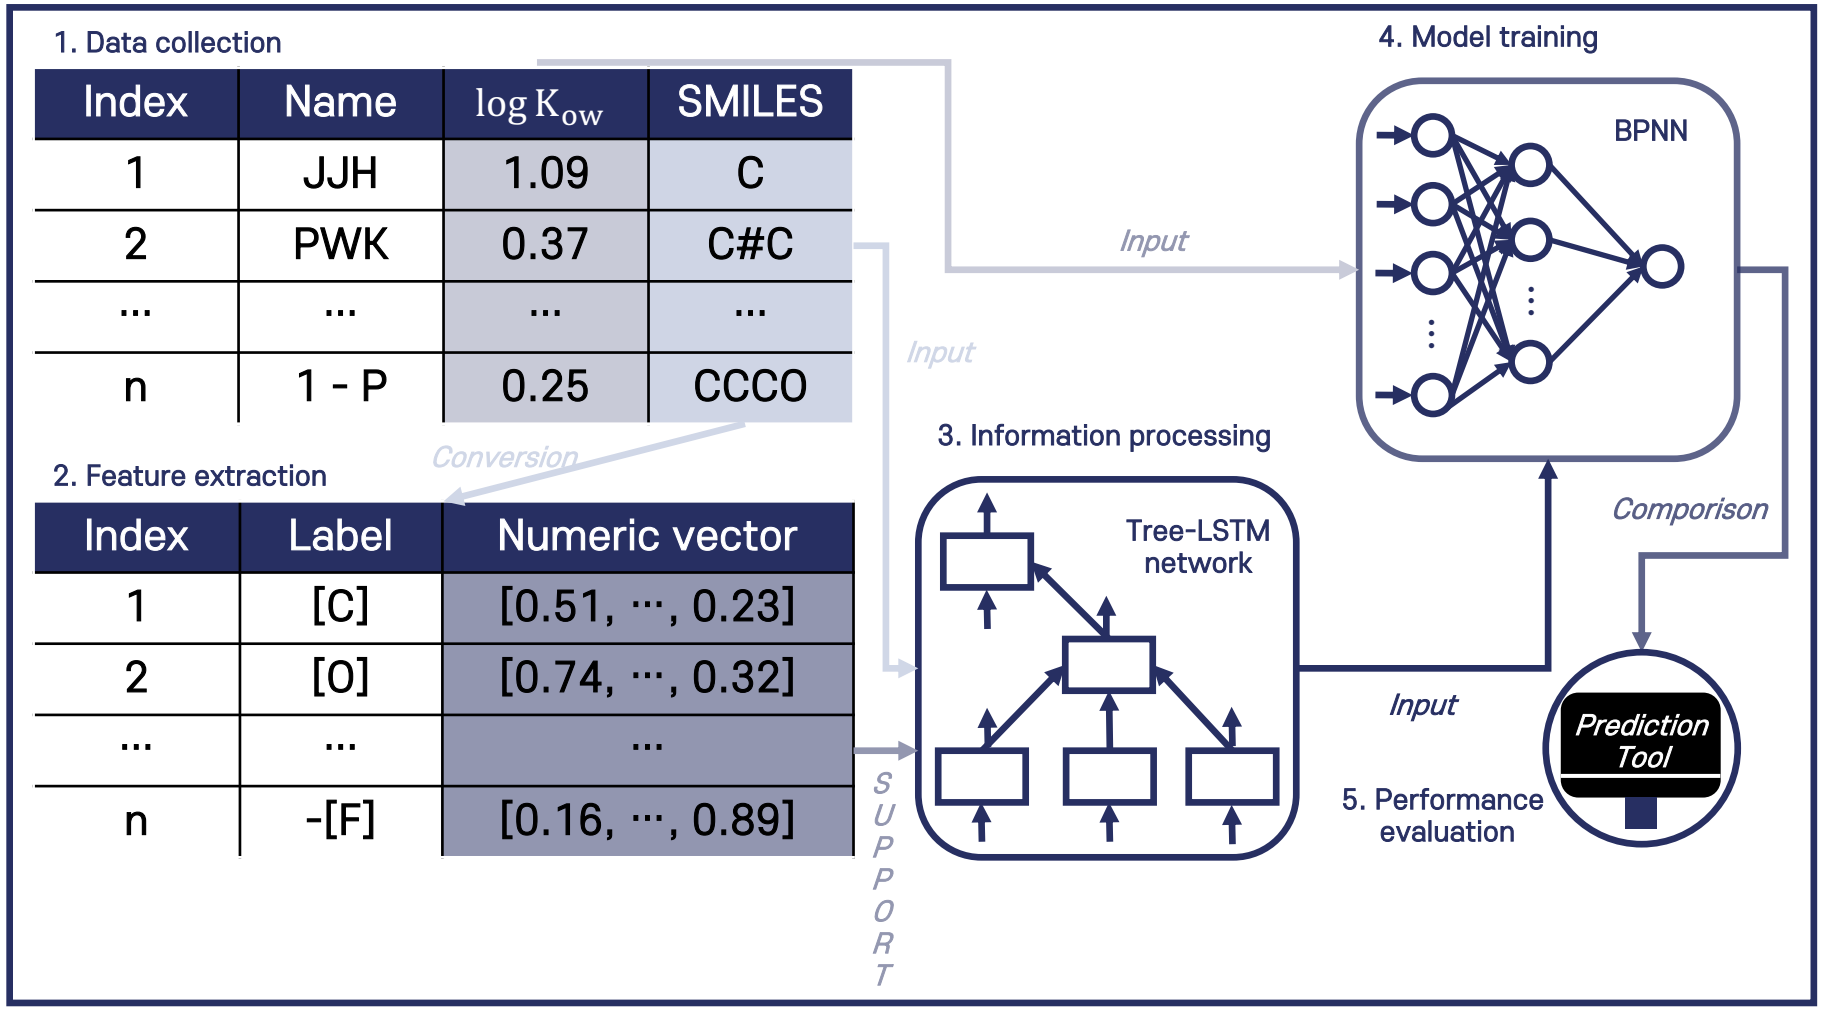

딥러닝 접근 방식을 사용하여 QSPR 모델을 개발하는 프로세스의 개략도

12) sciencedirect

I 프로토타입

LIGHT

메인 화면

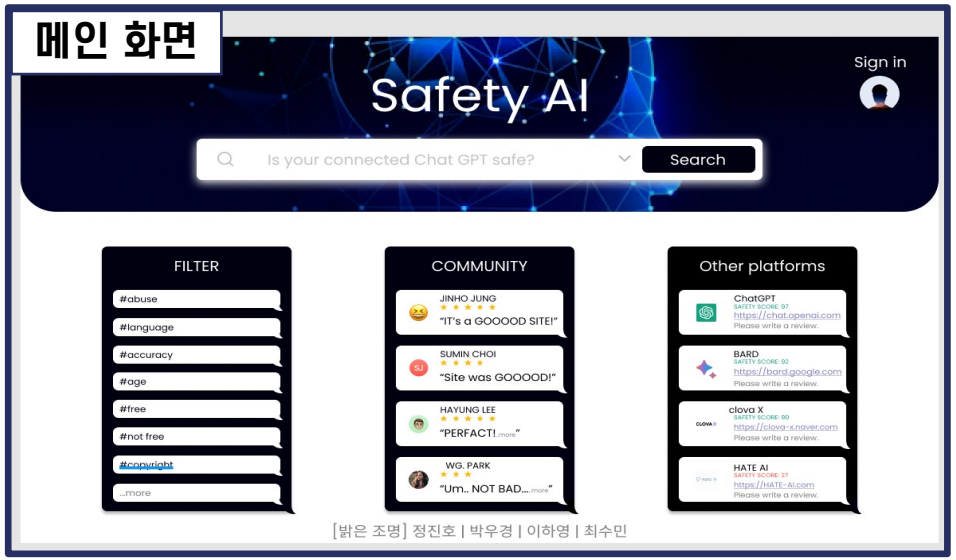

커뮤니티 화면

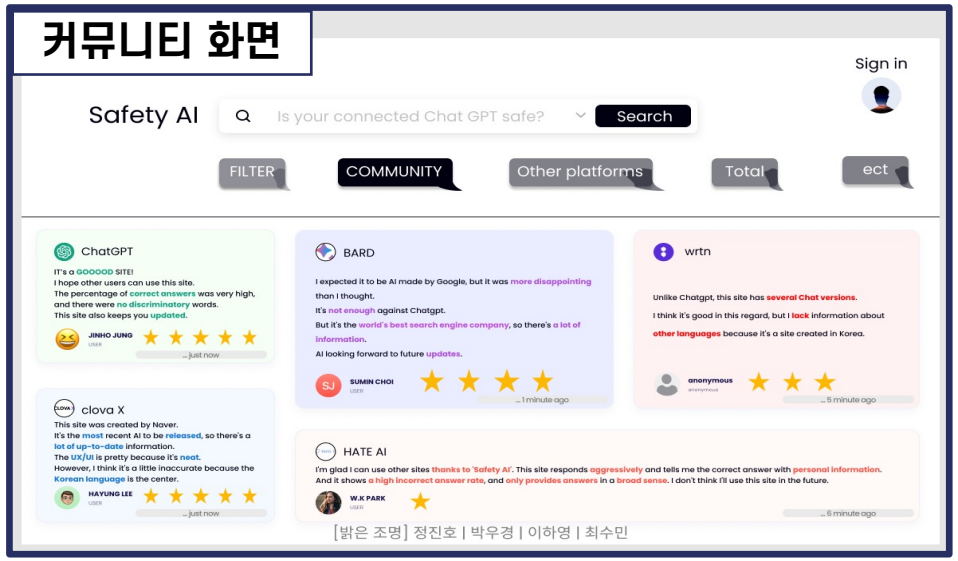

Safety Score 화면

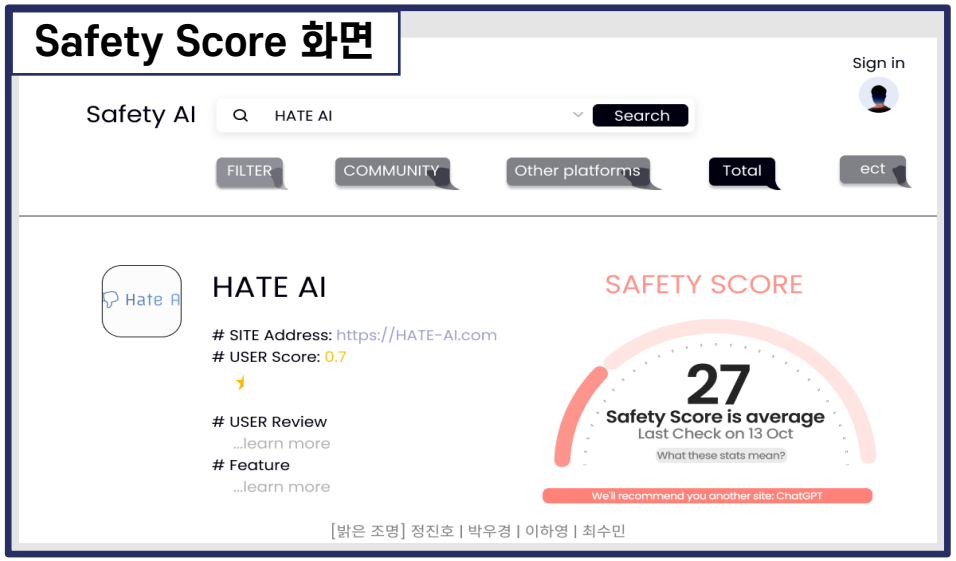

리뷰 화면

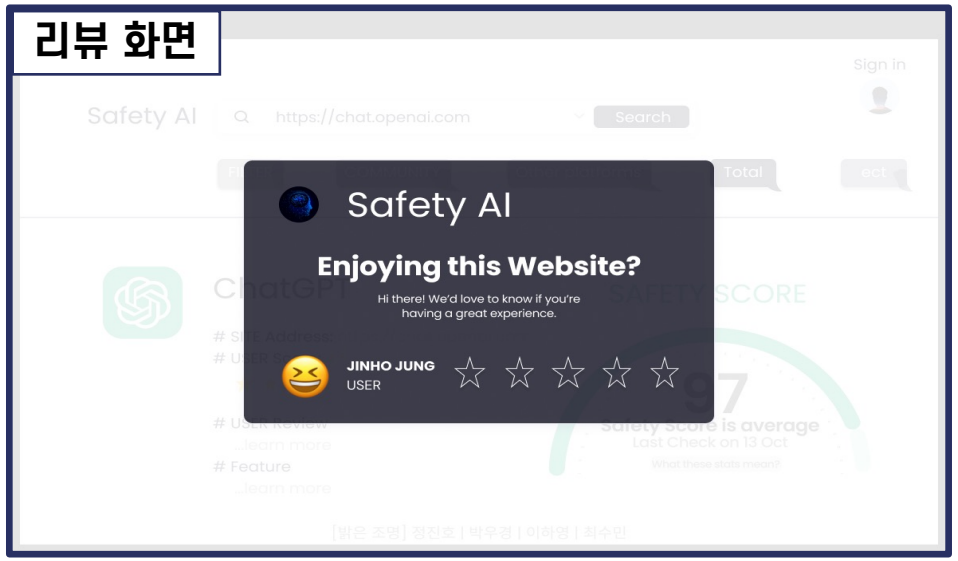

기 대 효 과

I 기대효과

LIGHT

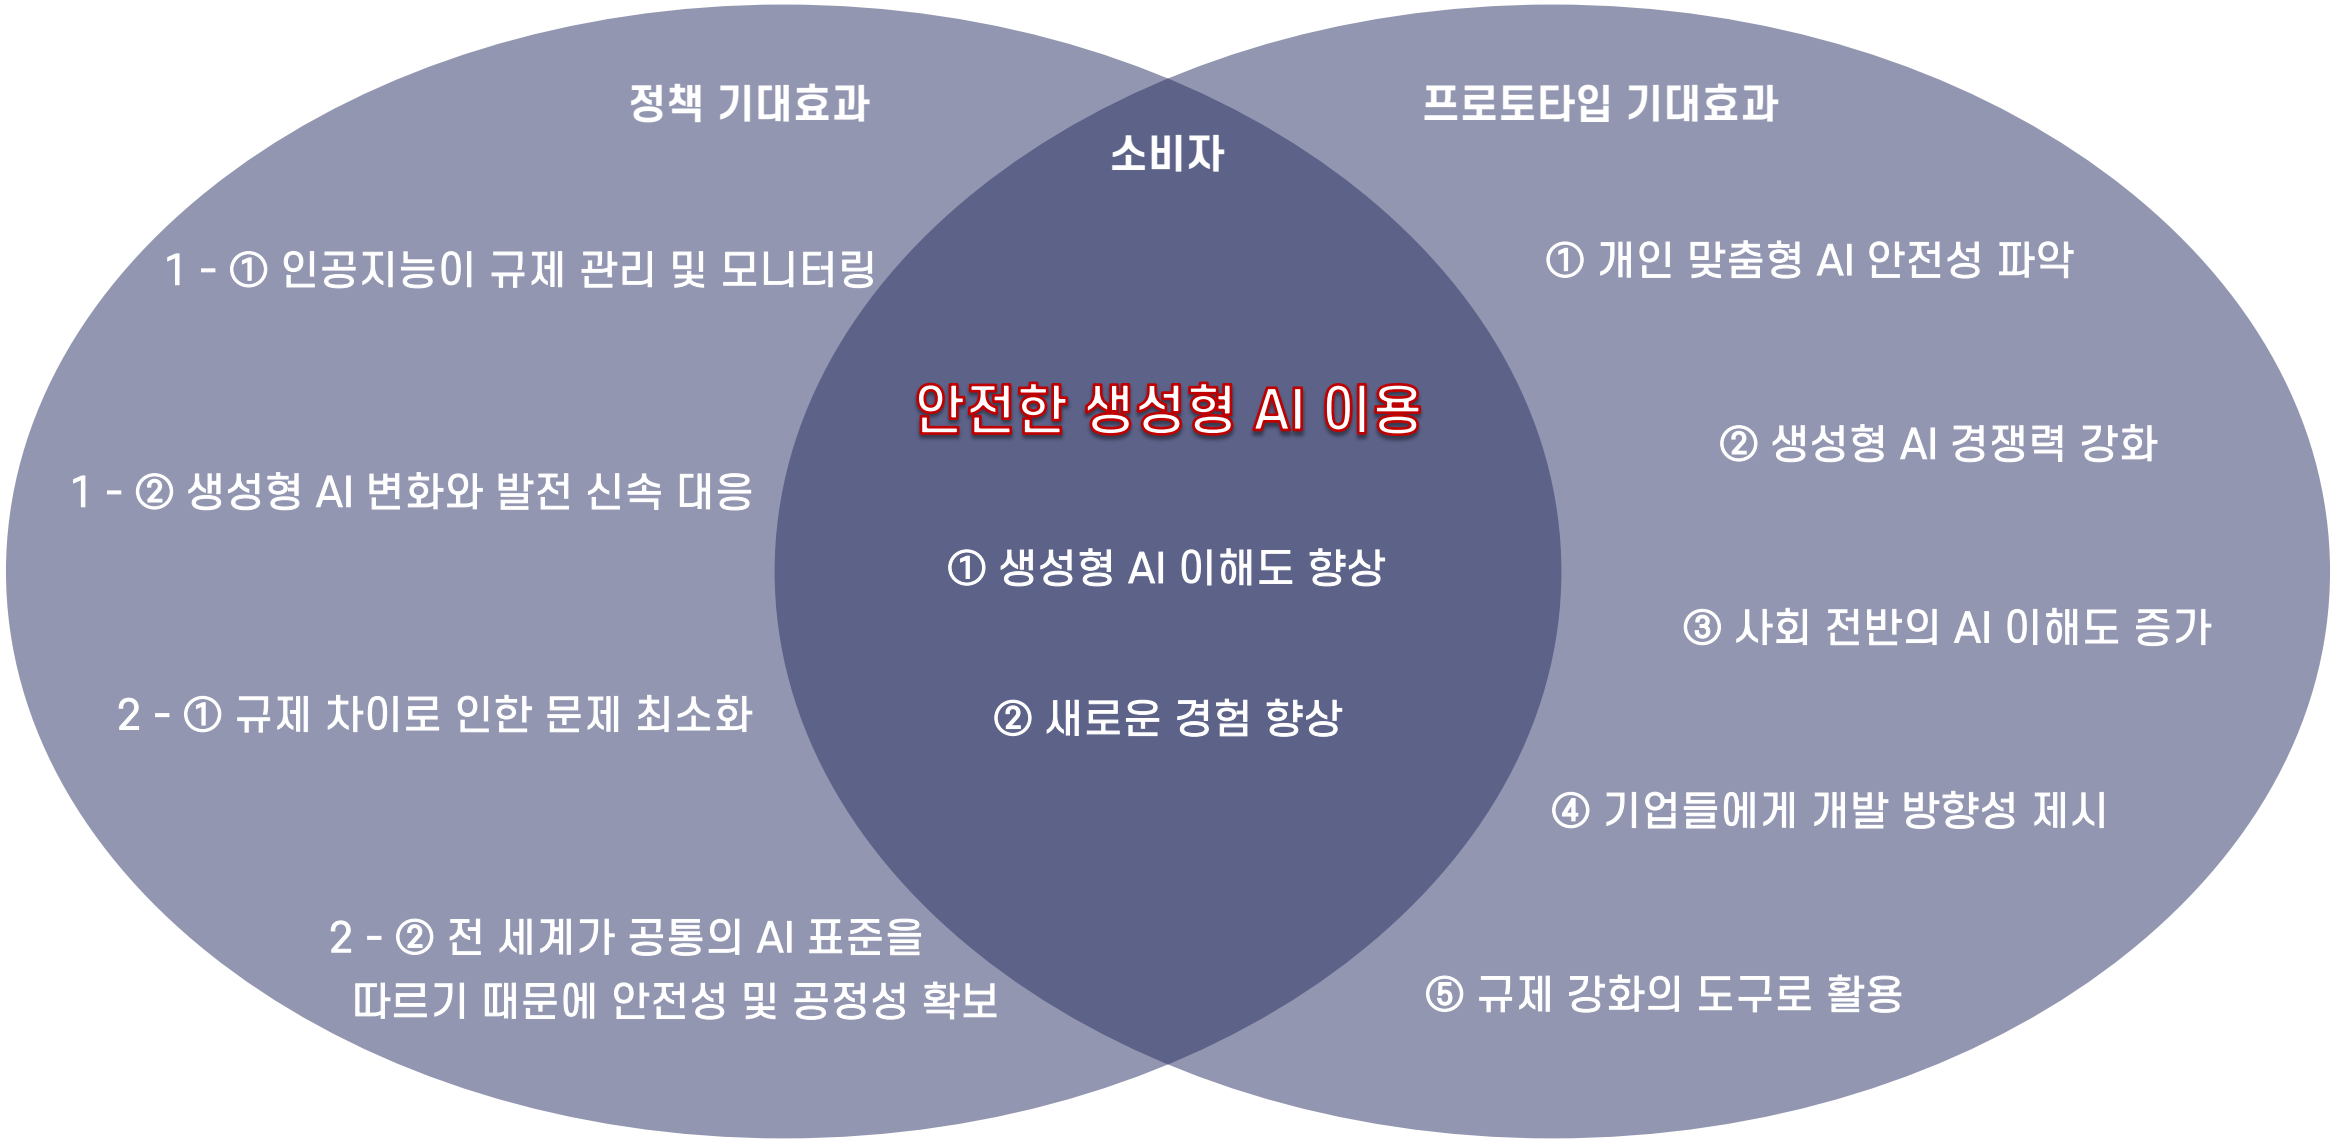
정책 기대효과
1 - ① 인공지능이 규제 관리 및 모니터링
1 - ② 생성형 AI 변화와 발전 신속 대응
2 - ① 규제 차이로 인한 문제 최소화
2 - ② 전 세계가 공통의 AI 표준을 따르기 때문에 안전성 및 공정성 확보
소비자
안전한 생성형 AI 이용
① 생성형 AI 이해도 향상
② 새로운 경험 향상
프로토타입 기대효과
① 개인 맞춤형 AI 안전성 파악
② 생성형 AI 경쟁력 강화
③ 사회 전반의 AI 이해도 증가
④ 기업들에게 개발 방향성 제시
⑤ 규제 강화의 도구로 활용

LIGHT

감 사 합 니 다